2026 K-Health 미개방 의료데이터 활용 경진대회_데이터 시각화 결과보고서
주최/주관: 과학기술정보통신부, NIPA, K-Health 참여기관 | 운영: 데이콘

CTG 파형 특성의 정의 및 추출을 통한 이상 판독(Abnormality) 예측 모델 개선

파형 특성 인자 분석과 Abnormality 의 임상적 이해

활용 데이터셋: [건양대학교의료원] 태아 심박동 모니터링 데이터

팀명: 아마데이터

설한동
소속: 서울대학교 컴퓨터공학과 21 학번, 4 학년
역할: 데이터 구조 분석, 인자 계산과 모델 분석, 분석 방법 및 결과 정리 (3~4 장)

설정혜
소속: 연세대학교 약학과 23 학번, 4 학년
역할: 임상 배경과 데이터 해석, 결과의 임상적 의미 검토, 약학적 고찰 (2 장, 5 장)

K-Health 참여기관: 대전정보문화산업진흥원, 건양대학교의료원, 대구디지털혁신진흥원, 대구·광주테크노파크 등
후원: 과학기술정보통신부, 정보통신산업진흥원, 대전정보문화산업진흥원, 대구디지털혁신진흥원, 대구테크노파크, 광주테크노파크

목차

요약 4

1. 서론 6

1.1 배경과 문제의식 6

1.2 연구 질문과 가설 6

1.3 제안서 대비 변경 사항 7

2. 분석 데이터 8

2.1 데이터 출처 및 구성 8

2.2 분석 데이터 선정과 제외 10

2.3 분석 데이터 특성 11

2.4 산모 단위 분할 13

2.5 해석에 있어서 고려해야 할 데이터 특성 14

3. 분석 방법 16

3.1 전처리와 파형 인자 28개 16

3.2 모델과 비교군 17

3.3 평가 지표와 신뢰구간 20

3.4 경보 기준, 기관 간 일반화, 분만 결과 분석 설계 22

4. 결과 25

4.1 판독 재현 성능 (H1, H2) 25

4.2 인자 기여 구조 (H3) 27

4.3 인자 모델과 CNN 비교 (H4) 29

4.4 임상정보 추가 효과 31

4.5 경보 성능 32

4.6 기관 간 일반화 평가 34

4.7 판독과 분만 결과 (H5) 36

5. 임상적 고찰 39

5.1 판독 재현과 태아 상태 예측의 차이 39

5.2 인자 이름과 임상 의미의 차이 42
5.3 변이도 중심 모델과 설명 가능성 45
5.4 경보 부담과 적용 가능성 47
5.5 모델이 반영하지 못하는 임상 맥락 48
5.6 선행 연구와의 비교 49
5.7 종합 50
6. 한계와 향후 과제 52
6.1 한계 52
6.2 향후 과제 52
Data availability 54
참고문헌 54
부록 A. 파형 인자 28개의 계산 규칙 56
부록 B. 파형 인자의 계산 특성과 주석 비교 58
부록 C. 임신과 분만 중 사용 약물의 태아 심박 영향 59

요약

본 연구는 5분 태아 심박동 모니터링 파형에서 계산한 28개 인자가 전문의의 이상 판독을 얼마나 재현하는지, 어떤 인자군에 예측 성능이 의존하는지, 그 성능이 경보와 기관 이동에서도 유지되는지를 평가하였다. 전문의 판독과 분만 결과의 관계는 별도의 기록 단위 분석으로 살펴보았다. 이 설계는 공개 데이터(CTU-UHB) 산모 552명으로 파형 인자 기반 모델과 CNN을 비교한 Google Research의 선행 연구(Chiou et al., 2025)를 국내 산모 20,551명 규모로 확장한 것이며, 학습 라벨은 분만 결과 대신 전문의 판독을 사용하였다.

분석 자료는 산모 20,551명의 기록 22,137건, 5분 구간 94,148개이다. 같은 산모의 반복 검사와 다태아 기록을 묶어 학습·검증·시험 집합을 나누었다. 단일 인자 모델, 가산 모델, CatBoost·XGBoost 및 경량 CNN을 비교하고, 시험 성능과 짝지은 차이에 산모 군집 부트스트랩 95% 신뢰구간을 제시하였다. 주 모델 Cat28의 입력은 전처리한 FHR·TOCO에서 계산한 28개 인자이며, 특징군 제거·평활화 변경·SHAP 분석으로 기여 구조를 확인하였다.

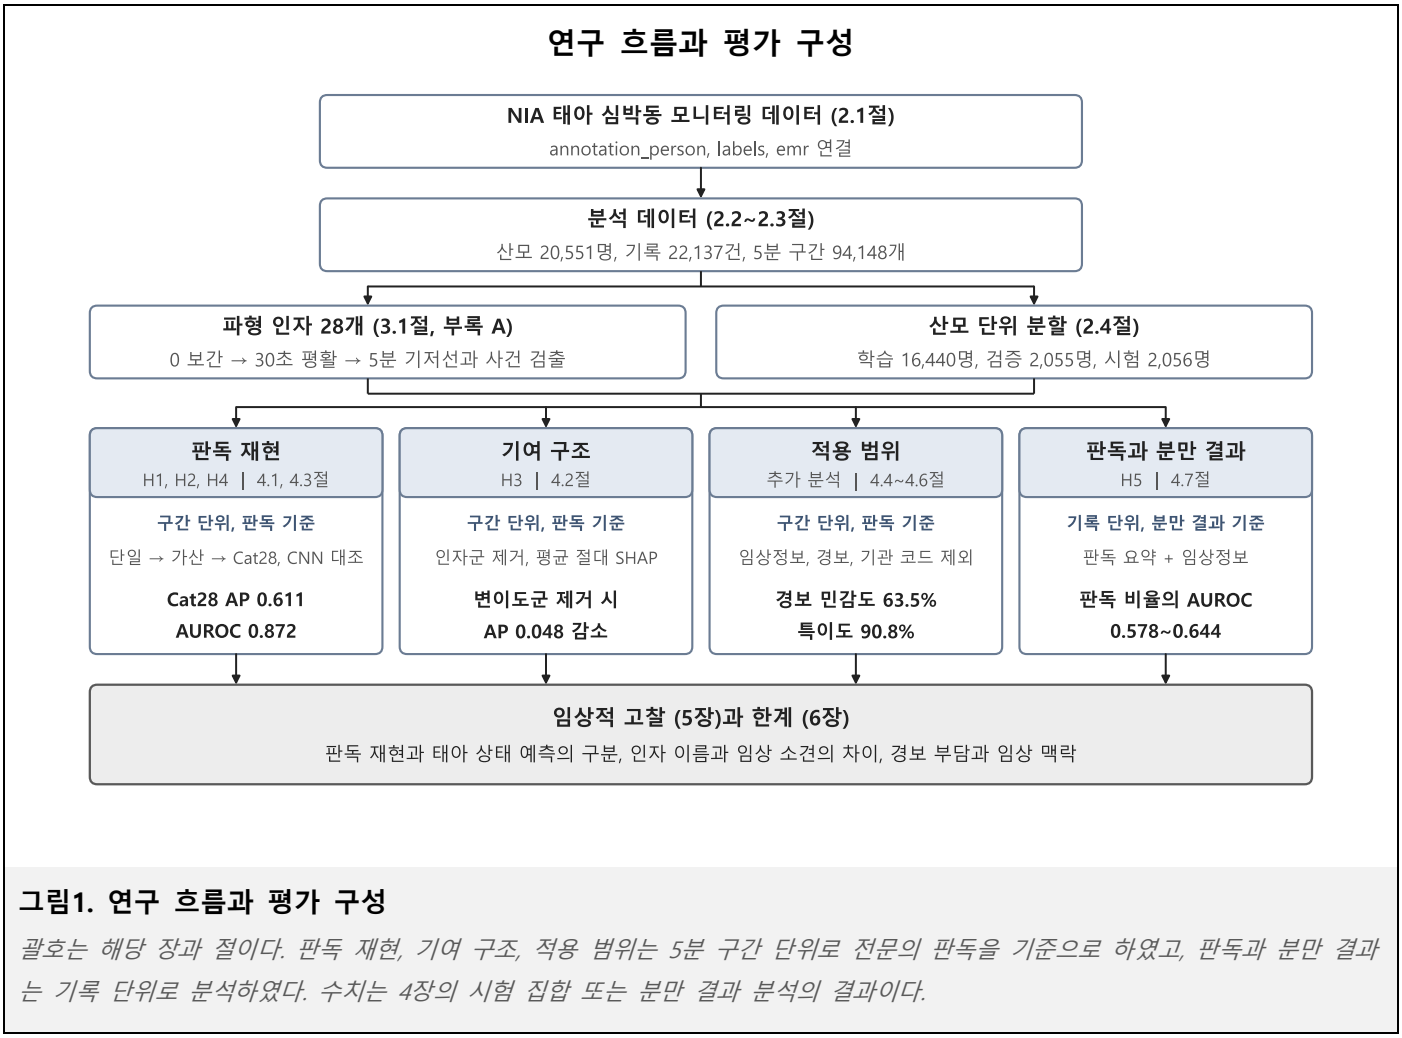


그림1. 연구 흐름과 평가 구성

괄호는 해당 장과 절이다. 판독 재현, 기여 구조, 적용 범위는 5분 구간 단위로 전문의 판독을 기준으로 하였고, 판독과 분만 결과는 기록 단위로 분석하였다. 수치는 4장의 시험 집합 또는 분만 결과 분석의 결과이다.

시험 구간 9,458개에서 Cat28의 AP는 0.611(95% CI 0.570~0.653), AUROC는 0.872(0.858~0.886)였다. 검증에서 선택한 단일 spline 모델보다 AUROC가 0.128(0.110~0.146) 높았다. 변이도 인자군 제거 시 AP는 0.048(0.034~0.062) 감소하였다. 절대 수준을 보존한 소형 CNN과 비교하면 Cat28의 AP 차이

는 -0.014(-0.033~0.004), AUROC 차이는 -0.016(-0.023~-0.008)이었다. 따라서 AP에서 차이의 방향이 명확하지 않았으나 AUROC는 CNN에 유리하였고, 동등성을 입증한 결과로 해석하지 않았다.

검증 특이도 90%를 기준으로 고정한 경보의 시험 민감도는 63.5%, 특이도는 90.8%, 양성 예측도는 57.1%였다. 정상 기록의 22.2%에서 경보가 발생했고, 정상 기록의 유지 시간당 경보 구간 수는 0.97개였다. 기관 코드 제외 평가에서는 기관별 이상 판독 비율과 경보 특이도가 달랐다. 실제 판독 요약을 임상정보에 추가한 분만 결과 분석에서는 1분 Apgar의 예측이 개선되었으나, pH와 5분 Apgar의 증분은 지표에 따라 달랐다.

이 결과는 구현으로 정의한 파형 인자를 이용한 판독 재현의 가능성을 보여 준다. 다만 인자 이름과 임상 소견의 동일성을 전제할 수 없다. 5분 단위 기저선 추정, 30초 평활, 사건 문턱과 유형 분류의 제한을 구분해 설명하였으며, 지속감속·중증 감속 인자는 이번 특징표에서 모두 상수였다. 인자 기여는 해당 계산값에 대한 모델의 의존성을 뜻하며, 전문의의 판단 과정이나 태아 상태에 대한 인과적 설명을 뜻하지 않는다.

1. 서론

1.1 배경과 문제의식

태아 심박동 모니터링 파형에는 심박수 수준, 변동, 가속·감속, 자궁수축과의 시간 관계가 함께 나타난다. 본 연구의 질문은 이 파형에서 명시적인 규칙으로 계산한 인자들이 자료에 저장된 전문의 이상 판독을 어느 정도 재현하는가이다. 예측 결과를 입력 인자와 연결할 수 있다면 모델이 사용한 정보를 검토할 수 있으나, 그 인자가 해당 임상 소견을 정확하게 측정하는지는 별도의 문제이다.

예측 대상은 5분 구간의 Abnormality이며, 제대동맥혈 pH나 Apgar 점수와 구별한다. 판독 재현 성능이 높더라도 이를 곧바로 태아 상태의 진단 성능이나 임상적 유익성으로 바꿔 해석할 수 없다. 따라서 파형 인자에 의한 판독 재현, 인자 기여의 구조, 실제 판독과 분만 결과의 관계를 차례로 평가하였다. 데이터와 판독 생성 맥락은 2장, 임상적 해석은 5장에서 다룬다.

분석은 단일 인자로 시작해 여러 인자를 결합한 모델과 파형을 직접 입력하는 CNN으로 비교 범위를 넓힌다. 이어 검증에서 정한 경보 기준, 기관 코드 제외 평가, 임상정보 추가 효과를 확인한다. 28개 인자는 구현 규칙에 따른 파형 요약값으로 정의하고, 계산 규칙과 임상 용어의 차이는 3.1절·5.2절 및 부록 A에서 검토한다.

1.2 연구 질문과 가설

제안서의 H1–H5는 판독 재현의 충분성·종합성, 인자 기여 구조, 경량 CNN과의 비교, 판독과 분만 결과의 부분적 대응을 묻는다. 가설의 방향은 유지하되, 판단에 사용하는 증거와 해석 범위를 아래와 같이 정리하였다. 이 보고서에서 '인자'는 부록 A의 계산 규칙으로 정의한 입력 열을 뜻한다.

표1. 연구 가설과 평가 근거

가설	질문	평가 근거·해석 범위
H1 충분성	인자 조합이 전문의 판독의 상당 부분을 재현하는가?	AP를 주 지표로 하고 AUROC·Brier와 신뢰구간을 함께 제시. 판독 재현의 정도를 평가하며 임상적 충분성의 문턱을 새로 정하지 않음.
H2 종합성	단일 인자보다 인자 조합의 예측력이 높은가?	AUROC를 주 지표로 하여 검증에서 선택한 단일 모델과 조합 모델의 짝지은 시험 성능 차이 및 개발 집합 반복검증을 평가.
H3 기여 구조	변이도·심박수 수준·감속 관련 인자군이 주요 기여를 하는가?	훈련 자료의 관계, SHAP, 인자군 제거를 함께 검토. 계산값의 예측 기여와 임상 소견의 중요도를 구별.

가설	질문	평가 근거·해석 범위
H4 경량 모델 대등성	인자 모델이 지정한 경량 CNN과 비슷한 판독 재현 성능을 내는가?	AP를 주 지표로 하고 같은 시험 구간의 AUROC·Brier 차이, 정규화·용량·비용을 비교. 동등성·비열등성 검정으로 설계한 분석은 아님.
H5 판독–분만 결과 대응	실제 판독과 pH·Apgar의 대응은 부분적인가?	실제 판독 요약의 직접 연관 및 임상정보 대비 예측 증분. 자동 모델의 분만 결과 예측력을 평가한 것은 아님.

가설별 결론은 4장에서 제시한다. 경보·기관 코드 제외 평가와 분만 결과 분석은 적용 범위를 살펴보는 추가 분석이다. 출처: 제안서 4.2.2절.

1.3 제안서 대비 변경 사항

제안서의 연구 질문을 실제 실행된 입력·모델·평가 절차에 맞추어 보고하였다. 단일 인자는 선형과 spline 두 계열에서 각각 검증 AUROC로 선택하였고, 조합 모델에는 선형·spline 가산 모델과 Cat28·Cat18·XGB28을 포함하였다. 개발 집합 반복검증과 동일 seed 비교는 주 시험 결과의 방향을 확인하는 보조 근거로 제시하였다.

28개 인자의 명칭은 원래 코드와 연결되도록 유지하였으나, 이름이 임상 소견과 같다는 이유만으로 측정의 동일성을 전제하지 않았다. 특히 2초 차이 기반 stv, 5분 창의 기저선, 규칙에 따른 감속 유형을 명시하였다. 계산 규칙에서 도출되는 제한과 주 분석 결과에서 관찰한 결과를 구분하고, 전체 정의는 부록 A에 제시하였다.

CNN 비교에서는 두 정규화와 검증에서 선택한 용량·seed의 결과를 함께 보고하였다. 차이의 신뢰구간이 0을 포함한다는 이유만으로 동등성을 확정하지 않고, 지표별 차이와 불확실성을 기술하였다. 분만 결과 분석은 실제 전문가 판독의 요약을 임상정보에 더하는 기록 단위 비교로 수행하였다. 결과의 수치는 본문과 표에, 계산 규칙과 주석 비교는 부록 A·B에 제시하였다.

2. 분석 데이터

2.1 데이터 출처 및 구성

분석 자료는 한국지능정보사회진흥원(NIA)의 2022년 인공지능 학습용 데이터 구축 사업으로 만들어진 태아 심박동 모니터링 데이터이다. 본 팀은 건양대학교의료원의 의료데이터안심존에서 분석을 진행하였다. 원시데이터는 11개 기관 15개 병원에서 수집되었으며(NIA, 2023, p. 19), 기관윤리심의위원회와 기관데이터심의위원회의 승인 후 획득되었다(NIA, 2023, pp. 10-11, 13). 구축 규모는 자료 유형별 24,597건으로, Training 19,678건, Validation 2,459건, Testing 2,460건으로 배분되어 있다(NIA, 2023, p. 8).

수치 시계열은 CTG 그래프 이미지를 수치화한 것이며(NIA, 2023, pp. 21-22), 수집, 정제, 가공 과정은 앞서 제출한 제안서의 2.1절에 기술하였다. 이 보고서의 기록과 구간은 제안서의 레코드와 세그먼트를 뜻한다. 기록은 한 산모의 한 차례 측정에서 얻어진 연속된 CTG 기록이고, 구간은 이를 5분 간격으로 나눈 단위이다(제안서 2.3.1절). 이 분석에서는 이미지를 제외한 JSON 3종을 기록 ID로 연결해 사용하였다. 신호는 5분 구간마다 FHR과 TOCO가 2초 간격으로 150개씩 들어 있고, 다태아 기록은 해당 태아의 구간만 선택하였다. 각 자료의 내용은 아래와 같다.

표2. 분석에 활용한 원자료의 구성

원자료	분석 활용 항목	용도
annotation_person	code	기록 코드(예: aju_10357_20120618). 첫 번째 밑줄 앞의 접두사로 13개 기관 코드를 구분. 기관 코드와 실제 병원의 대응은 미확인.
	twins	단태아("False"), 다태아("True") 표시. 다태아 기록이면 해당 태아의 구간만 선택.
	data.partial_image	구간 이미지의 파일명. 이름의 twin1, twin2와 기록 ID 끝자리(_1, _2)를 맞춰 해당 태아의 구간을 식별. 이미지 내용은 사용하지 않음.
	data.fhr, data.toco	구간별 FHR(bpm)과 TOCO(원본 척도) 값. 5분 구간마다 채널별 150개 값을 읽어 파형 인자 28개 계산과 CNN 입력에 사용.
	data.interval_sec	측정 간격(초). 2초가 아니면 신호 오류로 보아 기록 전체를 제외.
labels	ID	기록 ID. 파일명과 일치하는지 검증하며, 다르면 기록 전체를 제외.
	Abnormality	5분 구간별 전문의 이상 판독(예: 1_0_0은 첫 구간만 이상). ① 모델의 예측 대상. ② 산모의 이상 구간 보유 여부를 층화 분할(stratified split) 기준으로 사용. ③ 기록별 이상 구간 비율과 가장 긴 이상 연속 길이를 계산해 분만 결과 분석의 판독 요약으로 사용.
	Bbox	이상 구간의 이미지 좌표([x1, y1, x2, y2, width, height]). 좌표가 이상 라벨의 구간과 맞는지 검증. 맞지 않으면 기록 전체를 제외하고, Bbox가 없으면 미검증 상태로 유지.
	BaseLine	기록별 판독 기저심박수. 파형 인자 figo_baseline의 기록 평균과 비교해 측정 타당성 확인.
	Baseline_Variability	기록별 판독 기저선 변이도(0 absent, 1 minimal, 2 moderate, 3 marked). figo_baseline_var의 기록 평균과 비교.
	Acceleration	기록별 판독 가속 유무(1 Yes, 2 No). n_accel의 기록 합계와 비교.
	Early_deceleration	기록별 판독 조기감속 유무(0 No, 1 Yes). n_early_decel의 기록 합계와 비교.
	Late_deceleration	기록별 판독 후기감속(0 없음, 1 1회, 2 2회 이상). n_late_decel의 기록 합계와 비교.
	Variable_deceleration	기록별 판독 변이감속(0 없음, 1 1회, 2 2회 이상). n_variable_decel의 기록 합계와 비교.

원자료	분석 활용 항목	용도
	Prolonged_deceleration	기록별 판독 지속감속 유무(0 No, 1 Yes). n_prolonged_decel의 기록 합계와 비교.

원자료	분석 활용 항목	용도
emr	ID	기록 ID. 파일명과 일치하는지 검증하며, 다르면 기록 전체를 제외.
	Mother.de-identification_ID	비식별 산모 ID. 같은 산모의 반복 검사와 다태아 기록을 묶어, 학습, 검증, 시험 집합에 나뉘지 않도록 산모 단위로 분할.
	Mother.Height, Mother.Weight	산모 신장, 체중. 임상 변수로 사용.
	Mother.Gravida, Mother.Para	임신 횟수, 출산 횟수. 임상 변수로 사용.
	Mother.SBP, Mother.DBP	수축기 혈압, 이완기 혈압. 임상 변수로 사용.
	Mother.GHTN, Mother.Hypertension	임신성 고혈압, 기왕 고혈압 여부. 임상 변수로 사용.
	Mother.GDM, Mother.DM	임신성 당뇨, 기왕 당뇨 여부. 임상 변수로 사용.
	Mother.pre-eclampsia	자간전증, 자간증 여부(1 pre-eclampsia, 2 eclampsia, 3 해당없음). 임상 변수로 사용.
	Birth Date, Mother.Birth Date	신생아 출생 연월, 산모 출생 연월. 두 출생 연도의 차에 1을 더해 산모 연령을 산출하고 임상 변수로 사용.
	GA.wks, GA.day	분만 시 재태주수의 주, 일. 주 + 일/7로 재태주수를 산출하고 임상 변수로 사용.
	UA.pH	제대동맥혈 pH(선택 항목). 6~8 범위의 값만 사용하고, 7.20 미만을 분만 결과로 정의.
	APGAR.1min, APGAR.5min	출생 1분, 5분 Apgar 점수. 0~10 범위의 값만 사용하고, 7점 미만을 분만 결과로 정의.

임상 변수 13개는 항목을 그대로 쓴 11개와 산출한 산모 연령, 재태주수다. 임상정보 추가 분석과 분만 결과 분석의 기준 모델에 사용했다. 판독 7개 항목은 측정 점검에만 쓰고 모델 입력과 인자 선택에는 쓰지 않았다.

출처: NIA, 2023, pp. 3-6; 제안서 2.1.4절, 표4.

2.2 분석 데이터 선정과 제외

분석 데이터는 자료 연결, 기록 검증, 구간 결측 확인의 세 단계로 선정하였다(그림2). 먼저 원자료의 고유 기록 ID는 annotation_person과 emr이 각각 24,597개, labels가 22,167개였다. 이 중 세 자료에 모두 있는 22,167건을 입력으로 사용하였고, 제외된 2,430건은 모두 labels가 없는 기록이었다(계산). 같은 ID의 중복 파일은 내용이 같거나 labels의 Bbox 유무만 다른 경우 하나로 합쳤으며, 내용이 충돌한 기록은 없었다.

다음으로 기록을 검증하였다. 각 기록은 파일명과 내부 ID가 일치하고 산모 ID, 기관 코드, 다태아 표기가 유효해야 한다. 라벨은 수가 구간 수와 같고 값이 0 또는 1이어야 하며, 신호는 구간마다 FHR과 TOCO가 유한한 값 150개씩이고 측정 간격이 2초이며 FHR이 음수가 아니어야 한다. Bbox가 있으면 그 위치가 이상 라벨의 구간과 일치해야 한다. 이 검증에서 라벨 오류 28건과 신호 오류 2건을 제외하여 22,137건을 남겼으며, 그 밖의 사유로 제외된 기록은 없었다. 다만 Bbox가 없는 기록은 검증하지 않은 상태로 유지하였고, 그 수는 집계하지 않았다.

마지막으로 구간별 FHR 결측률을 확인하였다. FHR 값 0을 결측으로 보고, 150개 값 중 0의 비율이 30%를 초과하는 구간을 제외하도록 정하였으나 해당 구간은 없었다. 분석 데이터는 산모 20,551명의 기록 22,137건, 5분 구간 94,148개이며, 이상 구간이 하나 이상 있는 산모는 5,991명(29.2%, 계산)이었다.

라벨이 없는 2,430건과 검증에서 제외된 30건의 합은 NIA의 Testing 배정 수 2,460건과 같고, 남은

22,137건은 Training과 Validation의 합과 같다(NIA, 2023, p. 8; 계산). 따라서 표본 감소는 임상적 특성에 따른 선택보다 Testing 라벨이 제공되지 않은 결과일 가능성이 있으나, 원본 폴더와 대조하여 확인하지는 못하였다.

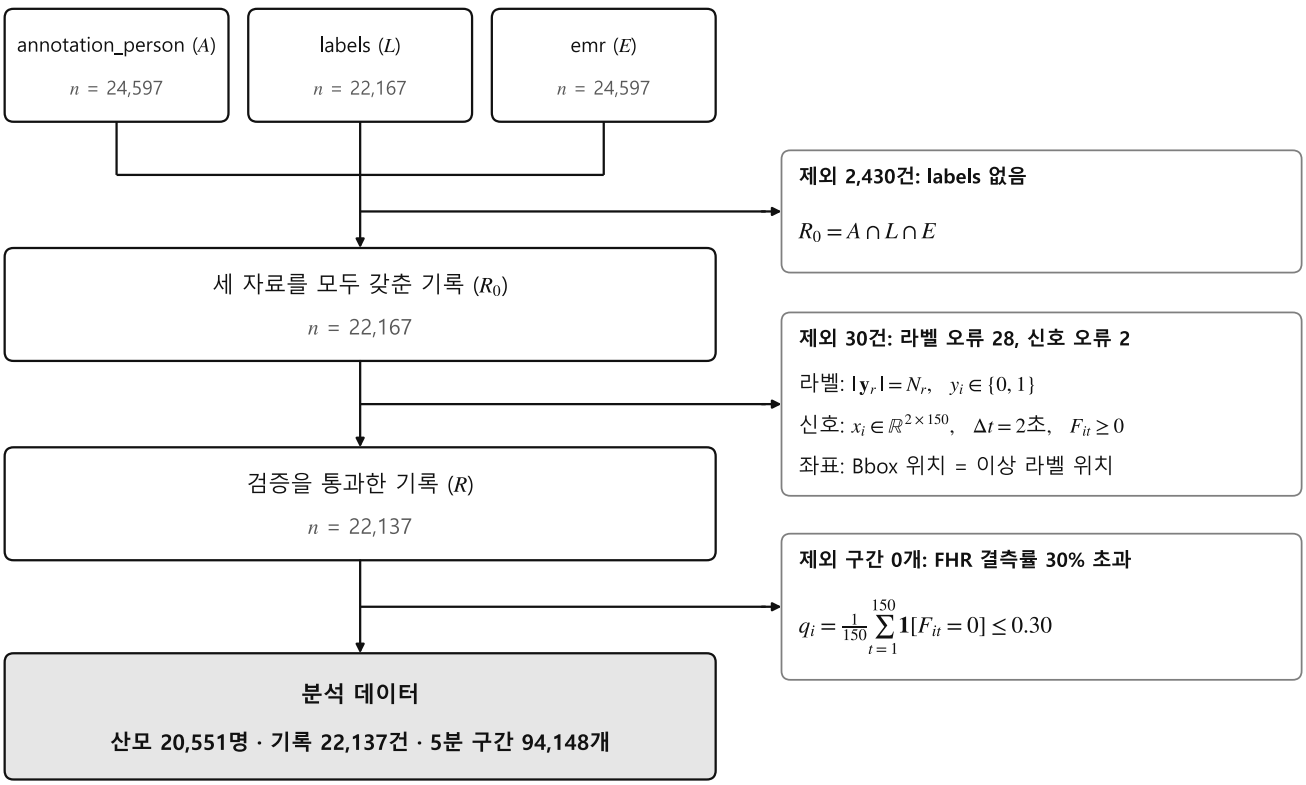


그림2. 분석 데이터 선정 과정과 판단 기준

F_{it}는 구간 i의 t번째 FHR 값, x_i는 구간 i의 FHR과 TOCO 신호, y_i는 구간 i의 이상 라벨, $\mathbf{y}_r$은 기록 r의 라벨 배열, N_r은 기록 r의 구간 수, Δt는 측정 간격, q_i는 구간 i의 FHR 결측률이다.

2.3 분석 데이터 특성

분석 데이터는 산모 20,551명의 기록 22,137건, 5분 구간 94,148개로, 산모당 평균 1.08건의 기록과 기록당 평균 4.25개의 구간(약 21분)을 포함한다(표3, 그림3; 계산). 이상 구간은 15,020개로 전체의 16.0%였다. 이상 구간이 하나 이상 있는 기록은 6,127건(27.7%), 산모는 5,991명(29.2%)이었다(계산). **집계 단위가 넓어질수록 이상 비율이 높아지므로, 결과를 읽을 때 어느 단위의 비율인지 구분해야 한다.**

데이터는 13개 기관 코드로 구분된다. 구간 수는 aju가 20,488개(21.8%), inj가 15,706개(16.7%)로 많았다. 산모 수가 공개 기준인 5명에 미치지 않는 1개 코드를 뺀 12개 코드의 이상 구간 비율은 knu 7.0%부터 cat 39.6%까지 차이를 보였다(그림5; 계산). 다만 기관 코드와 실제 병원의 대응은 확인되지 않았다. 코드 수가 수집 기관 수(11개)와 다른 이유도 확인되지 않았다.

분만 결과 중 Apgar 점수는 거의 모든 기록에서 관측되었으나, 선택 항목인 제대동맥혈 pH는 12,637건(57.1%)에서만 기록되어 있었다(NIA, 2023, pp. 4-5; 계산). pH 7.20 미만은 1,114건(8.8%), 1분 Apgar 7점 미만은 3,227건(14.6%), 5분 Apgar 7점 미만은 658건(3.0%)이었다. 이상 구간이 있는 기록의 비율은 pH가 관측된 기록에서 29.9%, 관측되지 않은 기록에서 24.7%였으므로, pH 측정 여부가 임상 상황과 관련되었을 가능성이 있다.

표3. 분석 데이터의 규모와 분만 결과

구분	항목	값	계산식
규모	산모	20,551명	-
	기록	22,137건	산모당 22,137 / 20,551 = 1.08건
	구간	94,148개	기록당 94,148 / 22,137 = 4.25개
이상 판독	이상 구간	15,020개 (16.0%)	15,020 / 94,148
	이상 구간이 있는 기록	6,127건 (27.7%)	6,127 / 22,137
	이상 구간이 있는 산모	5,991명 (29.2%)	5,991 / 20,551
분만 결과	pH 7.20 미만	1,114건 (8.8%)	1,114 / 12,637
	1분 Apgar 7점 미만	3,227건 (14.6%)	3,227 / 22,136
	5분 Apgar 7점 미만	658건 (3.0%)	658 / 22,137

집계값에서 계산하였다.

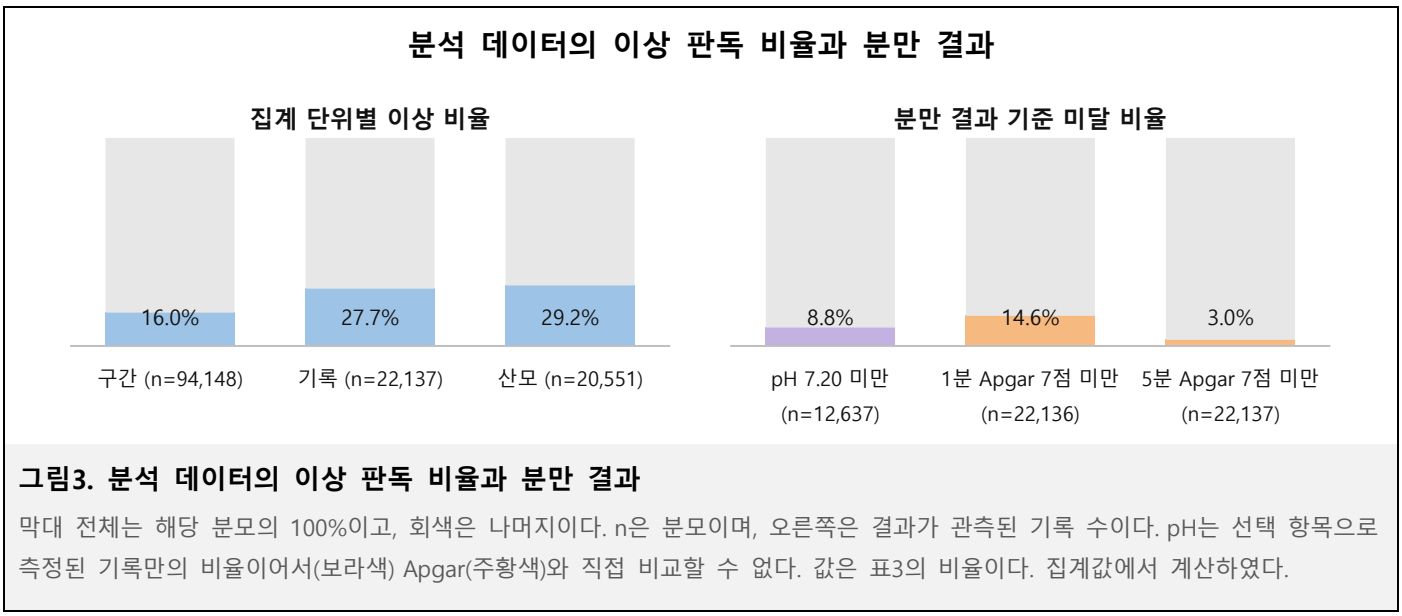


그림3. 분석 데이터의 이상 판독 비율과 분만 결과

막대 전체는 해당 분모의 100%이고, 회색은 나머지이다. n은 분모이며, 오른쪽은 결과가 관측된 기록 수이다. pH는 선택 항목으로 측정된 기록만의 비율이어서(보라색) Apgar(주황색)와 직접 비교할 수 없다. 값은 표3의 비율이다. 집계값에서 계산하였다.

데이터 구축 보고서에 따르면, 구축 전체 24,597건에서 산모는 30대가 76.64%로 가장 많았고, 출산 경험이 없는 경우가 54.35%였다. 태아 체중 2,500 g 미만은 33.37%(계산), 다태아는 16.05%, Category 2+3은 27.28%, 응급은 46.29%였다(그림4; NIA, 2023, p. 9). 이 값에는 분석에서 제외된 기록도 포함되어 있으므로, 분석 데이터의 분포와 다를 수 있다.

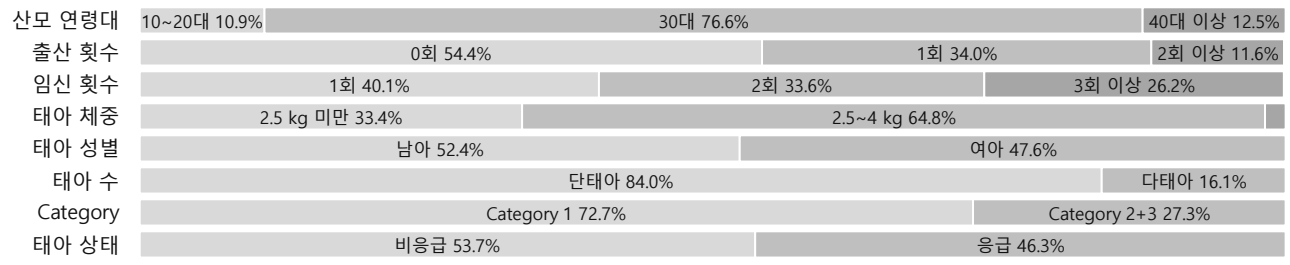


그림4. 구축 전체 데이터의 분포

분석에서 제외된 기록도 포함되어 분석 데이터의 분포와 다를 수 있다. 일부 구간은 묶어 계산하였고, 작은 구간의 라벨은 생략하였다. 체중 단위는 원문에 표기되지 않아 g으로 보았고, 재태주수 분포는 NIA 표에 없다. 출처: NIA, 2023, p. 9.

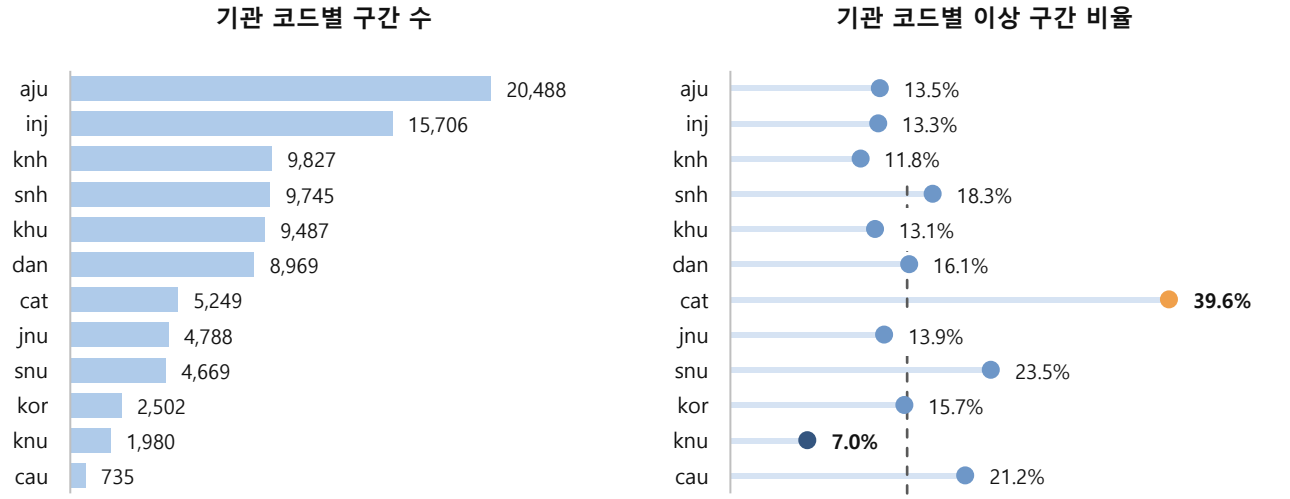


그림5. 기관 코드별 구간 수와 이상 구간 비율

점선은 전체 이상 구간 비율(16.0%)이다. 주황 점은 비율이 가장 높은 코드, 남색 점은 가장 낮은 코드이다. 산모 수 5명 미만인 1개 코드는 표시하지 않았다. 출처: 본 분석의 기관 코드별 집계로 작성; 계산.

2.4 산모 단위 분할

분석 데이터는 모델을 학습하기 전에 산모 단위로 학습, 검증, 시험 집합으로 나누어 고정하였다. 같은 산모의 반복 검사와 다태아 기록이 여러 집합에 흩어지면, 이미 학습한 산모의 정보로 성능이 높게 평가될 수 있기 때문이다.

목표 비율은 산모 수 기준 80:10:10이다. 먼저 전체 산모의 10%를 시험 집합에 배정하고, 남은 산모의 1/9을 검증 집합에 배정하였다. 이때 이상 구간을 하나라도 가진 산모인지를 기준으로 층화

분할(stratified split)하여, 이러한 산모의 비율이 세 집합에서 비슷하도록 하였다. 산모 ID를 정렬하고 난수 시드를 고정하여 같은 배정을 재현할 수 있게 하였으며, 분할에 실패해도 시드를 바꿔 다시 시도하지 않도록 정하였다.

그 결과 학습 집합에 산모 16,440명, 검증 집합에 2,055명, 시험 집합에 2,056명이 배정되었다(표4). 이상 구간이 있는 산모의 비율은 세 집합에서 29.1~29.2%, 이상 구간 비율은 15.9~16.2%였다(계산). 한 산모가 두 집합에 속하지 않는 것과 모든 구간이 배정된 것을 코드로 확인하였다. 학습 집합은 모델과 결측 대체와 척도 변환 기준의 추정에, 검증 집합은 모델과 경보 임계값의 선택에, 시험 집합은 선택을 고정한 뒤의 평가에 사용하였다.

다만 층화 기준에 기관 코드는 포함하지 않았고, 모든 기관 코드의 자료를 함께 나누었다. **따라서 이 평가는 같은 데이터 체계 안에서 새로운 산모에 대한 내부 검증이며, 외부 검증이 아니다.** 해당 산모가 과거 연구에 포함되었는지도 원본에 이력이 없어 확인할 수 없다. 기관 코드 제외 평가와 분만 결과 분석은 이 분할과 별도의 분할을 사용하며, 3.4절에 기술하였다.

표4. 산모 단위 분할 결과

집합	산모	기록	구간	이상 구간 (비율)	이상 구간이 있는 산모 (비율)	용도
학습	16,440	17,723	75,273	11,975 (15.9%)	4,793 (29.2%)	모델, 결측 대체, 척도 변환 기준 추정
검증	2,055	2,188	9,417	1,517 (16.1%)	599 (29.1%)	모델, 경보 임계값 선택
시험	2,056	2,226	9,458	1,528 (16.2%)	599 (29.1%)	선택 고정 후 평가
합계	**20,551**	**22,137**	**94,148**	**15,020 (16.0%)**	**5,991 (29.2%)**	

일부 비율은 집계값에서 계산하였다.

분할 기준은 다음과 같다. 수식의 아래 첨자 tr, va, te는 학습, 검증, 시험 집합을 뜻한다.

층화 기준:$b_m = max_{i:\, m_i=m}\, y_i$

산모 집합의 분할:$M = M_{tr} \cup M_{va} \cup M_{te}$

집합 간 중복 금지:$M_a \cap M_b = \emptyset \quad (a \neq b)$

배정 비율:$|M_{te}| \approx 0.1|M|, \quad |M_{va}| \approx \frac{1}{9}(|M| - |M_{te}|)$

2.5 해석에 있어서 고려해야 할 데이터 특성

이 절에서는 이후 결과를 읽을 때 고려해야 할 데이터 특성 다섯 가지를 정리하였다(표5).

첫째, 신호에 결측이 드러나지 않는다. 결측률 기준으로 제외된 구간은 없었고, 표시된 12개 기관 코드의 FHR 결측률은 모두 0.0이었다. 그러나 이는 신호 품질이 완전하다는 뜻이 아니다. 수치 시계열은 그래프 이미지에서 복원되었고, 불연속 구간은 자동으로 생성해 보정되었다(NIA, 2023, pp. 21-22). 따라서 0을 결측으로 보는 기준으로는 원래의 신호 소실을 찾아낼 수 없다. 또한 구간 평균 FHR의 범위가 50.3~219.7 bpm이었다. 외부 모니터링은 산모 심박 혼입과 이중 계수와 반감 계수에

취약하므로(FIGO, 2015, p. 14), 생리적 범위를 벗어난 구간에는 이러한 오류가 포함되었을 수 있으나 별도로 점검하지는 않았다.

둘째, 기록이 짧고 분만과의 시간 간격을 알 수 없다. 기록당 평균 길이는 약 21분으로(계산), 같은 사업의 자료를 쓴 선행 연구의 기록 길이 5~70분, 평균 약 23분과 비슷하다(박창은, 2025, p. 3; 계산). 측정일은 연월까지만 제공되므로(NIA, 2023, p. 4), 기록과 분만 사이의 간격을 계산할 수 없다. 4.7절의 분만 결과 분석은 이 간격을 통제하지 못한 결과이다.

셋째, 데이터가 구축 목표에 맞춰 구성되어 유병률이 실제 분만실과 다를 수 있다. 구축 목표는 Category 2+3이 30%, 응급이 45%였고, 실측값은 각각 27.28%, 46.29%였다(NIA, 2023, pp. 9, 31). 따라서 양성 예측도와 경보율을 실제 분만실의 수치로 옮길 수 없다. 예를 들어 5분 Apgar 7점 미만은 이 데이터에서 3.0%로, 스웨덴 전국 출생 자료의 0.74%(2014~2016년), 0.95%(2018~2020년)보다 높았다(Olofsson et al., 2021, p. 1553).

넷째, 예측 대상인 Abnormality의 정의는 넓을 가능성이 있다. 이상 구간이 있는 기록은 27.7%, 산모는 29.2%였다(표3). 같은 사업의 자료를 쓴 선행 연구는 중등도 변이도에 감속이 없거나 조기감속만 있는 경우를 정상으로, 그 외를 모두 비정상으로 정의하였다(박창은, 2025, p. 4). 기록 단위 비율은 구축 전체의 실측 Category 2+3 비율 27.28%(NIA, 2023, p. 9)와 비슷하지만, 이 분석에서는 CA 항목을 사용하지 않아 두 라벨의 관계를 확인하지 못하였다.

다섯째, 판독이 파형만으로 이루어지지 않았다. 가공판정 절차에서는 라벨링된 영상과 함께 EMR 데이터가 입력되었으며(NIA, 2023, p. 27), 여기에는 분만 이후 확정되는 정보도 포함될 수 있다(제안서 2.1.3절). FIGO도 불량 예후를 아는 후향 검토에서 CTG 소견이 더 이상하게 평가되는 경우가 많다고 설명한다(FIGO, 2015, p. 22). 따라서 Abnormality는 파형만 보고 내린 판단이 아닐 수 있으며, 모델이 재현한 것도 이러한 판독임을 고려해야 한다.

표5. 해석 시 고려할 데이터 특성

특성	확인된 값	해석 시 유의점
신호 결측	FHR 결측률 0.0, 구간 평균 FHR 50.3~219.7 bpm	복원과 자동 보정으로 신호 소실이 드러나지 않고, 범위 밖 구간은 점검하지 않음
기록 길이	기록당 약 21분, 측정일은 연월까지	분만까지의 간격을 통제할 수 없음
유병률	Category 2+3 27.28%, 응급 46.29% (구축 목표 30%, 45%)	양성 예측도와 경보율을 실제 분만실로 옮길 수 없음
Abnormality	이상 구간이 있는 기록 27.7%, 산모 29.2%	정의가 넓을 수 있고 CA와의 관계는 미확인
판독 환경	영상과 EMR을 함께 보고 판정	파형만의 판단이 아닐 수 있음

출처: NIA, 2023, pp. 4, 9, 21-22, 27, 31; FIGO, 2015, pp. 14, 22; 박창은, 2025, pp. 3-4; 제안서 2.1.3절; 계산.

3. 분석 방법

3.1 전처리와 파형 인자 28개

분석의 기본 단위는 한 태아의 5분 구간이며, 태아 심박수(FHR)와 자궁수축 신호(TOCO)를 각각 2초 간격의 150개 값으로 나타냈다. FHR은 bpm, TOCO는 원자료 척도를 유지했다. 신호 길이·측정 간격·유한성 및 기록과 판독의 대응을 확인하고, FHR의 0이 구간의 30%를 초과하면 해당 구간을 제외했다. 이후 예측 표적은 전문가의 구간 정상·이상 판독이며, 분만 결과와 구분했다.

구간 i의 두 채널을 F_i, T_i, 전처리를 P_u, 특징 추출 규칙을 Φ로 표기했다. u=30은 30초 평활, u=0은 평활 생략 조건이다. I_l은 길이가 l개 이하인 연속 0 구간을 보간하는 연산이다. 양옆 값이 있으면 선형 보간하고, 한쪽 값만 있으면 그 값을 연장하며, 채널 전체가 0이면 그대로 둔다. 두 조건 모두 먼저 7표본 이하의 0 구간을 채웠다. 평활 조건의 S_{15}는 중심 위치를 포함한 앞뒤 7표본의 이동평균이며, 0은 평균에서 제외하고 중심이 0인 위치는 0으로 유지했다. 마지막으로 남은 0을 길이 제한 없이 보간했다. 합성 기호 ∘는 오른쪽 연산부터 적용한다는 뜻이다.

$$x_i = (F_i, T_i) \in \mathbb{R}^{2\times 150}, \qquad f_s = 0.5\ \text{Hz},$$
$$P_0 = I_{150} \circ I_7, \qquad P_{30} = I_{150} \circ S_{15} \circ I_7,$$
$$z_i^{(u)} = \Phi(P_u(F_i), P_u(T_i)) \in \mathbb{R}^{28}.$$

기본 분석에는 30초 평활 특징을 사용했다. 평활·비평활 양쪽에서 28개 값이 모두 유한하게 계산된 구간만 공통 분석집합에 남기고, 특징 모델과 CNN에 같은 구간 및 산모 분할을 적용했다. 따라서 평활 효과를 비교할 때 평가 대상이 바뀌지 않는다. 다만 CNN 입력은 원본 FHR의 0만 보간하고 TOCO는 그대로 유지하므로, 특징 모델과 CNN의 입력 전처리는 동일하지 않다.

28개 인자는 다음 여섯 군으로 구성했다. 이 구분은 특징군 제거 분석에도 동일하게 사용했다. 인자 이름은 구현에서 계산하는 양을 가리키며, 임상 측정값과의 동등성을 뜻하지 않는다. 전체 변수의 정의·단위·의존 관계와 해석 제한은 부록 A에 제시했다.

표6. 28개 파형 인자의 구성

특징군	개수	포함 내용
신호 수준·산포(signal)	4	FHR 평균·최솟값·최댓값·표준편차
기저선·분포(baseline)	4	추정 기저선·범위·중앙값·히스토그램 최빈 상자의 중점
변이(variability)	2	2초 간격 FHR 절대차 평균(stv)·기저선 마스크 내 극값 차이 평균
낮거나 높은 심박수(range)	2	FHR 110 bpm 미만·160 bpm 초과의 표본 비율
가속·감속(events)	9	감속 수·최대 깊이·시간 비율, 가속 수, 감속 유형별 5개 건수
수축·신호 연동 (contractions_coupling)	7	TOCO 평균·최댓값·표준편차, 수축 수, 동시점 상관·최소 지연 상관·해당 시차

28은 입력 열의 수이며, 상수 열이나 다른 인자의 정확한 파생값도 포함한다.

측정 규칙의 핵심은 구간 내부에서 추정한 기저선이다. 아래 식에서 F는 전처리한 FHR, $B^{(k)}$는 k번째 기저선 추정값, J_k는 양수이면서 현재 기저선과의 차이가 15 bpm 미만인 표본의 집합이다. 초기값은 양수 FHR의 평균으로 두고 J_k의 평균으로 갱신했다. J_k가 비면 현재값을 유지하며, 갱신 차이가 0.5 bpm 미만이거나 50회에 도달하면 종료했다. 최종 기저선을 B라 하고, $\mathcal{J}(\cdot)$는 주어진 조건을 만족하는 최대 연속 구간들의 집합, $\mathcal{D}$는 그중 FHR이 B보다 15 bpm 이상 낮은 상태가 8표본 이상 이어진 감속 집합이다. [a,b)는 a부터 b−1까지를 포함하며, 사건 길이는 표본 수에 2초를 곱해 계산했다.

$$J_k = \{t : F_t > 0,\ |F_t - B^{(k)}| < 15\}, \qquad B^{(k+1)} = \frac{1}{|J_k|}\sum_{t\in J_k} F_t \quad (|J_k| > 0),$$

$$\mathrm{stv} = \frac{1}{149}\sum_{t=0}^{148} |F_{t+1} - F_t|,$$

$$\mathcal{D} = \{[a,b) \in \mathcal{J}(0 < F \le B - 15) : b - a \ge 8\},$$

$$\mathrm{decel_time_frac} = \frac{\sum_{[a,b)\in\mathcal{D}} (b-a)}{150}, \qquad d([a,b)) = 2(b-a)\ \mathrm{s}.$$

따라서 stv는 2초 간격 파형의 변화량이며 박동 간격 기반 STV와 구분했다. 감속의 최소 길이는 구현상 8표본, 즉 16초이다. 기저선 변이도는 최종 갱신에 사용한 마스크의 각 연속 부분 안에서 인접 극값 간 높이 차이를 평균하며, 극값 쌍이 없으면 0으로 두었다. 가속·감속의 검출, 깊이·시간 비율 및 유형은 이 기저선과 사건 경계에 의존한다. 후기 감속은 가장 가까운 수축 시작과의 시간 관계로 먼저 분류하고, 나머지는 지속시간에 따라 나누므로 임상 유형명을 그대로 충족한다고 전제하지 않았다. 특히 n_severe_decel은 300초 초과를 요구하여 5분 구간에서는 구조적으로 0이다.

측정값과 전문가 판독의 대응은 기록 단위에서 점검했다. 비교 대상은 기저선·기저선 변이도·가속·조기 감속·후기 감속·변이 감속·지속성 감속의 일곱 파생값이다. 구간별 기저선·변이도는 기록 안에서 평균하고 사건 수는 합한 뒤, 해당 전문가 지표와 모두 존재하는 기록만 비교했다. Spearman 순위 상관을 계산하고 기저선에는 평균 절대차(bpm)를 추가했다. 사건 건수의 AUROC에서는 가속 판독값이 1, 감속 판독값이 양수인 경우를 사건 존재로 정의했다. 이는 모든 분할을 합친 측정 대응 점검으로, 모델 선택에 사용하지 않았으며 28개 전체의 임상 타당성을 검증하는 절차는 아니다.

공통 전처리에도 해석 제한이 있다. TOCO의 0까지 보간하므로 실제 영점과 결측을 별도로 식별하지 않으며, 중심형 이동평균은 구간 안의 뒤쪽 표본을 사용한다. 또한 5분 경계를 넘어 사건을 연결하지 않는다. 본 연구의 후속 성능은 이러한 고정된 추출 규칙을 포함한 예측 절차의 성능으로 해석했다. 계산값의 분포와 기록별 주석 비교 결과는 부록 B에 제시하였다.

3.2 모델과 비교군

주 모델은 28개 평활 특징을 사용하는 CatBoost(Cat28)로 정했다. 비교군은 단일 인자로 충분한지, 여러 인자의 가산 결합으로 충분한지, 입력 확장과 모델 구조가 성능에 어떤 차이를 만드는지를 구분하도록 구성했다. 모든 기본 비교는 동일한 시험 구간의 전문가 판독을 대상으로 했다. 처리 과정은 그림6과 같다.

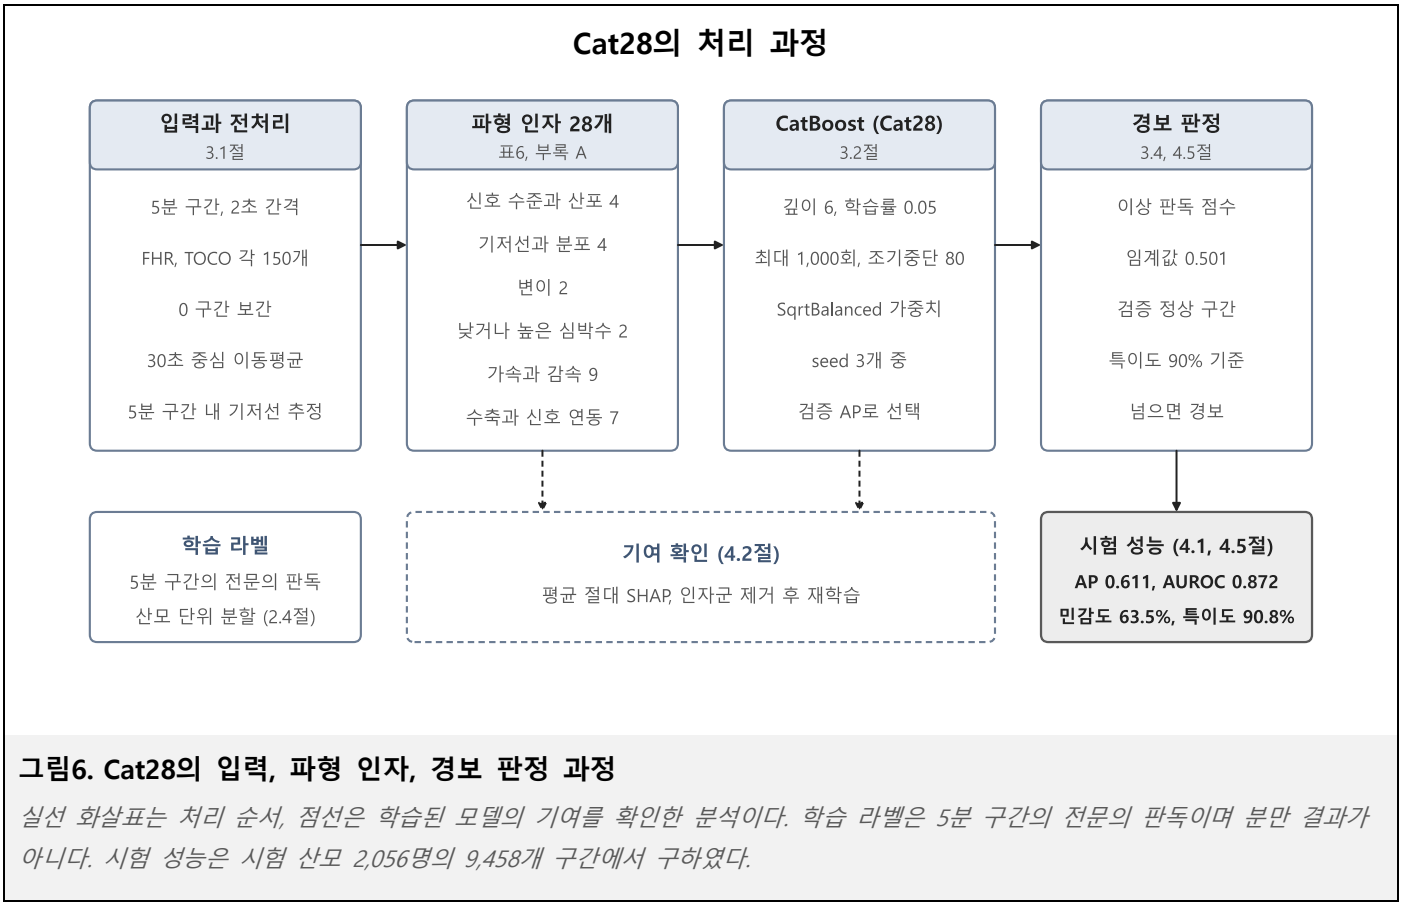


그림6. Cat28의 입력, 파형 인자, 경보 판정 과정

실선 화살표는 처리 순서, 점선은 학습된 모델의 기여를 확인한 분석이다. 학습 라벨은 5분 구간의 전문의 판독이며 분만 결과가 아니다. 시험 성능은 시험 산모 2,056명의 9,458개 구간에서 구하였다.

표7. 모델과 비교 목적

모델·조건	입력	비교 목적 및 선택 규칙
단일 선형·단일 spline	각각 인자 1개	계열별 28개 후보를 학습하고 검증 AUROC로 인자 하나 선택
선형 가산·spline 가산	28개 평활 특징	여러 인자의 선형·비선형 가산 결합 평가; 각 계열 한 번 적합
Cat28	28개 평활 특징	사전 지정 주 모델; 학습 seed 42·43·44 중 검증 AP로 선택
Cat18	특징 목록 앞의 18개	기저선·감속 유형·분포 인자를 추가한 입력 확장의 효과 비교
XGB28	28개 평활 특징	다른 부스팅 구현과 비교; seed 42·43·44 중 검증 AP로 선택
특징군 제거·robust·비평활	제거 조건별 특징 또는 비평활 28개	입력 조건을 바꾼 뒤 CatBoost를 새로 학습; 조건별 검증 AP로 seed 선택
파형 CNN	FHR·TOCO 2×150 배열	직접 파형 입력 비교; 정규화·크기별 검증 AP로 폭과 대표 seed 선택
Cat28+임상정보	파형 특징 28개+임상변수 13개	동일 시험 구간에서 임상정보 추가의 증분 평가

로지스틱 계열은 훈련 중앙값으로 결측을 대체하고, 선형 입력 또는 spline 기저를 만든 뒤 훈련 평균·표준편차로 표준화했다. Spline은 훈련 범위에 균등한 매듭 5개를 둔 3차 B-spline이며, 인자당 기저 6개와 절편을 사용하고 범위 밖에서는 경계값을 유지했다. 상수 특징은 spline 변환에서 제외하며, 단일 상수 특징의 모델은 절편만 학습한다. 두 계열 모두 구간에 동일한 가중치를 둔 이진 로그 손실과 L2 벌점(C=1)을 사용했다. 전처리의 추정값과 회귀계수는 훈련 자료에서만 정했다.

아래에서 z는 특징 벡터, $\sigma(v)=1/(1+e^{-v})$는 시그모이드, b는 절편이다. g_k는 인자 k의 선형 또는 spline 기여 함수, h_t는 t번째 회귀 트리, η는 트리 학습률이다. 단일 모델은 기여 함수 하나를 사용하고, 가산 모델은 인자별 기여를 더한다. 가산식에는 인자 간 상호작용 항이 없으며, 트리는 한 경로에서 여러 인자의 조건을 함께 사용할 수 있다.

$$p_{\text{single}}(z) = \sigma(b + g_k(z_k)),$$
$$p_{\text{add}}(z) = \sigma\left(b + \sum_k g_k(z_k)\right),$$
$$p_{\text{tree}}(z) = \sigma\left(b + \eta \sum_{t=1}^{T} h_t(z)\right).$$

CatBoost의 깊이는 6, XGBoost의 깊이는 4이며 학습률은 모두 0.05, 최대 반복 수는 1,000, 조기중단 대기 횟수는 80으로 설정했다. 반복 수 선택에는 CatBoost의 PRAUC와 XGBoost의 aucpr를 사용하고, 세 seed 중 후보 선택에는 공통 평균 정밀도(AP)를 사용했다. 두 종류의 PR 요약값은 계산 방식이 같지 않으므로 구분했다. CatBoost는 SqrtBalanced 클래스 가중치, XGBoost는 훈련 음성 수 n_0와 양성 수 n_1에 따른 양성 가중치 $\sqrt{(n_0/n_1)}$를 적용했다. 로지스틱 계열과 트리의 비교에는 함수 구조와 손실 가중치의 차이가 함께 포함된다. 선택 후 훈련·검증 자료를 합쳐 재학습하지 않았다.

인자 기여는 두 방식으로 살폈다. 첫째, 여섯 특징군을 하나씩 제거하여 재학습했고, 사건군 9개와 수축 수·기저선·기저선 변이도 3개를 뺀 16개 입력의 robust 조건 및 28개 비평활 조건을 추가했다. 총 8개 조건마다 seed 3개를 학습하고 검증 AP로 선택했다. 제거는 입력 열을 제외한 재학습이며 기존 모델의 값을 0으로 바꾸는 처리가 아니다. robust는 사전 정의된 입력 집합의 이름이다. 둘째, 선택된 Cat28의 Tree SHAP을 산출하여 훈련 구간 최대 512개를 seed 42로 비복원 추출한 표본에서 평균 절대 기여를 구했다. SHAP은 로그 오즈 출력의 분해이며 재학습 후 성능 변화나 인과 효과와 구분했다.

CNN에는 FHR의 0만 보간한 두 채널 배열 X_i를 입력하고 두 정규화를 비교했다. 아래에서 c는 채널, t는 시간 위치, I_tr은 훈련 구간 집합, μ_{ic}와 σ_{ic}는 해당 구간·채널의 시간축 평균과 표준편차이다. 공통 최대 절댓값 정규화는 훈련에서 정한 채널별 분모 s_c를 검증·시험에도 적용하여 구간 사이의 절대 수준과 크기 차이를 남겼다. 구간별 정규화는 각 구간의 평균과 크기를 제거하며, 이 통계에는 판독값을 사용하지 않았다.

$$s_c = \max\left(10^{-6}, \max_{i \in I_{\text{tr}}, t} |X_{ict}|\right),$$
$$[N_{\max}(X_i)]_{ct} = X_{ict}/s_c,$$
$$[N_z(X_i)]_{ct} = (X_{ict} - \mu_{ic})/\max(\sigma_{ic}, 10^{-6}).$$

CNN은 커널 길이 15의 시간축 합성곱, depthwise·pointwise 합성곱, 배치 정규화, ELU, 평균 풀링, dropout 0.25 및 최종 선형 출력층으로 구성했다. 폭 w에서 학습 매개변수 수는 $w^2+93w+1$이다. 실제 비교한 설정은 폭 8·32·64, 정규화 2종, seed 42·43·44의 18개 후보였다. 배치 크기는 최대 256, AdamW 초기 학습률은 3×10^{-4}, weight decay는 10^{-4}이며 코사인 학습률 감소를 사용했다. 양성 가중치는

$\sqrt{(n_0/n_1)}$로 두었다. 최대 400 epoch, 최소 40 epoch와 연속 40 epoch 미개선 규칙을 적용하고, 검증 AP가 최고였던 상태로 예측했다.

각 정규화에서 small(폭≤32)과 medium(폭≥64)을 나누고, 폭별 세 seed의 검증 AP 평균으로 폭을 고른 다음 해당 폭에서 검증 AP가 가장 높은 seed 하나를 선택했다. 최종 네 모델은 각각 평가했으며 시험 결과로 하나를 다시 선택하지 않았다. 정규화 효과의 보조 비교는 공통 최대 절댓값 정규화가 선택한 폭을 두 정규화에 함께 적용하여 같은 폭·seed로 비교했다. 추론 비용은 준비된 시험 입력의 정규화와 배치 추론을 세 번 측정한 중앙값을 구간 수로 나누었다. 모델 로딩·원자료 읽기·보간 시간은 제외했으며, Cat28의 특징 추출 비용과 모델 추론 비용도 구분했다.

임상정보 추가 모델에는 산모 연령·재태 연령, 신장·체중, 임신·출산 횟수, 수축기·이완기 혈압, 임신성 고혈압·고혈압·임신성 당뇨·당뇨·전자간증의 13개 변수를 기록 식별자로 연결했다. 파형 28개와 합친 41개 입력을 같은 구간 분할에서 학습했으며, 임상 결측은 NaN으로 유지해 CatBoost가 처리했다. 산모 연령은 원자료의 출생 연도 차이에 1을 더한 값이고 재태 연령은 주+일/7이다. 출생 결과·응급 여부·전문가의 개별 판독 지표는 입력에 포함하지 않았다. 후보 세 개의 검증 AP로 seed를 선택하고 기존 Cat28과 비교했다.

3.3 평가 지표와 신뢰구간

같은 산모의 반복 검사와 다태아 기록이 학습과 평가에 걸쳐 포함되지 않도록 산모를 분할 단위로 삼았다. 남은 이상 구간이 하나라도 있는 산모인지로 층화하여 학습·검증·시험의 목표 비율을 80:10:10으로 정했다. 먼저 seed 42로 시험 10%를 분리하고, 나머지의 1/9을 seed 43으로 검증에 배정했다. 자료에서 추정하는 변환과 모델은 훈련에서 적합하고 후보·조기중단·보정·임계값은 검증에서 정한 뒤 시험에 고정 적용했다. 이 비율은 산모 수 기준이며 구간 수 비율과는 다를 수 있다.

순위 성능은 AP와 AUROC, 확률 오차는 Brier 점수로 평가했다. AP·AUROC는 클수록, Brier는 작을수록 좋다. 아래에서 J는 평가 구간 집합, y_i는 정상 0·이상 1의 전문가 판독, p_i는 예측 점수, w_i는 구간별 평가 가중치이다. W_+와 W_-는 각각 양성·음성 가중치 합이다. AP에서 b는 서로 다른 점수를 높은 순서대로 포함하는 단계이며, R_b와 P_b는 그 단계의 재현율과 정밀도이고 R_0=0이다. 같은 점수의 구간은 한꺼번에 포함했다. $\mathbf{1}[\cdot]$는 조건이 참이면 1인 지시함수이다.

$$W_+ = \sum_{i\in J} w_i\, y_i, \qquad W_- = \sum_{i\in J} w_i\,(1-y_i),$$

$$\mathrm{AUROC} = \frac{\sum_{i:y_i=1}\sum_{j:y_j=0} w_i\, w_j \{\mathbf{1}[p_i > p_j] + 1/2\,\mathbf{1}[p_i = p_j]\}}{W_+ W_-},$$

$$\mathrm{AP} = \sum_b (R_b - R_{b-1}) P_b, \qquad \mathrm{Brier} = \frac{\sum_{i\in J} w_i\,(p_i - y_i)^2}{\sum_{i\in J} w_i}.$$

점추정에서는 모든 구간에 w_i=1을 적용했다. AP는 재현율 증가량으로 정밀도를 가중한 값이며 PR 곡선의 사다리꼴 면적과 구별했다. AP와 경보의 양성예측도는 이상 판독 기저율에도 영향을 받으므로,

기관별 비교에서는 평가 구간의 이상 비율을 함께 제시했다. 분만 결과 분석에서는 같은 지표식을 기록 단위로 적용했다.

95% 신뢰구간은 산모 단위 bootstrap으로 계산했다. 평가집합의 산모 수를 H, 산모 m의 추출 횟수를 W_m, 구간 i의 산모를 m_i라 하자. 매 반복에 H명의 산모를 균등 복원추출하고 한 산모가 가진 모든 구간 또는 기록에 동일한 추출 횟수를 적용했다. 모델 A와 B의 지표 차이에는 같은 산모 추출 횟수를 사용했다. 아래 $\mathcal{M}$은 AP·AUROC·Brier 등 평가 지표, 별표는 재표집 결과를 뜻한다.

$$(W_m)_{m=1}^{H} \sim \text{Multinomial}(H; 1/H, \dots, 1/H), \qquad w_i = W_{m_i},$$
$$\Delta = \mathcal{M}(y, p^A) - \mathcal{M}(y, p^B),$$
$$\Delta^* = \mathcal{M}_w(y, p^A) - \mathcal{M}_w(y, p^B),$$
$$\text{CI}_{95\%} = [Q_{0.025}(\Delta^*), Q_{0.975}(\Delta^*)].$$

재표집 seed는 42, 반복 수는 2,000으로 고정했다. 양성·음성이 모두 남고 지표가 유한한 반복의 2.5%·97.5% 분위수를 사용했다. 한 클래스만 남은 반복은 Brier를 포함한 해당 분석의 모든 지표에서 제외하고, 경보 지표 중 특정 분모만 0이면 그 지표의 반복만 제외했다. 산모는 같은 확률로 추출하지만 지표는 구간 또는 기록 단위로 계산하므로 관측값이 많은 산모가 더 기여한다. 재표집 중 모델·선택 인자·보정 함수·임계값은 고정했다. 따라서 구간은 평가 산모 구성의 변동을 반영하며 재학습·재선택의 변동 전체를 포함하지 않는다. 다중 비교 보정은 적용하지 않았고, 차이 구간에 0이 포함된다는 사실을 동등성의 증거로 해석하지 않았다.

표8. 성능 차이의 부호를 읽는 기준

비교	계산 방향	AP·AUROC에서 양수의 의미
기본 모델·특징군 제거·CNN	Cat28 − 비교 모델	Cat28의 순위 성능이 높음
임상정보 추가	Cat28+임상정보 − Cat28	임상정보 추가 모델의 순위 성능이 높음
확률 보정	보정 후 − 보정 전	보정 후 순위 성능이 높음
CNN 정규화	공통 최대 절댓값 − 구간별 표준화	절대 크기를 보존한 모델의 순위 성능이 높음
분만 결과의 판독 요약 추가	임상정보+실제 판독 요약 − 임상정보	판독 요약을 추가한 모델의 순위 성능이 높음

Brier는 작을수록 좋으므로 동일한 차이 방향에서 음수가 앞쪽 모델에 유리하다. 경보 부담 지표도 값의 의미를 별도로 확인한다.

분할 변화에 대한 보조 평가에는 기존 학습·검증 산모만 합친 개발집합을 사용했다. 산모를 묶은 StratifiedGroupKFold 5-fold를 seed 42·43·44로 반복하고, 각 외부 fold를 제외한 산모를 내부 학습·검증 80:20으로 한 번 나누었다. 내부 분할 seed는 반복 seed+fold 번호였다. Cat28, 단일 spline, spline 가산을 같은 배정에서 새로 학습했으며 단일 spline의 인자도 내부 검증 AUROC로 다시 선택했다. Cat28은 해당 반복 seed 하나로 학습했으며 기본 비교처럼 세 seed를 경쟁시키지 않았다. 각 반복에서 다섯 외부 fold의 OOF 예측을 합쳐 개발집합 전체의 지표를 한 번 계산했다. 세 반복은 각각 보고하고 예측을 평균하거나 최고 반복을 선택하지 않았다.

OOF 지표는 fold별 성능의 평균과 다르며, 반복별 최솟값·최댓값도 95% 신뢰구간과 구분했다. OOF 차이의 bootstrap은 이미 얻은 예측을 고정한 산모 재표집이다. 외부 fold 모델들이 학습 자료 일부를

공유하는 의존성과 분할·재학습 변동을 모두 반영한 신뢰구간은 아니다. 한편 기본 모델·제거·임상정보 추가·CNN의 같은 seed 보조 비교에는 점추정만 보고했다. CNN의 같은 폭·seed 정규화 비교에는 별도로 짝지은 산모 bootstrap을 적용했다.

3.4 경보 기준, 기관 간 일반화, 분만 결과 분석 설계

경보 기준과 확률 보정

경보 기준은 검증 정상 구간에서 경험적 특이도가 적어도 90%가 되도록 정했다. 검증 음성 구간 수를 n_-, 그 점수를 오름차순으로 정렬한 값을 $v_{-(1)}, \ldots, v_{-(n_-)}$라 하자. 경보는 점수가 임계값 τ 이상일 때 발생한다. 경계 점수와 같은 값을 비경보에 포함하기 위해, 올림한 $0.9n_-$번째 값보다 큰 방향의 다음 표현 가능한 수(nextafter)를 임계값으로 사용했다. 이 기준은 시험 또는 새 기관의 특이도 90%를 보장하는 규칙이 아니다.

$$k = \lceil 0.9 n_- \rceil, \qquad \tau = \mathrm{nextafter}(v_{(k)}, +\infty), \qquad d_i = \mathbf{1}[p_i \geq \tau].$$

확률 보정은 선택된 Cat28을 유지한 채 검증 점수와 판독으로 별도의 로지스틱 함수를 적합했다. $\tilde{p}$는 p를 $[10^{-6}, 1-10^{-6}]$으로 제한한 점수, α와 β는 검증에서 추정한 기울기와 절편, q는 보정 점수이다. 보정에는 L2 로지스틱 회귀(C=1)를 사용하고 별도 표준화나 클래스 가중치는 적용하지 않았다. q에도 검증 특이도 90% 규칙을 적용해 임계값을 다시 정한 뒤 시험에 고정했다. 보정 효과는 같은 시험 산모에서 보정 후−보정 전의 짝지은 차이로 평가했다.

$$\tilde{p} = \min(1 - 10^{-6}, \max(10^{-6}, p)), \qquad q = \sigma\left(\hat{\alpha} \log \frac{\tilde{p}}{1-\tilde{p}} + \hat{\beta}\right).$$

경보 성능은 구간 민감도·특이도·양성예측도(PPV)와 함께 정상 기록 경보율, 정상 시간당 경보 구간 수로 평가했다. 정상 기록은 결측 제외 전 원래 판독이 모두 정상이었던 기록이다. 아래에서 R_J는 평가 구간이 하나 이상 남은 기록 집합, n_r는 정상 기록 표시, d_r는 남은 구간에서 경보가 한 번이라도 발생한 표시이다. r_i는 구간 i의 기록이며, 모든 합은 해당 평가집합에서 계산한다.

$$d_r = \max_{i \in J : r_i = r} d_i,$$

$$\mathrm{NormalRecordAlarm} = \frac{\sum_{r \in R_J} n_r \, d_r}{\sum_{r \in R_J} n_r},$$

$$\mathrm{AlarmsPerNormalHour} = \frac{\sum_{i \in J} n_{r_i} \, d_i}{(1/12) \sum_{i \in J} n_{r_i}}.$$

시간 분모는 정상 기록에 남은 5분 구간 수를 12로 나눈 값이다. 이상 기록 안의 정상 구간은 이 기록·시간 지표에 포함하지 않았고, 연속된 경보 구간도 각각 세었다. 따라서 시간당 값은 연속 경보를 합친 사건 수가 아니다. AP·AUROC·Brier를 포함한 여덟 지표에 산모 bootstrap을 적용했다. 보정도는 시험 점수를 폭 0.1의 열 구간으로 나누어 평균 점수와 실제 이상 비율을 표시하되, 보정 후에는 보정 점수로 다시 묶었다. 오류 사례는 TP·TN·FP·FN에서 최대 두 구간씩 점수의 극단에서 선택한 예시로, 대표 빈도 추정에 사용하지 않았다.

기관을 제외한 일반화 평가

기관별 평가에서는 전체 공통 분석집합에서 기관 하나를 제외하고 분할을 새로 구성했다. 평가 기관에 등장한 산모는 다른 기관의 구간까지 모두 학습·검증에서 제외했다. 나머지 source 산모를 이상 구간 보유 여부로 층화하여 seed 42의 학습·검증 80:20으로 나누고, Cat28 후보 세 개를 학습하여 검증 AP로 선택했다. 모델, 두 경보 임계값 및 확률 보정 함수는 source에서만 정하고 평가 기관에 고정 적용했다. 다음 기관을 평가할 때는 이 절차를 새로 수행했다.

평가 기관별로 구간 이상 비율, 산모·구간 수와 보정 전후의 여덟 지표를 제시하고, 해당 기관 산모를 2,000회 재표집한 신뢰구간을 구했다. 보정 전후 각각의 구간은 산출했지만 두 값의 차이에 대한 신뢰구간은 별도로 산출하지 않았다. 기관 코드는 원자료 메타데이터에서 추출한 집단 구분이며 실제 병원과의 일대일 대응이 확인된 변수는 아니다. 따라서 이 분석은 같은 자료체계 안의 기관 제외 평가로 해석했다.

실제 판독 요약과 분만 결과

분만 결과 분석은 구간 판독 예측과 구분하여 기록 단위로 수행했다. 원래 기록자료에서 결과별 관측집합을 만들고, UA.pH는 6~8, 출생 1분·5분 Apgar는 0~10의 유한한 값을 사용했다. 양성 기준은 UA.pH<7.2, APGAR1<7, APGAR5<7로 고정했다. 결측·범위 밖 값은 해당 결과 분석에서만 제외하고 음성으로 대체하지 않았다. 결과가 관측된 기록과 제외된 기록의 규모 및 이상 판독 보유 비율도 함께 비교했다.

기록 r의 전체 구간 수를 N_r, 원래 구간 판독을 y_{rj}, 임상변수 13개를 c_r라 하자. 실제 판독 요약 h_r는 이상 구간 비율 a_r와 최장 연속 이상 구간 수 ℓ_r의 두 값이다. 연속성은 구간 이미지 파일명의 접두사가 같고 번호가 1씩 증가하는지로 판단하며, ℓ_r를 실제 경과 시간으로 환산하지 않았다. 판독 요약은 구간 제외 전 레이블 전체에서 계산하고 Cat28의 예측값으로 대체하지 않았다. 아래 두 입력 조건을 같은 기록의 분만 결과 표적 Y_r에 대해 비교했다.

$$a_r = \frac{1}{N_r}\sum_{j=0}^{N_r-1} y_{rj}\,, \qquad h_r = (a_r, \ell_r),$$

$$u_r^{(0)} = c_r \in (\mathbb{R}\cup\{\mathrm{NA}\})^{13}, \qquad u_r^{(1)} = (c_r, h_r) \in (\mathbb{R}\cup\{\mathrm{NA}\})^{15},$$

$$Y_r^{(\mathrm{pH})} = \mathbf{1}[\mathrm{UA.pH}_r < 7.2], \qquad Y_r^{(\mathrm{Apgar})} = \mathbf{1}[\mathrm{Apgar}_r < 7].$$

먼저 a_r 자체를 순위 점수로 사용한 AP·AUROC와 판독 유무×분만 결과의 교차표를 구했다. 이어 결과별로 산모를 묶은 5-fold OOF 예측을 만들었다. 외부 fold는 seed 42의 StratifiedGroupKFold, 내부 학습·검증은 산모별 양성 기록 보유 여부로 층화한 80:20 분할(seed 42+fold 번호)이었다. 두 입력 모델은 같은 내부 배정에서 학습 seed 42로 적합하고, 내부 검증으로 반복 수만 정했다. 외부 fold의 산모는 학습과 내부 검증에서 모두 제외했으며 선택 후 재학습하지 않았다.

다섯 fold의 OOF 예측을 합쳐 관측 기록 전체에서 AP·AUROC·Brier와 판독 요약 추가–임상정보만의 차이를 계산했다. 기록별 가중치는 점추정에서 1, 산모 bootstrap에서는 해당 산모의 추출 횟수로 두었

다. 이 분석은 파형 인자 계산에 성공한 구간이나 기존 시험 기록으로 제한하지 않고 결과가 관측된 원래 기록을 사용하므로, 고정 시험 비교와 별개의 모집단·표적을 갖는다. 같은 자료체계 안의 OOF 분석이며 독립된 새 자료의 확증 결과로 해석하지 않았다.

4. 결과

4.1 판독 재현 성능 (H1, H2)

판독 재현 성능은 2.4절에서 고정한 시험 산모 2,056명의 9,458개 구간에서 평가하였다. 시험 구간의 이상 비율은 16.2%였다. 단일 인자 28개에 선형·spline 모델을 각각 적용한 56개 후보 중 검증 AUROC로 선택된 인자는 선형에서 감속 시간 비율(decel_time_frac), spline에서 stv였다. 조합 모델은 각 계열의 검증 AP로 선택을 고정한 뒤 같은 시험 구간에서 비교하였다.

표9. 선택된 단일 인자 모델과 조합 모델의 시험 성능

모델	AP (95% CI)	AUROC (95% CI)	Brier (95% CI)
단일 선형	0.329 (0.297~0.363)	0.639 (0.622~0.657)	0.120 (0.112~0.128)
단일 spline	0.450 (0.413~0.490)	0.744 (0.725~0.764)	0.112 (0.105~0.120)
선형 28	0.514 (0.477~0.554)	0.819 (0.803~0.834)	0.107 (0.100~0.114)
spline 가산 28	0.595 (0.555~0.637)	0.869 (0.855~0.882)	0.093 (0.087~0.099)
Cat18	0.605 (0.565~0.646)	0.870 (0.856~0.883)	0.100 (0.095~0.106)
Cat28	0.611 (0.570~0.653)	0.872 (0.858~0.886)	0.099 (0.094~0.105)
XGBoost 28	0.611 (0.571~0.652)	0.870 (0.855~0.883)	0.100 (0.095~0.105)

시험 산모 2,056명, 구간 9,458개. CI는 산모 군집 부트스트랩 2,000회의 백분위 구간이다. AP·AUROC는 클수록, Brier는 작을수록 좋다. 단일 선형은 decel_time_frac, 단일 spline은 stv를 사용한다. 선택 seed는 Cat28=44, Cat18=43, XGBoost 28=42이며, 선형 28·spline 가산 28은 seed 42로 한 번 적합하였다.

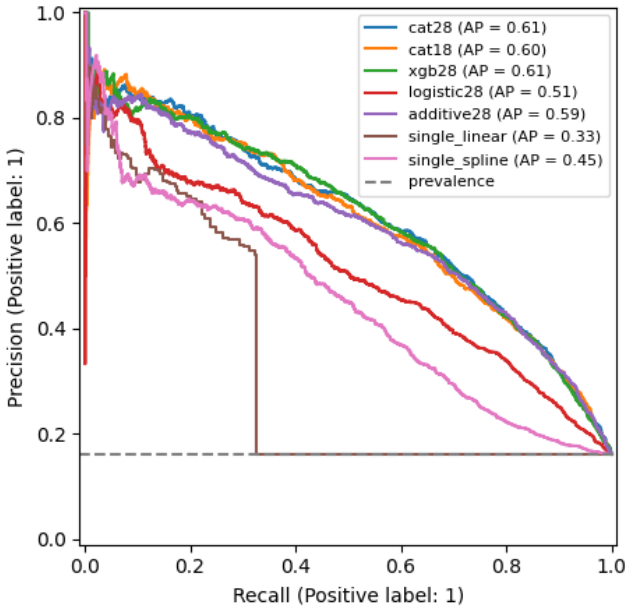


그림7. 선택된 모델들의 시험 precision–recall 곡선

같은 시험 산모 2,056명의 9,458개 구간을 평가한 원본 그림이다. 회색 점선은 시험 구간의 이상 비율이다. 곡선은 구간 판독 재현 성능을 나타내며 분만 결과 예측 곡선이 아니다.

Cat28의 시험 AP는 0.611 (95% CI 0.570~0.653), AUROC는 0.872 (0.858~0.886)였다. 단일 spline의 AP 0.450, AUROC 0.744보다 높았으며, 같은 시험 산모를 짝지어 비교한 차이도 각각 0.160 (0.127~0.196),

0.128 (0.110~0.146)로 양수였다. 여러 인자의 조합은 이 자료의 판독 재현에 추가 정보를 제공하였다. 다만 단일 선형과 단일 spline은 선택된 인자까지 다르므로 두 모델 간 차이 전체를 함수 형태의 효과로 분리하지 않았다.

표10. Cat28과 비교 모델의 짝지은 시험 성능 차이

비교 모델	ΔAP (95% CI)	ΔAUROC (95% CI)	ΔBrier (95% CI)
단일 선형	+0.282 (+0.245~+0.318)	+0.233 (+0.216~+0.252)	−0.021 (−0.028~−0.014)
단일 spline	+0.160 (+0.127~+0.196)	+0.128 (+0.110~+0.146)	−0.013 (−0.019~−0.007)
선형 28	+0.097 (+0.068~+0.123)	+0.054 (+0.043~+0.064)	−0.007 (−0.013~−0.002)
spline 가산 28	+0.016 (+0.004~+0.029)	+0.003 (−0.0004~+0.007)	+0.006 (+0.003~+0.009)
Cat18	+0.006 (−0.002~+0.015)	+0.002 (−0.0006~+0.005)	−0.001 (−0.002~−0.0001)
XGBoost 28	−0.0006 (−0.007~+0.007)	+0.003 (+0.0006~+0.005)	−0.0008 (−0.002~−0.00009)

모든 차이는 Cat28−비교 모델이다. AP·AUROC의 양수, Brier의 음수가 Cat28에 유리하다. 시험 산모 2,056명·9,458개 구간에서 산모를 함께 재표집한 2,000회 CI이다. 0 부근의 부호를 보존하기 위해 차이는 소수점 4자리, 아주 작은 경계값은 6자리까지 표시하였다.

같은 28개 인자를 쓰는 선형 모델에서 spline 가산 모델로 바꾸면 AP는 0.514에서 0.595, AUROC는 0.819에서 0.869로 높아졌다. Cat28과 가산 모델의 차이는 AP 0.016 (0.004~0.029)이었으나 AUROC 차이 0.003의 CI는 −0.0004~0.007으로 0을 포함하였다. Brier는 가산 모델이 0.093으로 Cat28의 0.099보다 낮았다. 비선형 관계를 허용한 모델의 이득과, 확률값의 오차가 작다는 성질은 구별해야 한다. 이 비교만으로 상호작용의 순수한 효과를 분리할 수는 없다.

Cat28−Cat18의 AP 차이와 Cat28−XGBoost 28의 AP 차이도 각각 0.006 (−0.002~0.015), −0.0006 (−0.007~0.007)로 CI가 0을 포함하였다. 따라서 Cat28을 모든 조합 모델보다 우수한 모델로 해석하지 않았다. 이들은 인자 추가와 학습 알고리즘 변경의 영향을 각각 확인하는 비교군이다.

개발 집합에서의 반복성

시험 산모를 제외한 개발 집합 18,495명·84,690개 구간에서 산모 단위 5-fold 교차검증을 세 seed로 반복하였다. 각 외부 fold의 학습·내부 검증 자료로 모델과 단일 인자를 선택한 뒤, 그 과정에 포함되지 않은 산모의 OOF 예측을 모았다. 세 반복에서 Cat28의 AP는 0.590~0.594, 가산 모델은 0.574~0.577, 단일 spline은 0.442~0.447이었다.

표11. 개발 집합의 반복 교차검증 AP와 짝지은 차이

반복 seed	Cat28 AP	단일 spline AP	가산 AP	Cat28−단일 ΔAP (95% CI)	Cat28−가산 ΔAP (95% CI)
42	0.594	0.442	0.574	+0.152 (+0.141~+0.161)	+0.020 (+0.014~+0.025)
43	0.590	0.447	0.577	+0.143 (+0.133~+0.153)	+0.013 (+0.008~+0.018)
44	0.592	0.443	0.577	+0.149 (+0.139~+0.159)	+0.016 (+0.011~+0.020)

개발 산모 18,495명·84,690개 구간의 OOF 결과이며 봉인된 시험 결과와 분모가 다르다. 절대 AP는 점추정만 산출하였다. 차이의 CI는 각 반복의 고정 OOF 예측을 산모 단위로 2,000회 재표집한 값으로, 반복 간 변동이나 전체 재학습의 불확실성을 나타내지 않는다.

개발 집합에서도 Cat28과 두 비교군의 AP 차이 방향은 세 반복에서 같았다. 내부 검증에서 단일 spline에 선택된 인자는 15개 fold 중 stv가 14회, hist_width가 1회였다. 이는 한 번의 산모 배정에만 의존하지 않는지 확인한 보조 결과이며, 시험 집합의 성능을 대체하거나 외부 검증으로 해석하지 않았다.

4.2 인자 기여 구조 (H3)

인자 기여는 두 방법으로 확인하였다. 첫째, 인자군을 제거한 뒤 모델을 다시 학습하여 시험 성능 변화를 비교하였다. 둘째, 선택된 Cat28의 출력에 대한 기여를 훈련 표본의 평균 절대 SHAP로 요약하였다. 제거 후 재학습의 효과와 이미 학습된 모델의 출력 기여는 서로 다른 양이다.

표12. 인자군 제거와 평활 조건 변경에 따른 시험 성능 차이

비교 조건	유지 인자 수	ΔAP (95% CI)	ΔAUROC (95% CI)
FHR 수준·분산 제거	24	+0.009 (+0.003~+0.015)	+0.009 (+0.006~+0.012)
기저선·분포 제거	24	+0.003 (−0.003~+0.009)	−0.0005 (−0.003~+0.002)
변이 관련 2개 제거	26	+0.048 (+0.034~+0.062)	+0.028 (+0.021~+0.035)
서맥·빈맥 비율 제거	26	+0.008 (+0.003~+0.013)	−0.0002 (−0.002~+0.001)
가속·감속 9개 제거	19	+0.006 (−0.00009~+0.011)	+0.0003 (−0.001~+0.002)
수축·결합 7개 제거	21	−0.002 (−0.008~+0.005)	−0.002 (−0.004~+0.0004)
16개 인자 유지 (robust)	16	+0.009 (+0.002~+0.016)	+0.003 (+0.0003~+0.005)
비평활 28개 (unsmoothed)	28	−0.021 (−0.036~−0.007)	−0.018 (−0.025~−0.011)

차이는 평활 Cat28−비교 조건이다. 양수이면 비교 조건의 성능이 더 낮다. 모든 행은 같은 시험 산모 2,056명·9,458개 구간과 2,000회 짝지은 산모 부트스트랩을 사용한다. 각 조건은 검증 AP로 seed를 따로 선택하였다. robust는 기저선·기저선 변이도, 가속·감속 관련 9개, 수축 수를 제외한 16개를 유지한다. 비평활도 0값 보간을 시행하며, 30초 이동평균만 생략하였다. 제거군의 전체 열 목록은 3.2절과 부록 A를 따른다.

변이 관련 두 인자(stv, figo_baseline_var)를 제거하면 AP가 0.048 (95% CI 0.034~0.062), AUROC가 0.028 (0.021~0.035) 낮아져 6개 제거군 중 감소 폭이 가장 컸다. FHR 수준·분산군 제거에서도 AP와 AUROC가 모두 낮아졌다. 반면 가속·감속군과 수축·결합군 제거의 AP 차이 CI는 0을 포함하였다. 서맥·빈맥 비율 제거는 AP 차이가 양수였으나 AUROC 차이 CI는 0을 포함하여 지표에 따라 양상이 달랐다.

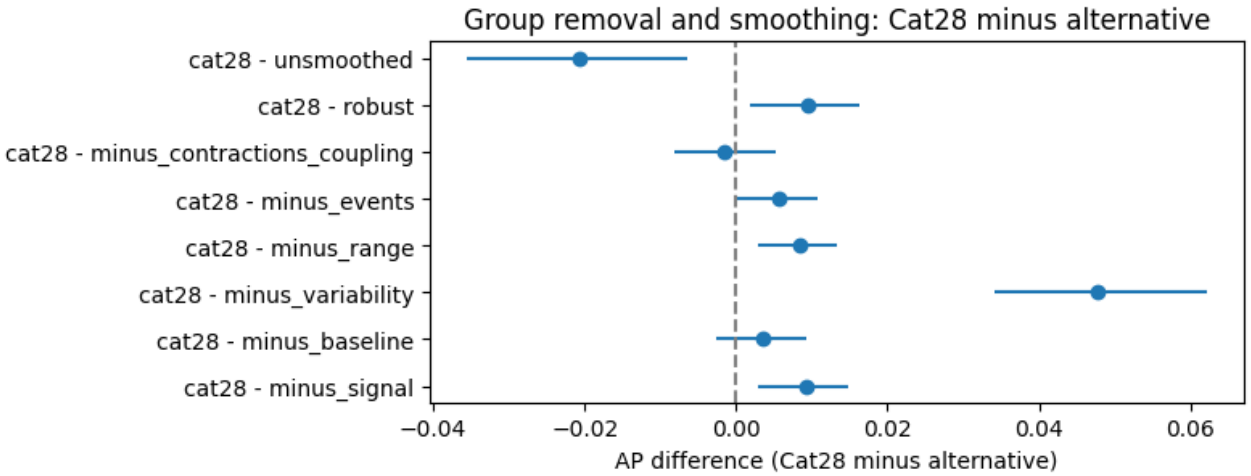


그림8. 인자군 제거와 평활 조건 변경의 시험 AP 차이

점과 선은 평활 Cat28–비교 조건의 AP 차이와 짝지은 산모 부트스트랩 95% CI다. minus_는 해당 인자군을 제거하고 재학습한 조건, robust는 16개 인자를 유지한 조건, unsmoothed는 비평활 조건이다. 가로축의 양수는 비교 조건의 AP가 낮음을 뜻한다.

측정 규칙 의존성이 큰 인자를 제외한 16개 조건(robust)의 AP는 Cat28보다 0.009 (0.002~0.016) 낮았다. 이는 남은 통계값만으로도 상당한 판독 정보를 유지함을 보여 주지만, 제거된 임상 현상이 중요하지 않다는 뜻은 아니다. 상관된 인자가 정보를 대신 담을 수 있고, 부록 B에서 보듯 일부 계산값은 이름에 대응하는 임상 소견을 충분히 구별하지 못한다. 군 제거 결과는 여러 비교를 수행한 탐색적 분석으로 읽었다.

평활화를 생략한 조건은 반대로 더 높은 성능을 보였다. 평활–비평활의 차이는 AP −0.021 (−0.036~−0.007), AUROC −0.018 (−0.025~−0.011)였다. 같은 seed끼리 비교한 AP 차이도 42·43·44에서 각각 −0.023, −0.022, −0.021로 모두 비평활 조건에 유리하였다. 변이 관련 인자군 제거의 AP 차이 역시 같은 seed에서 0.041, 0.046, 0.048로 방향이 유지되었다. 이 보조 비교에는 CI를 산출하지 않았다.

평활화가 작은 파형 변화를 줄이는 처리라는 점은 코드 정의에서 확인할 수 있지만, 어떤 정보의 변화가 성능 차이를 일으켰는지는 이 결과만으로 분리할 수 없다. 이후 경보와 기관 간 일반화 분석은 원래 기준인 평활 Cat28을 유지하였다. 시험 결과에 맞추어 주 모델을 비평활 조건으로 교체하지 않았다.

선택된 모델의 출력 기여

선택된 Cat28(seed 44)에 대해 훈련 구간 512개를 표집하여 평균 절대 SHAP를 구하였다. logit 척도에서 stv 0.764, fhr_min 0.634, hist_mode 0.459가 가장 높았고, hist_median 0.232, fhr_max 0.179, hist_width 0.143이 뒤를 이었다. 기저선 변이도는 0.109였다. 반면 규칙 기반 감속 유형들의 값은 0.003~0.009이었고, 상수였던 n_severe_decel과 n_prolonged_decel은 모두 0이었다.

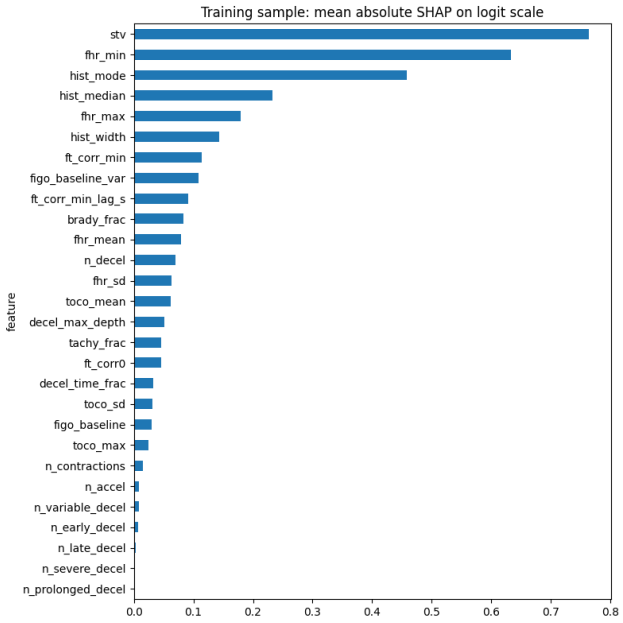


그림9. 훈련 표본에서의 Cat28 인자별 평균 절대 SHAP

선택된 Cat28(seed 44)의 훈련 구간 512개 표본에서 구한 logit 척도의 평균 절대 기여도이다. 양·음의 방향이나 확률 변화량을 표시한 값이 아니며, 생리적 원인 또는 전문의의 실제 판단 근거를 뜻하지 않는다. 그림의 모든 행은 계산 인자 이름을 가리킨다.

이 결과는 변이 관련 계산값과 심박수 수준·분포가 현재 모델의 판독 재현에 크게 관여함을 보여 준다. 그러나 SHAP 순위와 제거 효과를 임상 소견의 중요도 순위로 옮길 수는 없다. 특히 낮은 제거 효과는 인자 간 대체 가능성과 측정 규칙의 제약을 함께 고려해야 하며, 전문의 판독 과정이나 태아 상태의 생리적 기전을 입증한 결과가 아니다.

4.3 인자 모델과 CNN 비교 (H4)

파형을 직접 입력하는 CNN과도 같은 시험 산모 2,056명·9,458개 구간에서 비교하였다. 두 정규화, 폭 8·32·64, seed 42·43·44의 조합 18개가 모두 학습을 완료하였다. 작은 모델군에서는 두 정규화 모두 폭 32가 선택되었고 중간 모델군은 폭 64였다. 모든 학습에서 40 epoch 연속 검증 AP 미개선 조건을 충족했으며, 그중 구간별 z 정규화·폭 64·seed 44는 400 epoch 상한에도 동시에 도달하였다. 상한에 도달했으나 미개선 조건을 충족하지 못한 학습은 없었다.

표13. 검증에서 선택된 네 CNN의 시험 성능

정규화	폭	seed	AP (95% CI)	AUROC (95% CI)	Brier (95% CI)
maxabs	32	43	0.625 (0.584~0.669)	0.888 (0.875~0.900)	0.100 (0.095~0.106)
maxabs	64	44	0.622 (0.582~0.664)	0.886 (0.874~0.898)	0.106 (0.100~0.111)
구간별 z	32	44	0.467 (0.432~0.506)	0.808 (0.791~0.825)	0.121 (0.115~0.127)
구간별 z	64	42	0.465 (0.430~0.503)	0.806 (0.789~0.823)	0.124 (0.118~0.130)

시험 산모 2,056명·9,458개 구간, 산모 부트스트랩 2,000회 CI. maxabs는 훈련 자료의 채널별 최대 절댓값으로 나눈 정규화, 구간별 z는 구간·채널마다 평균과 표준편차로 변환한 정규화다. 폭 32와 64의 매개변수 수는 각각 4,001개와 10,049개이다. 비교 기준인 평활 Cat28의 AP는 0.611, AUROC 0.872, Brier 0.099이다.

채널별 최대 절댓값 정규화(maxabs)를 사용한 CNN의 시험 AP는 폭 32에서 0.625, 폭 64에서 0.622였으며, AUROC는 각각 0.888, 0.886이었다. 구간별 z 정규화의 AP는 0.467, 0.465, AUROC는 0.808, 0.806이었다. 같은 CNN 계열 안에서도 입력 정규화에 따른 차이가 크게 나타났다.

표14. 평활 Cat28과 선택 CNN의 짝지은 시험 성능 차이

비교 CNN	ΔAP (95% CI)	ΔAUROC (95% CI)	ΔBrier (95% CI)
maxabs·폭 32	−0.014 (−0.033~+0.004)	−0.016 (−0.023~−0.008)	−0.001 (−0.004~+0.002)
maxabs·폭 64	−0.011 (−0.031~+0.007)	−0.014 (−0.021~−0.006)	−0.006 (−0.009~−0.004)
구간별 z·폭 32	+0.144 (+0.104~+0.182)	+0.064 (+0.048~+0.080)	−0.021 (−0.026~−0.016)
구간별 z·폭 64	+0.146 (+0.108~+0.183)	+0.066 (+0.050~+0.082)	−0.024 (−0.029~−0.020)

차이는 Cat28−CNN이다. AP·AUROC의 양수, Brier의 음수가 Cat28에 유리하다. 2,056명·9,458개 구간에서 같은 산모를 함께 재표집한 2,000회 CI이며, 각 조건의 검증에서 선택된 대표 seed를 비교하였다.

Cat28−maxabs CNN의 AP 차이는 폭 32에서 −0.014 (95% CI −0.033~0.004), 폭 64에서 −0.011 (−0.031~0.007)으로 두 CI 모두 0을 포함하였다. AUROC 차이는 각각 −0.016 (−0.023~−0.008), −0.014 (−0.021~−0.006)으로 CNN에 유리하였다. Brier는 폭 64의 maxabs CNN보다 Cat28이 낮았으나 폭 32 비교에서는 차이 CI가 0을 포함하였다. 따라서 한 지표로 모델 전체의 우열을 요약하거나, AP 차이가 명확하지 않다는 이유로 동등성 또는 비열등성을 선언하지 않았다.

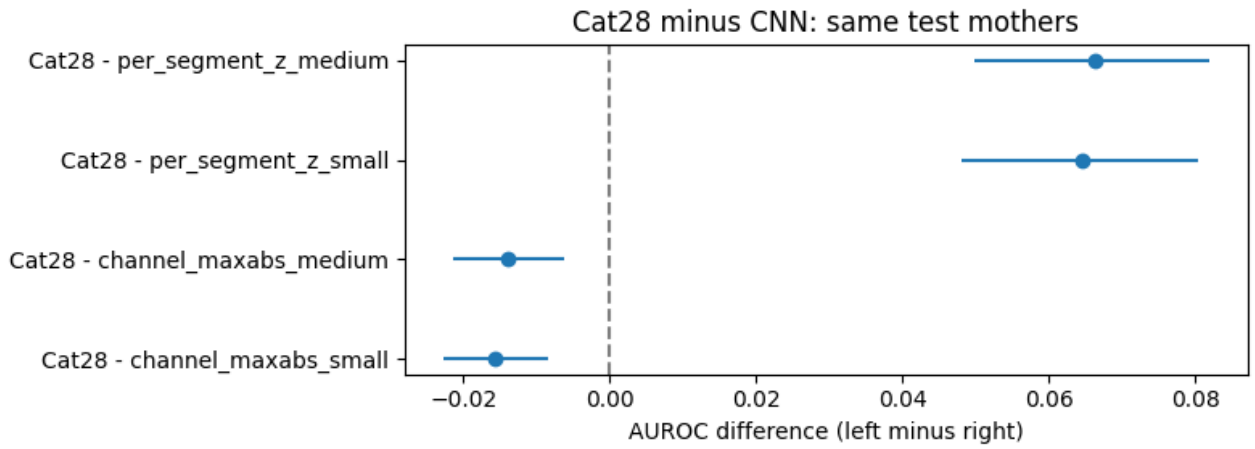


그림10. 평활 Cat28과 선택 CNN의 시험 AUROC 차이

점과 선은 Cat28−CNN의 AUROC 차이와 짝지은 산모 부트스트랩 95% CI다. 음수는 CNN에 유리한 방향이다. maxabs 정규화의 두 CNN과 구간별 z 정규화의 두 CNN은 차이 방향이 서로 다르다.

폭과 seed를 맞춘 정규화 비교

대표 모델끼리의 비교에는 선택 seed의 차이도 포함되므로, 선택된 두 폭에서 같은 seed의 maxabs−구간별 z 차이를 별도로 확인하였다. 여섯 비교 모두 AP와 AUROC 차이의 CI가 양수였고, AP 차이는 0.153~0.173이었다. Brier 차이도 여섯 비교 모두 음수였다. 이 설정에서는 구간 간 절대 수준과 크기를 보존하는 정규화가 더 유리하였다. 이를 모든 CNN 구조나 모든 폭에 대한 정규화의 일반적 우열로 확대하지는 않았다.

표15. 같은 폭·seed에서 비교한 CNN 정규화 효과

폭	seed	maxabs−z ΔAP (95% CI)	maxabs−z ΔAUROC (95% CI)
32	42	+0.173 (+0.139~+0.206)	+0.092 (+0.076~+0.107)
32	43	+0.164 (+0.128~+0.199)	+0.083 (+0.069~+0.098)
32	44	+0.153 (+0.120~+0.185)	+0.074 (+0.060~+0.089)
64	42	+0.161 (+0.128~+0.196)	+0.080 (+0.065~+0.094)
64	43	+0.164 (+0.132~+0.197)	+0.080 (+0.066~+0.095)
64	44	+0.164 (+0.133~+0.196)	+0.081 (+0.067~+0.095)

각 행은 같은 폭과 seed에서 정규화만 다른 두 CNN의 시험 예측 비교다. 시험 산모 2,056명·9,458개 구간의 짝지은 산모 부트스트랩 2,000회 CI이다. 이 비교도 동일한 가중치를 단순 변환한 것이 아니라, 각 정규화 조건으로 따로 학습한 모델의 비교다.

계산 비용

표16. 선택된 Cat28과 CNN의 학습·추론 시간

선택 모델	학습 시간 (초)	추론 (μs/구간)	선택 seed
Cat28	13.342	0.498	44
maxabs CNN·폭 32	259.524	1.867	43
maxabs CNN·폭 64	186.981	3.079	44
구간별 z CNN·폭 32	289.021	2.513	44
구간별 z CNN·폭 64	357.301	3.741	42

선택된 대표 seed 한 개의 측정 실행 시간이며 전체 후보 탐색 비용이 아니다. CNN 추론은 정규화를 포함한 시험 묶음 추론 3회의 중앙값을 구간 수로 나눈 값이고, 모델 로딩·원자료 읽기·FHR 보간은 제외한다. Cat28 추론은 인자 계산 비용을 포함하지 않는다. 실행 장치와 측정 범위를 일치시킨 비교가 아닌 시간을 보편적 속도비로 해석하지 않았다.

Cat28에는 위 추론 시간 외에 인자 추출 비용이 든다. 전체 94,148개 구간의 평균 인자 추출 시간은 평활 조건 7.407 ms/구간, 비평활 조건 7.344 ms/구간이었다. CNN 학습·추론에는 CUDA를 사용하였다. 따라서 모델 호출 시간만으로 파형 입력부터 결과 출력까지의 전체 비용을 비교할 수 없고, 실제 운영 장비에서의 지연이나 메모리 사용량을 검증한 결과도 아니다.

이번 비교는 동일한 산모·구간을 사용하지만 입력 전처리까지 같은 실험은 아니다. CNN은 FHR 결측 보간과 원본 TOCO를 사용하고, 기준 Cat28은 30초 평활 후 계산한 인자를 사용한다. 또한 이 CNN은 소형 구조를 길이 150에 맞춰 처음부터 학습한 대조 모델이다. 결과는 이 입력·정규화·학습 조건의 비교로 한정하며, 인자 모델 또는 모든 CNN의 일반적 우열을 뜻하지 않는다.

4.4 임상정보 추가 효과

파형 인자에 임상정보를 추가하는 분석은 전문가의 구간 판독을 예측하는 과제를 유지한 상태에서 수행하였다. 28개 파형 인자에 신장·체중, 임신·출산 횟수, 수축기·이완기 혈압, 임신성 고혈압·고혈압·임신성 당뇨·당뇨·전자간증, 산모 연령과 재태 연령의 13개 변수를 더하여 총 41개 입력을 사용하였다. 기존 산모 분할과 평가 구간을 유지하였으며, 훈련·검증·시험 구간 수는 각각 75,273개, 9,417개, 9,458개였다. 분만 결과는 이 모델의 입력에 포함하지 않았다.

추가 모델은 세 학습 seed 중 검증 AP가 가장 높은 seed 43을 선택하였다. 주 비교는 각 입력 조건에서 검증 자료로 선택한 모델끼리 수행하였고, 동일한 시험 산모 2,056명과 구간 9,458개에서 지표 차이를 계산하였다. 차이의 방향은 '임상정보 + 파형 인자 모델 – 파형 인자 모델'이며, 신뢰구간은 두 모델에 같은 산모 추출 횟수를 적용한 2,000회 재표집으로 구하였다.

표17. 임상정보 추가에 따른 판독 예측 성능의 변화

지표	성능 차이 (95% 신뢰구간)
AP	+0.002 (−0.011~0.014)
AUROC	−0.003 (−0.006~0.001)
Brier	−0.001 (−0.003~−0.00004)

차이 = 임상정보 추가 모델 − Cat28. AP·AUROC는 양수, Brier는 음수일 때 개선이다.

시험 산모 2,056명·구간 9,458개; 산모 재표집 2,000회.

AP와 AUROC 차이의 신뢰구간은 모두 0을 포함하여, 임상정보가 판독 순위 성능을 추가로 높였다는 근거는 뚜렷하지 않았다. Brier 차이는 −0.001로, 확률 오차는 소폭 감소하였다. 따라서 이번 자료에서는 임상정보 추가가 파형 인자만으로 얻은 판독 재현 성능을 크게 바꾸지는 않았으며, 지표에 따라 효과의 방향과 크기가 달랐다. 임상정보의 실제 이용 가능 시점, 특히 재태 연령이 모니터링 당시 확보된 정보인지에 대한 확인은 별도로 필요하다.

4.5 경보 성능

Cat28의 경보 기준은 검증 자료의 정상 구간에서 특이도가 90% 이상이 되도록 정한 뒤 시험 자료에 고정하여 적용하였다. 선택된 원점수 임계값은 0.501이었으며 검증 특이도는 0.9였다. 시험에서는 산모 2,056명의 9,458개 구간 중 이상 판독 1,528개, 정상 판독 7,930개를 평가하였다.

표18. 시험 구간의 전문가 판독과 경보 결과

전문가 판독	경보 없음	경보 있음
정상	7,199 (TN)	731 (FP)
이상	557 (FN)	971 (TP)

검증에서 정한 임계값을 시험 자료에 그대로 적용하였다. 각 칸은 5분 구간 수이다.

표19. 고정 임계값을 적용한 시험 경보 성능

평가 지표	점추정	95% 신뢰구간
구간 민감도	0.635	(0.604~0.668)
구간 특이도	0.908	(0.899~0.917)
구간 양성예측도(PPV)	0.571	(0.535~0.607)
정상 기록 경보율	0.222	(0.201~0.242)
정상 시간당 경보 구간 수	0.974	(0.864~1.088)

정상 기록은 제외 전 원래 판독 전체가 정상인 기록이다. 시간 지표의 분모는 해당 기록에서 유지된 5분 구간 수를 12로 나눈 값이다. 마지막 행의 단위는 개/시간이며, 나머지 행은 비율이다. 산모 재표집 2,000회로 신뢰구간을 산출하였다.

시험 특이도는 약 90.8%로 검증에서 설정한 수준에 가까웠으나, 민감도는 약 63.5%였다. 즉, 고정 기준은 정상 구간의 경보를 제한하는 동시에 이상 판독 구간 557개를 경보하지 않았다. 경보가 발생한 구간 중 실제 이상 판독의 비율은 약 57.1%였다. 구간 특이도가 높더라도 정상 기록의 약 22.2%에서는 경보가 한 번 이상 발생하였다. 이는 한 기록에 여러 구간이 포함되므로 구간 단위 오류와 기록 단위 경보 부담을 함께 보아야 함을 보여준다.

정상 시간당 경보는 약 0.974개였지만, 이는 연속 경보를 하나로 합친 사건 수가 아니라 경보가 발생한 5분 구간 수이다. 또한 제외된 구간을 포함한 전체 검사시간이 아닌 유지된 정상 기록의 관측시간을 분모로 사용한다. 따라서 이 값을 실제 연속 모니터링에서 의료진이 경험하는 경보 사건의 빈도와 동일하게 해석할 수는 없다.

확률 보정과 경보의 변화

검증 점수에 로지스틱 확률 보정을 적합한 뒤 시험 자료에 적용하였다. 학습된 기울기는 0.976로 양수였으며, 보정 점수의 검증 임계값은 0.312였다. 원점수의 시험 Brier는 0.099이었고, 보정 후 – 보정 전 차이는 −0.009 (95% 신뢰구간 −0.011~−0.006)로 확률 오차가 감소하였다. 반면 AP와 AUROC의 차이는 모두 0이었고, 보정 점수에서 다시 정한 임계값을 적용했을 때 시험 경보가 바뀐 구간도 0개였다.

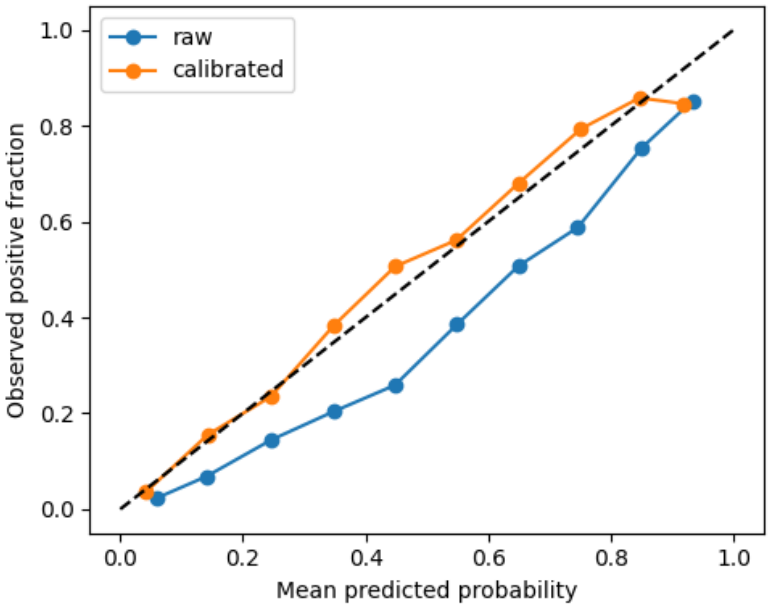


그림11. Cat28의 시험 점수에 대한 확률 보정 전후 비교

각 점은 같은 확률 구간에 속한 시험 구간의 평균 예측값과 실제 이상 판독 비율이다. 보정 전후에 각각 점수 구간을 구성하였으며, 대각선은 두 값의 일치를 나타낸다. 보정 함수는 검증 자료에서 학습하였다.

이번 보정은 점수의 크기와 실제 이상 판독 빈도의 대응을 개선하였지만, 시험 자료에서 점수 순위나 경보 대상은 바꾸지 않았다. 따라서 확률 보정의 개선과 민감도·오경보의 개선은 구분해야 한다. 검증에서 정한 경보 기준과 보정 함수의 효과가 다른 기관에서도 유지되는지는 다음 절에서 별도로 평가하였다.

4.6 기관 간 일반화 평가

기관 간 일반화는 원자료의 기관 코드를 하나씩 학습에서 제외하는 방식으로 평가하였다. 평가 기관 코드에 등장한 산모는 다른 기관 코드에 있는 구간까지 학습 후보에서 제거하였고, 남은 산모를 훈련·검증으로 나누어 기관 코드별 Cat28을 새로 학습하였다. 모델 선택, 확률 보정과 경보 기준 설정은 모두 학습 측 검증 자료에서 수행하였다. 총 13개 기관 코드 중 12개에서 평가를 완료하였으며, 나머지 1개는 분할 불가(split_unavailable)로 집계되었다. 아래 결과는 완료한 12개 기관 코드를 대상으로 한다.

표20. 평가를 완료한 기관 코드별 자료 구성

기관 코드	산모 수	구간 수	이상 구간 비율
aju	4,417	20,488	0.135
cat	1,021	5,249	0.396
cau	176	735	0.212
dan	1,884	8,969	0.161
inj	3,329	15,706	0.133
jnu	1,234	4,788	0.139
khu	2,141	9,487	0.131
knh	2,127	9,827	0.118
knu	413	1,980	0.070
kor	615	2,502	0.157
snh	2,170	9,745	0.183
snu	1,023	4,669	0.235

각 기관 코드의 평가 집합에 남은 산모와 구간을 집계하였다. 이상 구간 비율은 전문가 판독을 기준으로 한다. 기관 코드는 원자료의 구분을 유지하였다.

표21. 학습에서 제외한 기관 코드의 원점수 성능

기관 코드	AP (95% CI)	AUROC (95% CI)	특이도 (95% CI)
aju	0.559 (0.531~0.587)	0.860 (0.850~0.869)	0.922 (0.917~0.927)
cat	0.751 (0.725~0.777)	0.815 (0.799~0.830)	0.692 (0.669~0.715)
cau	0.666 (0.564~0.762)	0.882 (0.847~0.914)	0.938 (0.912~0.960)
dan	0.587 (0.549~0.626)	0.847 (0.832~0.863)	0.898 (0.889~0.907)
inj	0.556 (0.524~0.589)	0.872 (0.859~0.882)	0.892 (0.885~0.899)
jnu	0.621 (0.566~0.672)	0.890 (0.873~0.904)	0.944 (0.934~0.953)
khu	0.525 (0.481~0.567)	0.844 (0.827~0.862)	0.891 (0.882~0.898)
knh	0.478 (0.425~0.532)	0.868 (0.854~0.882)	0.915 (0.906~0.925)
knu	0.316 (0.233~0.420)	0.850 (0.807~0.888)	0.923 (0.907~0.939)
kor	0.518 (0.450~0.586)	0.795 (0.752~0.835)	0.890 (0.871~0.907)
snh	0.541 (0.503~0.579)	0.852 (0.840~0.864)	0.906 (0.895~0.916)
snu	0.707 (0.667~0.748)	0.879 (0.864~0.894)	0.892 (0.878~0.906)

각 기관 코드의 원점수(raw) 조건이다. 경보 기준은 학습 측 검증 자료에서 정하였으며 평가 기관 코드에서는 변경하지 않았다. 신뢰구간은 해당 평가 기관 코드의 산모 재표집 2,000회로 구하였다.

기관 코드별 AP는 0.316~0.751, AUROC는 0.795~0.890이었다. AP는 해당 기관 코드의 이상 구간 비율과 함께 해석해야 한다. 예를 들어 cat은 AP 0.751와 함께 이상 비율 0.396를 보인 반면, knu는 AP 0.316과 이상 비율 0.070을 보였다. 서로 다른 양성 비율과 자료 구성을 가진 기관 코드의 AP만으로 기관별 난이도나 이동 성능을 단정하기는 어렵다.

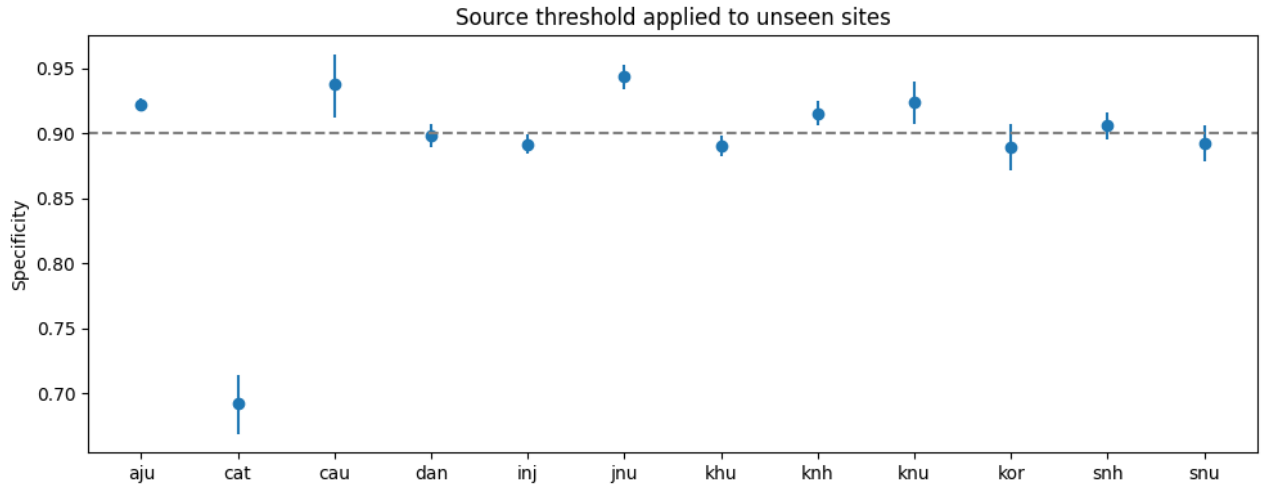


그림12. 학습 측 경보 기준을 새로운 기관 코드에 적용했을 때의 특이도

점은 기관 코드별 원점수 특이도, 세로선은 산모 bootstrap 95% 신뢰구간이다. 점선 0.90은 학습 측 검증 자료에서 설정한 목표이며 평가 기관 코드의 보장 성능이 아니다.

특이도는 0.692~0.944로 차이가 컸다. cat에서는 AP가 가장 높았음에도 특이도가 0.692 (0.669~0.715)이었으며, 정상 기록 경보율은 0.612 (0.561~0.661), 정상 시간당 경보 구간 수는 3.360 (2.984~3.746)이었다. 이는 순위 성능이 높더라도 다른 기관 코드에서 정한 경보 기준이 정상 구간의 경보를 같은 수준으로 제한하지 못할 수 있음을 보여준다.

확률 보정의 기관 코드 간 이동

학습 측 검증 자료에서 적합한 확률 보정도 모든 평가 기관 코드에서 Brier를 낮추지는 않았다. cau, snh, snu에서는 보정 후 Brier 점추정이 증가하였다. 따라서 동일 자료 분할에서 관찰한 보정 효과를 다른 기관 코드에도 일률적으로 적용할 수는 없다. 아래 비교는 점추정의 방향을 기술한 것이며, 보정 차이에 대한 짝지은 신뢰구간을 제시한 분석은 아니므로 통계적으로 유의한 악화로 해석하지 않는다.

표22. 학습 측 확률 보정 후 Brier 점추정이 증가한 기관 코드

기관 코드	보정 전 Brier	보정 후 Brier
cau	0.107	0.116
snh	0.113	0.114
snu	0.113	0.116

Brier는 작을수록 좋다. 학습 측 검증 자료에서 적합한 보정기를 해당 평가 기관 코드에 그대로 적용한 결과이다.

이 평가는 같은 자료 체계 안에서 기관 코드를 제외한 일반화 평가이다. 기관 코드와 실제 의료기관의 일대일 대응이 확인된 독립 외부병원 검증으로 확대하여 해석하지 않았다. 또한 신뢰구간은 선택된

모델과 경보 기준을 고정한 상태에서 평가 산모 구성의 변동을 나타내며, 기관별 모델의 재학습이나 학습 기관 구성 변화에 따른 불확실성까지 포함하지 않는다.

4.7 판독과 분만 결과 (H5)

판독 재현과 분만 결과 예측은 서로 다른 과제이므로, 이 절에서는 관측 단위를 5분 구간에서 검사 기록으로 바꾸어 분석하였다. 먼저 실제 전문가 판독과 분만 결과의 연관을 기술하고, 이어 임상정보만 사용한 모델에 실제 판독 요약을 추가했을 때의 예측 증분을 평가하였다. 판독 요약은 원래 전문가 판독에서 구한 이상 구간 비율과 최장 연속 이상 구간 수이며, 자동 판독 모델의 예측 점수를 입력한 분석은 아니다.

분만 결과의 관측 범위와 판독의 직접 연관

제대동맥혈 pH는 6~8 범위, 1분·5분 Apgar는 0~10 범위의 값만 유효 관측으로 취급하였다. 양성은 pH < 7.2, Apgar < 7로 정의하였다. 결측값이나 유효 범위 밖 값은 해당 결과 분석에서 제외하였으며 정상 결과로 대치하지 않았다.

표23. 분만 결과별 분석 집단

결과	관측 기록 수	관측 산모 수	양성 기록 수	결측·범위 밖 기록 수
제대동맥혈 pH	12,637	11,769	1,114	9,500
1분 Apgar	22,136	20,550	3,227	1
5분 Apgar	22,137	20,551	658	0

양성 비율은 제대동맥혈 pH 0.088, 1분 Apgar 0.146, 5분 Apgar 0.030였다. 같은 산모의 반복 검사와 다태아 기록을 포함하며, 평가는 기록 단위로 수행하였다.

표24. 실제 이상 판독 비율과 분만 결과의 직접 연관

결과	판독 비율의 AP	판독 비율의 AUROC
제대동맥혈 pH	0.115	0.582
1분 Apgar	0.191	0.578
5분 Apgar	0.056	0.644

기록별 실제 이상 판독 구간 비율을 순위 점수로 사용하였다. 이는 분만 결과에 맞추어 학습한 모델의 확률값이 아니며, 이 직접 연관표에는 신뢰구간을 제시하지 않았다.

실제 이상 판독 비율의 AUROC는 제대동맥혈 pH 0.582, 1분 Apgar 0.578, 5분 Apgar 0.644이었다. 판독 이상과 분만 결과 이상은 서로 일치하지 않았다. 예를 들어 pH 양성 기록 1,114개 중 630개는 원래 구간 판독이 모두 정상이었고, 이상 판독이 있는 기록 중에도 pH 음성이 3,300개 있었다. 따라서 판독을 잘 재현하는 성능만으로 분만 결과를 잘 예측한다고 판단할 수는 없다.

제대동맥혈 pH의 관측 여부에 따른 자료 구성도 달랐다. 이상 판독이 하나라도 있는 기록의 비율은 pH 관측 집합에서 0.299, 결측·범위 밖 집합에서 0.247였다. 관측 집합만을 평가한 결과를 전체 기록으로 옮겨 해석할 때 이러한 차이에 따른 선택 편향을 고려해야 한다.

임상정보에 실제 판독 요약을 추가한 예측 증분

결과별로 임상정보 13개만 사용한 모델과 판독 요약 2개를 추가한 모델을 비교하였다. 산모 단위 외부 5-fold와 내부 훈련·검증 분할을 적용하여 각 기록은 자기 산모가 학습과 조기중단에서 제외된 모델로 한 번 예측되었다. 두 입력 조건은 같은 내부 분할과 학습 seed 42를 사용하였다. 다섯 fold의 OOF 예측을 모두 모아 기록 단위 지표를 계산하였고, 같은 산모를 함께 재표집하여 모델별 성능과 짝지은 차이의 신뢰구간을 구하였다. 세 분만 결과 모두 전체 fold와 두 입력 조건의 평가를 완료하였다.

표25. 분만 결과 예측 모델별 OOF 성능

결과	입력 조건	AP (95% CI)	AUROC (95% CI)	Brier (95% CI)
제대동맥혈 pH	임상정보	0.112 (0.103~0.124)	0.570 (0.552~0.587)	0.117 (0.114~0.120)
제대동맥혈 pH	임상정보 + 판독	0.117 (0.107~0.130)	0.580 (0.561~0.597)	0.144 (0.142~0.147)
1분 Apgar	임상정보	0.444 (0.425~0.462)	0.762 (0.753~0.772)	0.123 (0.121~0.125)
1분 Apgar	임상정보 + 판독	0.473 (0.454~0.491)	0.784 (0.774~0.793)	0.114 (0.112~0.116)
5분 Apgar	임상정보	0.169 (0.144~0.201)	0.746 (0.725~0.767)	0.050 (0.048~0.051)
5분 Apgar	임상정보 + 판독	0.184 (0.156~0.218)	0.772 (0.751~0.793)	0.050 (0.048~0.051)

표의 판독은 실제 전문가 판독 요약이다. 각 결과의 관측 기록 전체에 대한 OOF 예측을 모아 계산하였으며 fold별 지표의 평균이 아니다. 모델별·지표별 유효 산모 재표집 횟수는 2,000회이다.

표26. 실제 판독 요약 추가에 따른 분만 결과 예측의 증분

결과	ΔAP (95% CI)	ΔAUROC (95% CI)	ΔBrier (95% CI)
제대동맥혈 pH	0.005 (−0.007~0.017)	0.010 (−0.009~0.029)	0.027 (0.026~0.029)
1분 Apgar	0.029 (0.021~0.037)	0.022 (0.016~0.027)	−0.009 (−0.010~−0.008)
5분 Apgar	0.014 (−0.0006~0.031)	0.026 (0.012~0.039)	−0.0002 (−0.0006~0.0003)

차이는 '임상정보 + 실제 판독 요약 − 임상정보'이다. AP·AUROC는 양의 차이, Brier는 음의 차이가 개선을 의미한다. 95% 신뢰구간은 고정된 OOF 예측의 짝지은 산모 재표집 2,000회로 산출하였다.

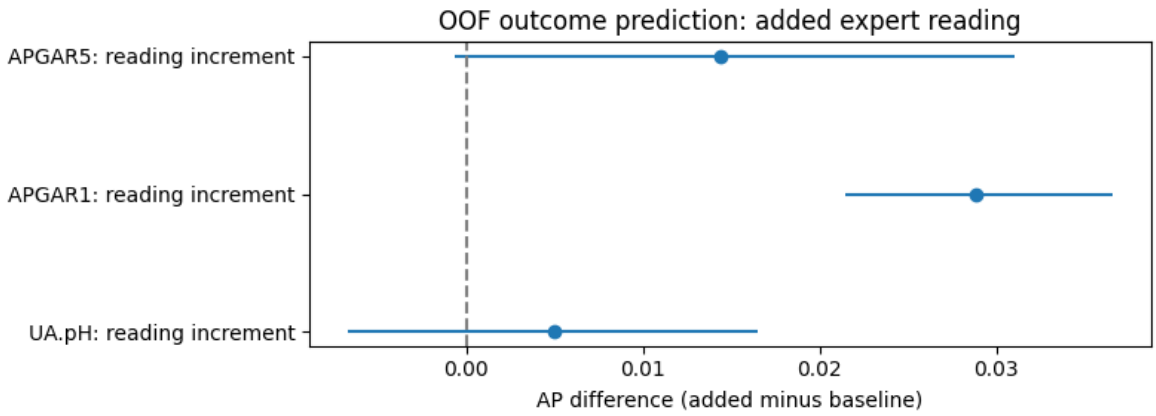


그림13. 실제 판독 요약 추가에 따른 분만 결과 예측 AP의 변화

가로축은 임상정보에 실제 판독 요약을 추가했을 때의 AP 차이이다. 점은 차이의 점추정, 선은 짝지은 산모 bootstrap 95% 신뢰구간이며, 0은 두 조건의 차이가 없는 위치이다.

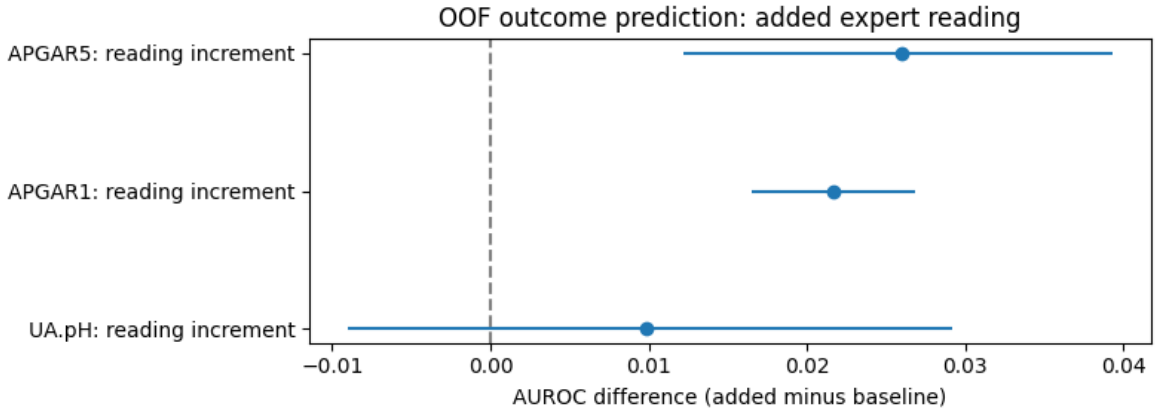


그림14. 실제 판독 요약 추가에 따른 분만 결과 예측 AUROC의 변화

AP와 동일한 OOF 예측 및 비교 방향으로 계산한 AUROC 차이이다. 결과별 결론은 AP·AUROC·Brier를 함께 고려하여 해석하였다.

1분 Apgar에서는 임상정보만 사용한 AP는 0.444에서 판독 요약 추가 후 0.473으로 높아졌고, 차이는 0.029 (0.021~0.037)이었다. AUROC 차이도 0.022 (0.016~0.027)로 양수였으며, Brier 차이는 −0.009 (−0.010~−0.008)로 감소하였다. 이 결과에서는 판독 요약 추가가 순위 성능과 확률 오차를 함께 개선하였다.

제대동맥혈 pH에서는 AP·AUROC 차이의 신뢰구간이 모두 0을 포함했고, Brier는 0.027 (0.026~0.029) 증가하였다. 5분 Apgar에서는 AUROC 차이가 0.026 (0.012~0.039)로 양수였으나 AP와 Brier 차이의 신뢰구간은 0을 포함하였다. 따라서 판독 요약의 추가 예측력은 분만 결과와 평가 지표에 따라 달랐으며, H5를 모든 결과에 일관된 개선으로 해석할 수는 없다. 차이의 신뢰구간이 0을 포함한다는 사실만으로 판독 정보의 기여가 전혀 없다고 결론내리는 것 역시 적절하지 않다.

이 비교는 실제 전문가 판독 정보의 탐색적 예측 증분을 평가한 것이다. 자동 판독 모델을 사용했을 때의 임상 효용을 직접 입증하지 않으며, 기존 고정 시험 산모도 포함하는 별도의 OOF 분석이므로 독립적인 외부 확증 결과로 보지 않았다. 분만 결과의 관측 선택 편향, 모니터링부터 분만까지의 시간, 입력 정보가 실제 예측 시점에 이용 가능했는지는 별도의 검토가 필요하다. 또한 분만 결과별 확률 보정을 적용하지 않은 점과, 고정 OOF 예측의 신뢰구간이 모델 재학습·fold 재분할에 따른 변동을 포함하지 않는 점을 고려하여 해석하였다.

5. 임상적 고찰

5.1 판독 재현과 태아 상태 예측의 차이

Cat28의 AUROC 0.872는 전문의 판독을 재현하는 능력을 나타낸 값이며, 태아의 산증이나 예후를 예측하는 능력을 나타낸 값이 아니다. 고정 임계값에서 Cat28 경보의 전문의 판독에 대한 민감도는 63.5%, 특이도는 90.8%였다(그림15). 실제 판독의 분만 결과 판별 능력(discrimination)은 AUROC 0.578~0.644였다(표27; 4.7절). 다만 두 값은 예측 대상과 단위가 달라 직접 우열을 비교할 수는 없다. 또한 분만 결과 분석에는 모델의 예측 점수가 아니라 실제 판독을 입력하였으므로, Cat28이 분만 결과를 얼마나 예측하는지는 이번 연구에서 평가하지 않았다.

표27. 판독 재현과 분만 결과 판별의 AUROC

판별 대상	N	AUROC
Cat28의 판독 재현	9,458	0.872
판독의 pH 7.20 미만 판별	12,637	0.582
판독의 1분 Apgar 7점 미만 판별	22,136	0.578
판독의 5분 Apgar 7점 미만 판별	22,137	0.644

N은 Cat28이 시험 집합의 5분 구간 수, 판독이 기록 수이다. 판독의 AUROC는 기록 내 이상 구간 비율을 기준으로 구하였고 산모 군집을 반영하지 않았다. Cat28 AUROC의 95% CI(산모 군집 부트스트랩)는 0.858~0.886이다. pH는 측정된 기록의 값이다.

기록 안에 이상 구간이 있는지를 분만 결과와 비교하였다. 분만 결과의 기준 미달은 pH 7.20 미만, 1분 또는 5분 Apgar 7점 미만이다. pH 7.20 미만에 대한 민감도는 43.4%, 특이도는 71.4%, 양성 예측도는 12.8%였다. 기준 미달이 아닌 기록 중 이상 구간이 있었던 위양성 비율은 pH 28.6%, 1분 Apgar 25.7%, 5분 Apgar 26.9%였고, 기준 미달 기록 중 이상 구간이 없었던 위음성 비율은 pH 56.6%, 1분 Apgar 60.6%, 5분 Apgar 47.4%였다(그림15; 계산).

FIGO는 의심 또는 병적 CTG가 민감한 지표이지만 특이도와 양성 예측도가 낮고, 대사성 산증과 낮은 Apgar 점수를 예측하는 능력이 제한적이라고 설명하며(FIGO, 2015, pp. 22-23), ACOG도 낮은 관찰자 간 및 관찰자 내 신뢰도와 높은 위양성률을 한계로 든다(ACOG, 2025, p. 586). 개별 연구를 정리한 Olofsson et al.의 표에서 FIGO 2015 분류의 민감도는 43.6~71.4%, 특이도는 74.0~96.8%이며, 이는 위음성 비율 28.6~56.4%, 위양성 비율 3.2~26.0%에 해당한다(표28; Olofsson et al., 2021, p. 1552; 계산). 연구마다 산증 기준과 분만 단계가 달라 하나의 값으로 묶을 수는 없다. 또한 ACOG는 지속 전자 감시가 간헐 청진에 비해 제왕절개(RR 1.63, 95% CI 1.29~2.07)와 기구 분만(RR 1.15, 95% CI 1.01~1.33)의 위험 증가와 관련된다고 정리한다(ACOG, 2025, p. 586). 산혈증 포착에서도 산혈증 24건의 소규모 연구에서 3단계 분류의 Category III는 12%, 5단계 분류의 orange 또는 red는 79%로 분류 체계에 따라 차이가 컸다(ACOG, 2025, p. 587). 컴퓨터 판독에서는 INFANT 소프트웨어 지원 유무를 비교한 46,042명의 시험에서 복합 불량 예후가 양군 모두 0.7%였고, 딥러닝 연구에서 pH 7.05 미만 예측의 민감도는 79%, 특이도는 78%였다(ACOG, 2025, p. 596). 이번 결과에서 특이도와 양성 예측도가 낮고 위양성이 많다는 점은 이러한 서술과 방향이 같다(표28). 그러나 pH 7.20 미만에 대한 민감도는 43.4%로, 의심 또는 병적 CTG를 민감한 지표로 설명한 FIGO의 서술과 달리 높지 않았다. FIGO의

서술은 의심 또는 병적 분류와 대사성 산증을 다루고, 이번 분석은 이상 구간 유무와 pH 7.20 미만을 사용하였으므로, 이 차이가 판독 자체의 차이인지는 확인할 수 없다. Cat28은 판독을 학습 라벨(reference label)로 사용하였으므로, 판독의 이러한 한계를 답습한다.

표28. 문헌에 보고된 CTG 분류와 모델의 성능

분류	민감도	특이도	위음성	위양성
FIGO 2015 (연구 4편)	43.6~71.4	74.0~96.8	28.6~56.4	3.2~26.0
3단계 Category III	12	-	88	-
5단계 orange 또는 red	79	-	21	-
딥러닝 모델	79	78	21	22

단위는 %이고, 위음성은 100-민감도, 위양성은 100-특이도로 계산하였으며, -는 보고되지 않은 값이다. FIGO 2015는 연구 4편에서 나온 결과 5건의 범위로, 산증 기준(pH 7.00~7.10)과 특이도의 비교 기준이 서로 다르다. 3단계와 5단계는 산혈증 24건의 같은 연구이고, 딥러닝은 pH 7.05 미만 기준이다. 출처: FIGO 2015는 Olofsson et al., 2021, p. 1552, 나머지는 ACOG, 2025, pp. 587, 596; 계산.



그림15. 판독 재현과 분만 결과 대응의 4분할표

파랑은 Cat28 경보와 전문의 판독의 비교로, 시험 집합의 5분 구간 단위이다. 경보는 검증 집합에서 특이도 90%가 되도록 고정한 임계값(0.501)을 넘은 구간이고, 95% CI(산모 군집 부트스트랩)는 민감도 60.4~66.8, 특이도 89.9~91.7, 양성 예측도 53.5~60.7이다. 보라와 주황은 모델이 아니라 전문의 판독과 분만 결과의 비교로, 기록 단위이다. 이상 구간 있음은 기록 안에 이상 구간이 하나라도 있는 경우이고, 이상 구간 없음은 하나도 없는 경우이며, 산모 군집을 반영하지 않았다. pH는 측정된 기록의 값이다. 색칠한 칸은 두 기준이 일치한 경우이다. 출처: 본 분석의 경보 결과(4.5절)와 분만 결과 집계(2.3절, 4.7절)로 작성; 계산.

이 수치들을 해석할 때는 유병률을 함께 보아야 한다. 양성 예측도는 민감도와 특이도뿐 아니라 유병률에 따라서도 달라지기 때문이다. 유병률을 π라 하면 양성 예측도는 다음과 같다.

$$\text{양성 예측도} = \frac{\text{민감도} \times \pi}{\text{민감도} \times \pi + (1 - \text{특이도})(1 - \pi)}$$

이상 구간 유무의 위양성 비율은 세 결과에서 25.7~28.6%로 비슷하였으나, 양성 예측도는 5분 Apgar 5.6%, pH 12.8%, 1분 Apgar 20.8%로 달랐고, 그 크기 순서는 유병률 3.0%, 8.8%, 14.6%의 순서와 같았다(그림15; 계산). 따라서 양성 예측도의 크기만으로 판독이 어느 결과와 더 잘 대응하는지 판단할 수 없다. Cat28의 양성 예측도 57.1%도 시험 집합의 이상 구간 비율 16.2%에서 얻은 값이다. 민감도 63.5%와 특이도 90.8%가 유지된다고 가정하면 이상 구간 비율이 10%일 때 양성 예측도는 43.4%, 5%일 때 26.6%로 낮아진다(그림16; 계산). 이 데이터는 Category와 응급 비율을 목표에 맞춰 구축되었으므로(2.5절) 분만 결과의 유병률도 실제 분만실과 같다고 볼 수 없다. 5분 Apgar 7점 미만의 경우 스웨덴 전국 출생 자료의 유병률 0.74%(2014~2016년)와 0.95%(2018~2020년)(Olofsson et al., 2021, p. 1553)를 같은 식에 넣으면, 이상 구간이 있는 기록의 양성 예측도는 5.6%에서 1.4~1.8%로 낮아진다(그림16; 계산).

유병률에 따른 양성 예측도의 변화

Cat28 경보와 전문의 판독, 유병률 10% 가정

	이상 구간	정상 구간	합계
경보 있음	635 a 참양성	830 b 위양성	1,465
경보 없음	365 c 위음성	8,170 d 참음성	8,535
합계	1,000	9,000	10,000

민감도	a/(a+c)	63.5%
위음성 비율	c/(a+c)	36.5%
특이도	d/(b+d)	90.8%
위양성 비율	b/(b+d)	9.2%
유병률	(a+c)/N	10.0%
양성 예측도	a/(a+b)	**43.4%**
실측 (유병률 16.2%)		57.1%

Cat28 경보와 전문의 판독, 유병률 5% 가정

	이상 구간	정상 구간	합계
경보 있음	318 a 참양성	876 b 위양성	1,194
경보 없음	182 c 위음성	8,624 d 참음성	8,806
합계	500	9,500	10,000

민감도	a/(a+c)	63.5%
위음성 비율	c/(a+c)	36.5%
특이도	d/(b+d)	90.8%
위양성 비율	b/(b+d)	9.2%
유병률	(a+c)/N	5.0%
양성 예측도	a/(a+b)	**26.6%**
실측 (유병률 16.2%)		57.1%

전문의 판독과 5분 Apgar, 보고 유병률 0.74%

	7점 미만	7점 이상	합계
이상 구간 있음	39 a 참양성	2,672 b 위양성	2,711
이상 구간 없음	35 c 위음성	7,254 d 참음성	7,289
합계	74	9,926	10,000

민감도	a/(a+c)	52.6%
위음성 비율	c/(a+c)	47.4%
특이도	d/(b+d)	73.1%
위양성 비율	b/(b+d)	26.9%
유병률	(a+c)/N	0.74%
양성 예측도	a/(a+b)	**1.4%**
실측 (유병률 3.0%)		5.6%

전문의 판독과 5분 Apgar, 보고 유병률 0.95%

	7점 미만	7점 이상	합계
이상 구간 있음	50 a 참양성	2,666 b 위양성	2,716
이상 구간 없음	45 c 위음성	7,239 d 참음성	7,284
합계	95	9,905	10,000

민감도	a/(a+c)	52.6%
위음성 비율	c/(a+c)	47.4%
특이도	d/(b+d)	73.1%
위양성 비율	b/(b+d)	26.9%
유병률	(a+c)/N	0.95%
양성 예측도	a/(a+b)	**1.8%**
실측 (유병률 3.0%)		5.6%

그림16. 유병률에 따른 양성 예측도의 변화

그림15의 민감도와 특이도를 고정하고 유병률만 바꾼 계산값이다. 칸의 수는 10,000건당 기대 건수를 반올림한 값으로, 실제로 관측된 수가 아니다. 파랑은 Cat28 경보와 전문의 판독, 주황은 전문의 판독과 5분 Apgar의 비교이다. 이상 구간 비율 10%와 5%는 예시이고, 5분 Apgar의 유병률 0.74%와 0.95%는 스웨덴 전국 출생 자료의 2014~2016년과 2018~2020년 값이다(Olofsson et al., 2021, p. 1553). 실측은 그림15의 값이다. 집계값에서 계산하였다.

위 계산은 민감도와 특이도가 유병률과 무관하게 일정하다고 가정한 것이며, 이 가정이 항상 성립하지는 않는다. 23개 메타분석(연구 416편)을 분석한 Leeflang et al.은 같은 메타분석 안에서 유병률이 최저값에서 최고값으로 변할 때 민감도 또는 특이도가 0~40%포인트 변하였고, 이 효과는 8개 메타분석(35%)에서 통계적으로 유의하였다고 보고하였다. 전반적으로 유병률이 높을수록 특이도가 낮은 경향이 있었으나 민감도에서는 그러한 체계적인 효과가 없었고, 저자들은 환자 스펙트럼과 같이 유병률과 정확도에 함께 작용하는 기전의 결과일 가능성이 높다고 해석하였다(Leeflang et al., 2013). 따라서 이번 민감도와 특이도를 유병률이 다른 환경에 그대로 옮길 수 없고, 다른 환경에서의 성능은

그 환경의 데이터로 다시 확인해야 한다. 경보 부담에서의 의미는 5.4절에서 다룬다.

다만 판독과 분만 결과의 대응이 낮다는 결과를 판독이 틀렸다는 뜻으로 읽어서는 안 된다. 첫째, 관찰 선택의 영향이 있을 수 있다. 제대동맥혈 pH는 57.1%의 기록에서만 관측되었고, 이상 구간이 있는 기록의 비율은 관측된 기록에서 29.9%, 관측되지 않은 기록에서 24.7%로 달랐다(계산). 둘째, 시간과 개입을 통제하지 못하였다. 기록과 분만 사이의 간격을 알 수 없고(2.5절), 분만 중 감시의 목적은 저산소증과 산혈증에 앞선 상황을 찾아 태아 손상을 막는 데 있다(FIGO, 2015, p. 23). FIGO도 판독 기준, 파형 이상과 출생 사이의 간격, 불량 결과의 기준이 연구마다 달라 결과가 엇갈린다고 설명한다(FIGO, 2015, p. 22). 이상 구간 뒤의 개입으로 결과가 좋아졌다면 이 분석에서는 불일치로 집계될 수 있으나, 개입 여부는 분석에 사용하지 않았다. 셋째, 결과 정의의 제약이 있다. Chiou et al.은 선행 연구의 pH 기준을 7.05~7.20으로 정리하였고(Chiou et al., 2025, p. 3), 표28의 FIGO 2015 연구들은 7.00~7.10을 사용하였다. 이번 분석의 7.20 미만은 이 가운데 가장 넓은 기준이다. 염기 결핍 등 다른 산-염기 지표는 사용하지 않았다. 넷째, 판독에 분만 결과 정보가 섞였을 가능성이 있다. 가공판정 절차에는 라벨링된 영상과 함께 EMR 데이터가 입력되었고(NIA, 2023, p. 27), 여기에는 분만 이후 확정되는 정보도 포함될 수 있다(제안서 2.1.3절). FIGO도 불량 예후를 아는 후향 검토에서 CTG 소견이 더 이상하게 평가되는 경우가 많다고 설명한다(FIGO, 2015, p. 22). 이번 분석에서는 그 영향을 분리하지 못하였다.

임상 변수만으로 구한 AUROC도 1분 Apgar 0.762, 5분 Apgar 0.746, pH 0.570으로 결과 지표마다 달라, 판독과 분만 결과의 관계를 하나의 지표로 단정할 수 없다.

따라서 이번 결과는 파형 인자로 전문의 판독을 재현하여 판독을 보조할 수 있다는 근거이며, 태아 상태를 예측할 수 있다는 근거는 아니다.

5.2 인자 이름과 임상 의미의 차이

28개 입력에는 평균, 범위 같은 요약 통계, 기저선과 변이도 추정값, 규칙으로 검출한 사건 수, 두 신호의 상관이 함께 포함된다. 서로 다른 성격의 계산값을 모두 임상 소견의 직접 측정으로 취급할 수 없다. 부록 B의 주석 비교도 일부 인자의 기록별 대응을 점검한 것이며, 28개 전체의 임상 타당성을 검증한 결과는 아니다. 각 변수의 정의, 의존 관계, 해석 범위는 부록 A에 정리하였다.

파형 인자는 선행 연구의 규칙에 따라 계산한 값이므로, 판독 항목과 이름이 같아도 같은 임상 소견을 측정한 것은 아니다. 인자별 임상 정의와 코드 규칙의 차이는 표29와 같다. 판독에 해당 소견이 있는 기록에 대한 판별 AUROC는 변이감속(variable deceleration) 0.773, 조기감속(early deceleration) 0.656, 후기감속(late deceleration) 0.637, 가속(acceleration) 0.567, 지속감속(prolonged deceleration) 0.500이었고, 기저선 변이도(baseline variability)의 Spearman 상관계수는 0.259였다(표43).

표29. 파형 인자와 임상 정의의 차이

인자	임상 정의	코드 규칙	결과
n_prolonged_decel	FIGO 3분 초과, ACOG 2분 이상 10분 미만	후기감속이 아니고 180~300초	모든 구간 0, AUROC 0.500
n_severe_decel	대응하는 임상 정의 없음	후기감속이 아니고 300초 초과	5분 구간에서 관측 불가, 모든 구간 0
n_early_decel	수축과 일치하는 얕고 짧은 감속	후기감속이 아니고 180초 미만인 나머지	AUROC 0.656, 1회인 구간의 이상 구간 50.5%
n_variable_decel	시작에서 최저점까지 30초 미만	시작에서 첫 최저점까지 30초 미만	AUROC 0.773
n_late_decel	완만한 감속, 수축 시작 20초 이후에 시작	수축 시작 20초 후부터 수축 종료 전에 시작	AUROC 0.637, 수축 미검출 구간(22.3%)에서 계수 불가
n_accel	32주 이후 15 bpm 이상, 15초 이상 2분 미만	15 bpm 이상 16초 이상, 600초 미만, 임신주수 구분 없음	AUROC 0.567, Spearman -0.146
figo_baseline_var	진폭 5~25 bpm	평활 신호의 인접 극값 차이 평균	Spearman 0.259, 5분위 평균 0.95~5.66 bpm
stv	박동별 변이	2초 표본 사이 절대차 평균	박동별 임상 STV와 다름

임상 정의: FIGO, 2015, pp. 16, 18; ACOG, 2025, pp. 588-589. AUROC는 판독에 해당 소견이 있는 기록을 판별한 값이고, 이상 구간 비율은 학습 집합의 값이다. 코드 규칙과 결과: 부록 A, 부록 B.

가장 뚜렷한 차이는 지속감속에서 나타났다. FIGO는 3분을 넘는 감속으로, ACOG는 2분 이상 10분 미만의 감속으로 정의하고(FIGO, 2015, p. 18; ACOG, 2025, p. 589), 코드는 180~300초의 감속을 지속감속으로 센다. 그러나 판독에 지속감속이 있는 기록이 380건인데도 n_prolonged_decel은 94,148개 구간 모두에서 0이었고, AUROC는 0.500이었다. n_severe_decel도 300초를 넘는 사건을 5분 구간 안에서 관측할 수 없어 모든 구간에서 0이었다. 두 인자의 평균 절대 SHAP도 0이었다(4.2절). 따라서 Cat28의 입력 열은 28개이지만, 이번 평활 특징표에서 상수가 아닌 열은 26개이다. 반면 n_prolonged_decel의 0은 구조적 제약이 아니라 이번 구현 규칙에서 검출되지 않은 결과이며(표44), 이 관찰만으로 원인별 기여를 분리할 수는 없다.

이 차이는 모델 설명(model explanation; 예측에 기여한 입력을 제시하는 것)에서 특히 중요하다. 지속감속은 저산소혈증을 시사할 수 있고, 5분을 넘으면서 80 bpm 미만이 유지되고 변이도가 감소한 경우는 급성 저산소증 및 산증과 자주 관련되어 긴급한 개입이 필요하다(FIGO, 2015, p. 18). 그런데 Cat28에는 이 소견을 직접 가리키는 인자가 없다. fhr_min과 brady_frac처럼 심박수 수준을 나타내는 인자가 정보를 일부 대신할 가능성은 있으나, 그 경우 설명은 지속감속이 아니라 심박수 저하로 나타난다. 지속감속 인자가 측정되지 못한 것이 성능에 미친 영향은 이번 연구에서 측정하지 않았다.

다른 인자도 이름 그대로 해석할 수 없다. FIGO는 조기감속이 태아 저산소증이나 산증을 시사하지 않는다고 설명하지만(FIGO, 2015, p. 18), n_early_decel이 1회인 구간의 이상 구간 비율은 50.5%로 0회인 구간의 12.8%보다 높았다. 코드가 후기감속이 아니고 180초 미만인 감속을 모두 조기감속으로 세기 때문에, 조기감속의 임상 정의에 해당하지 않는 사건이 포함될 수 있다. 가속도 FIGO는 저산소증이나 산증이 없음을 나타내는 소견으로 설명하지만(FIGO, 2015, p. 22), n_accel이 2회인 구간의 이상 구간 비율은 36.6%로 0회인 구간의 15.5%보다 높았다. 기저선 추정값이 낮아지면 실제 기저선 구간이 가속으로 잘못 분류(misclassification)되었을 가능성이 있으나, 실제 데이터로 확인하지 않은 가설이다.

figo_baseline_var는 5분위(quintile; 값 크기순 5등분) 평균이 0.95~5.66 bpm으로, 5~25 bpm이라는 임상 기준(FIGO, 2015, p. 16)을 그대로 적용할 수 없었다. stv도 2초 표본 사이의 차이이므로 박동별 임상 STV와 다르다.

표30. 파형 인자 해석에 영향을 주는 계산상의 제한

계산 단계	주요 영향 인자	해석 시 구별할 점
0 처리, 보간, 30초 평활	FHR, TOCO 요약과 이후 모든 파생 인자	전처리 후 값의 요약이며 원신호의 짧은 극값과 변동을 그대로 보존하지 않음. 두 채널의 0을 모두 보간 대상으로 취급.
5분 기저선과 마스크	figo_baseline, figo_baseline_var, 가속과 감속 인자	구간에서 지배적인 수준에 추정값이 영향을 받음. 기저선의 변화가 사건의 진폭 기준에도 전달됨.
사건 문턱과 창 경계	n_decel, n_accel, 깊이와 시간 비율	문턱을 넘은 연속 표본의 길이로 사건을 판정. 창을 넘는 사건의 전체 길이와 연결을 복원하지 않음.
감속 유형 분류	early, late, variable, prolonged, severe	후기 우선, 지속시간 기반 잔여 분류이며 변이감속은 다른 유형과 중복. severe의 300초 초과 조건은 5분 창에서 충족 불가.
수축과 상관 요약	TOCO 3통계, 수축 수, 상관 3인자	피크 검출과 신호 간 선형 관계의 요약. 임상적 수축 강도, 사건별 대응, 생리적 반응 지연을 직접 검증한 값은 아님.

표는 계산 규칙의 성질을 정리한 것이며, 각 실패 조건이 실제 자료에서 발생한 빈도를 추정한 결과가 아니다.

기저선은 각 5분 구간의 양수 FHR 평균에서 시작하고, 현재 추정값과의 차이가 15 bpm 미만인 값만 반복적으로 평균한다. 따라서 낮은 수준이 구간의 상당 부분을 차지하면 그 수준이 추정 기저선에 반영될 수 있다. 가속과 감속은 이 추정값에서 ±15 bpm을 기준으로 검출하므로, 기저선 변화가 사건 검출에도 영향을 준다.

이러한 계산 특성은 공개 CTU-UHB 데이터의 실제 파형에서도 예시적으로 확인된다(그림17). 레코드 1170의 40~45분 구간에서 동일한 평활 신호와 5분 검출 창을 유지한 채 기저선 추정 범위만 해당 5분에서 25~50분의 공통 범위로 바꾸면, 기저선은 110.5 bpm에서 135.8 bpm으로, 감속 후보의 검출 시간은 0초에서 300초로 달라진다. 이 공개 사례는 본 분석 코호트와 별도로 선정한 계산 구조의 예시이며, 본 코호트의 미검출 빈도나 원인별 기여를 추정한 결과는 아니다.

또한 비교 기준으로 사용한 BaseLine의 구체적인 산출 절차와 신호 요약값으로부터의 독립성을 본 분석에서 별도로 검증하지 않았다. 따라서 높은 상관과 낮은 평균 절대차는 제공 주석과의 수치적 대응으로 해석해야 하며, 독립적인 임상 기저선 측정의 정확성으로 확대할 수 없다.

가속과 감속 건수는 기저선과의 진폭 차이와 최소 연결 길이에 의존한다. 가속 계수에는 첫 최고점까지의 시간 조건이, 변이감속 분류에는 첫 최저점까지의 시간 조건이 추가된다. 최소 15초는 2초 표본에서 8개, 즉 코드의 기간 계산으로 16초에 해당한다. n_early_decel은 후기 조건이 아니고 180초 미만인 사건의 잔여 분류이므로 수축이 검출되지 않아도 양수가 될 수 있다. n_variable_decel은 첫 최저점까지 30초 미만인 사건을 별도로 세므로 다른 유형과 중복된다. 따라서 이러한 값을 이름 그대로 임상 유형별 횟수로 읽어서는 안 된다.

변이도 역시 정의를 구별해야 한다. stv는 전처리한 FHR의 인접한 2초 표본 차이를 평균한 값이고, figo_baseline_var는 기저선 마스크 안의 인접 극값 차이를 평균한 값이다. 평활화, 마스크, 극값 검출에 따라 값이 달라지며, 임상 용어와 같은 이름이라는 이유로 동일한 단위의 측정이나 임상 문턱 적용을 보장하지 않는다. 평균, 중앙값, 표준편차, 히스토그램 인자는 파형을 요약하지만 시간 순서를 보존하지 않는다. 특히 hist_width는 fhr_max-fhr_min의 정확한 파생값이므로 28개 입력이 서로 독립적인 정보 28종을 뜻하지 않는다.

공개 CTU-UHB 기록의 기저선 추정 범위와 감속 후보

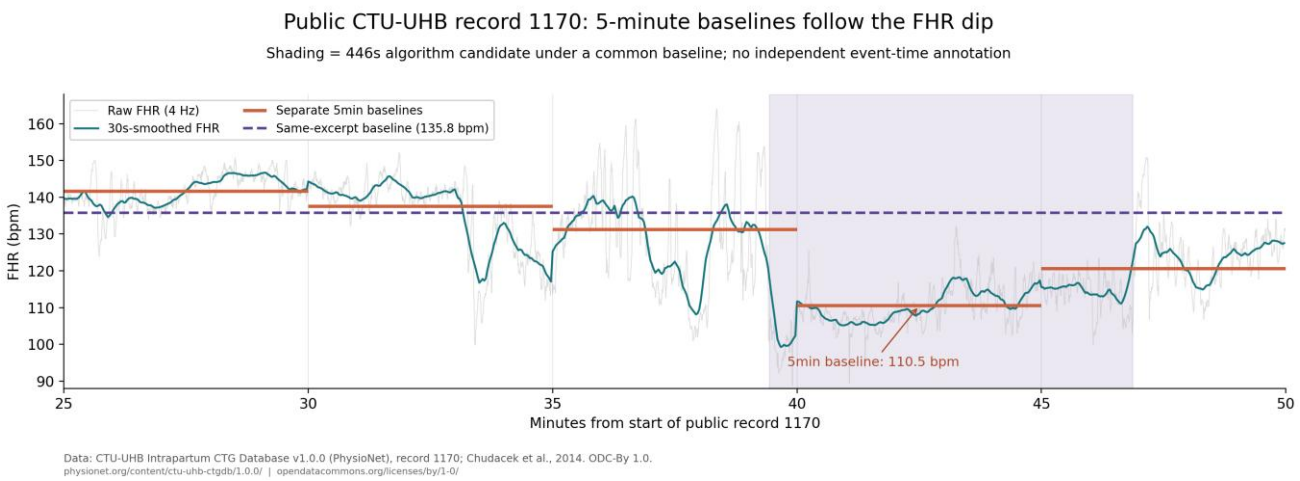


그림17. 공개 CTU-UHB 기록에서 기저선 추정 범위에 따른 감속 후보의 변화

레코드 1170의 25~50분. 회색은 원래 4 Hz FHR, 청록색은 2초 평균 후 각 5분 창에서 30초 평활화한 신호, 주황색은 각 5분의 독립 기저선, 보라색 점선은 동일 평활 신호의 25분 공통 기저선이다. 음영은 공통 기저선으로 창 경계를 연결했을 때 얻은 446초 알고리즘 후보(39.433~46.867분)이다. 본문의 300초는 40~45분 창 안의 후보 길이이다. 이 발췌에는 결측이나 보간이 없으며, 공통 기저선과 후보 시각은 독립적인 임상 정답으로 검증되지 않았다. 출처: CTU-UHB Intrapartum CTG Database v1.0.0, record 1170; Chudáček et al. (2014). https://physionet.org/content/ctu-uhb-ctgdb/1.0.0/; ODC Attribution License v1.0: https://opendatacommons.org/licenses/by/1-0/

따라서 인자군 제거와 SHAP로 확인한 것은 현재 구현으로 얻은 계산값의 예측상 기여이다. 어떤 사건 인자의 기여가 작더라도 해당 임상 소견이 중요하지 않다고 결론낼 수 없고, 다른 요약값이 정보를 대신했는지 또는 검출 규칙이 충분히 담지 못했는지도 구별해야 한다. 추출 규칙의 개선은 독립 참조값과 새 평가 자료를 이용해 검증할 후속 과제이다. 지속 시간이 긴 감속을 다루려면 인접 구간을 참조하는 기저선 추정이 필요하며(제안서 5.1.3절; 그림17), 이는 향후 과제로 정리하였다(6.2절).

5.3 변이도 중심 모델과 설명 가능성

Cat28의 판독 재현이 어떤 계산값에 의존하는지를 SHAP와 인자군 제거로 살펴보았다. 평균 절대 SHAP는 stv 0.764, fhr_min 0.634, hist_mode 0.459 순으로 높았다. 변이도 인자 두 개(stv, figo_baseline_var)를 제거하고 다시 학습시키면 AP가 0.048(95% CI 0.034~0.062), AUROC가 0.028(0.021~0.035) 낮아져 6개 인자군 중 감소 폭이 가장 컸고, 세 시드의 AP 감소도 0.041~0.048로 방향이 같았다. 검증 AUROC로 선택한 단일 spline 인자도 stv였으며 시험 AUROC는 0.744였다. 이는

ACOG가 중등도 변이도를 보호 소견으로, 변이도 소실과 설명되지 않는 지속적 최소 변이도를 고위험 소견으로 제시한 것과 방향이 같다(ACOG, 2025, p. 592). 다만 여기서의 변이도는 부록 A의 계산 규칙으로 정의한 값이므로, 임상 지침의 변이도와 관련지어 해석할 때에는 두 정의의 차이를 전제해야 한다.

표31. Cat28의 주요 인자와 인자값 분위별 이상 구간 비율

인자	SHAP	값 범위	분위 1 (최저)	분위 2	분위 3	분위 4	분위 5 (최고)
stv	0.764	0.17~0.85	27.0	7.5	6.3	8.7	30.0
fhr_min	0.634	108~147 bpm	32.5	10.9	9.6	9.9	16.7
hist_mode	0.459	123~155 bpm	17.7	12.0	12.2	13.4	24.2
fhr_max	0.179	133~167 bpm	20.7	14.2	13.0	12.7	18.9
hist_width	0.143	6.9~40.4 bpm	23.0	8.4	6.6	8.7	32.7
brady_frac	0.083	0~0.54	12.6	44.4	45.7	62.1	78.0
n_decel	0.070	0~4회	11.8	48.8	67.9	70.9	88.9
tachy_frac	0.046	0~0.72	15.1	11.0	12.7	14.8	40.4

단위는 %이다. 분위는 학습 집합의 구간을 인자값 크기로 5등분한 것으로, 0이 많은 brady_frac과 tachy_frac은 분위 1이 0인 구간이고 n_decel은 0~4회의 횟수이다(4회는 9구간). 값 범위는 분위 평균의 범위이다. 학습 집합 전체의 이상 구간 비율은 15.9%이다. 색칠한 칸은 25% 이상, 진한 칸은 50% 이상이다.

인자값과 이상 구간 비율의 관계는 비선형이었다. stv는 최저 분위가 27.0%, 최고 분위가 30.0%였고 중간 분위는 6.3~8.7%여서 U자형 관계를 보였다(표31). hist_width도 23.0%와 32.7%로 비슷하였다. 선형 로지스틱 모델(AUROC 0.819, AP 0.514)에서 비선형 관계를 허용한 가산 모델(additive model; 인자별 효과를 곡선으로 더하는 모델, 0.869, 0.595)로 갈 때 성능이 크게 오른 반면, 상호작용을 표현할 수 있는 Cat28과 가산 모델의 성능 차이는 AUROC 0.003(-0.0004~0.007), AP 0.016(0.004~0.029)으로 작았던 것도 이 비선형성과 부합한다. 낮은 쪽은 FIGO의 변이도 감소에 대응할 수 있으나, 변이도 감소는 저산소증이나 산증뿐 아니라 뇌 손상, 감염, 중추신경 억제제 등에서도 나타날 수 있다(FIGO, 2015, p. 16). 높은 쪽은 반복 감속과 함께 나타날 수 있는 변이도 증가(FIGO, 2015, p. 18)와 관련될 수 있다. 다만 stv는 평활 신호의 2초 표본 차이이므로, 감속 같은 큰 움직임도 값을 키울 수 있어 임상 변이도와 같다고 볼 수 없다. 또한 변이도는 육안 평가의 주관성이 크고 관찰자 간 불일치가 잦은 항목이므로(FIGO, 2015, pp. 16, 22), Cat28이 변이도에 크게 의존한 결과에는 이러한 판독의 불일치도 함께 반영되었을 수 있다. 두 모델은 함수 구조와 학습 설정도 다르므로 이 차이를 순수한 상호작용 효과로 분리할 수는 없다.

반면 감속 유형 인자의 평균 절대 SHAP는 0.003~0.009로 낮았고, 감속 및 가속 인자군을 제거해도 AP 차이는 0.006(-0.00009~0.011), AUROC 차이는 0.0003(-0.001~0.002)이었다. 수축 및 결합 인자군의 AP 차이도 -0.002(-0.008~0.005)였다. 그러나 이를 감속과 수축이 판독에 중요하지 않다는 뜻으로 읽어서는 안 된다. 감속 수가 0회, 1회, 2회로 늘면 이상 구간 비율은 11.8%, 48.8%, 67.9%로 높아졌다(표31). 상관된 인자는 서로를 대신할 수 있으므로, 감속 정보가 fhr_min이나 hist_width에 담겼을 가능성이 있고, 5.2절에서 보았듯 감속 유형 인자는 임상 소견과 잘 일치하지 않았다. 수축도 외부 TOCO로는 빈도만 신뢰할 수 있어(FIGO, 2015, p. 20), 인자가 수축과의 시간 관계를 충분히 담지

못했을 수 있다. 이러한 이유로 H3은 부분 지지로 판정하였다(4.2절).

평활화를 제거한 조건의 성능은 더 높았다. 이번 분석의 평활화는 30초 이동 평균이며, 평활화를 제거하면 AP가 0.021(95% CI 0.007~0.036), AUROC가 0.018(0.011~0.025) 높아졌고 세 시드 모두 방향이 같았다. 이동 평균은 주변 값을 평균하므로 짧은 변동과 극값을 변형할 수 있다. 다만 이 비교만으로 어느 인자의 정보 변화가 성능 차이를 만들었는지 분리할 수는 없다. 따라서 해당 결과는 전처리 선택에 대한 민감도 분석으로 보고하며, 시험 결과를 본 뒤 주 모델을 교체한 것으로 해석하지 않는다. 개선된 전처리의 최종 성능은 새로운 평가 자료에서 확인해야 한다.

따라서 이 역분석은 전문의 판독이 변이도와 심박수 수준의 양극단과 연관되었다는 가설을 제시하는 자료로 읽어야 한다. SHAP와 인자군 제거는 모델 출력의 기여와 예측 변화를 보여 줄 뿐, 생리적 원인이나 전문의의 실제 판단 과정을 설명하지 않는다. 또한 학습 라벨이 판독이므로 태아 상태에 대한 의미로 옮길 수 없다(5.1절). 이 가설을 확인하려면 전문의가 판독 근거를 항목별로 기록한 자료로 다시 분석할 필요가 있다.

5.4 경보 부담과 적용 가능성

판독 보조 도구로 쓰려면 성능 수치와 함께 경보의 빈도와 신뢰성을 보아야 한다(제안서 6.1절). 검증 집합에서 정한 임계값(0.501)을 적용하면 경보는 시험 구간의 18.0%(1,702/9,458)에서 발생하였다. 전문의가 이상으로 판독한 구간의 36.5%(557/1,528)는 탐지하지 못하였고(위음성), 경보의 42.9%(731/1,702)는 오경보(false alarm; 판독과 일치하지 않는 경보)였다(계산). 모든 구간이 정상인 기록의 22.2%에서 경보가 1회 이상 발생하였고, 정상 유지 시간당 경보 구간 수는 0.97개였다(표32). 이 값은 5분 구간 단위의 계산이므로 연속된 경보를 하나로 묶는 실제 모니터링의 부담과 다르며, 기준도 분만 결과가 아니라 전문의 판독이다(5.1절). 위음성이 있으므로 경보가 없다고 해서 정상으로 판단해서는 안 된다. 또한 지속 전자 감시는 제왕절개 위험 증가와 관련되므로(ACOG, 2025, p. 586), 오경보가 불필요한 개입으로 이어지는지도 함께 평가해야 한다.

표32. 시험 집합과 기관 코드별 경보 부담

구분	유병률	민감도	특이도	양성 예측도	정상 기록 경보율	시간당 경보
시험 집합	16.2	63.5	90.8	57.1	22.2	0.97
기관 코드 knu	7.0	53.6	92.3	34.4	23.5	0.88
기관 코드 cat	39.6	78.1	69.2	62.4	61.2	3.36

단위는 %이고, 시간당 경보는 정상 기록의 유지 시간당 경보 구간 수이다. 기관 코드 행은 해당 코드를 학습에서 제외한 평가이며, 유병률은 이상 구간 비율이다.

경보의 의미는 유병률에 따라 달라진다. 5.1절의 계산처럼 민감도와 특이도가 같아도 이상 구간 비율이 낮으면 양성 예측도는 낮아진다(그림16). 실제로 유병률이 7.0%인 knu의 양성 예측도는 34.4%였다. 반대로 유병률이 39.6%인 cat은 민감도가 78.1%로 높았지만 특이도가 69.2%로 낮아, 정상 기록의 61.2%에서 경보가 발생하였고 정상 유지 시간당 경보 구간 수는 3.36개였다(표32). cat의 특이도가 낮은 원인은 확인하지 못하였으나, 임계값을 다른 기관에 그대로 적용하면 특이도가

유지되지 않을 수 있음을 보여 준다. 12개 기관 코드의 원점수 AP와 이상 구간 비율 사이의 비가중 Pearson 상관은 0.83(계산)이어서 AP를 기관 간에 단순 비교할 수 없다. 또한 산모 나이, 재태주수, 다태아 여부와 같은 집단별 성능은 평가하지 않아, 특정 집단에서 경보 부담이나 위음성이 더 큰지는 알 수 없다.

계산량은 적었다. 분석은 안심존의 GPU 환경에서 수행하였다(CUDA, PyTorch 2.1.0, Python 3.10; 09 노트북 실행 출력). 이 환경에서 Cat28의 학습은 13.3~16.7초, 구간당 인자 계산은 7.4 ms, 예측은 0.5 μs였다(표33). 측정된 계산 시간은 5분 구간 길이보다 짧았으나, 전송, 대기, 전처리 전체를 포함한 실시간 시스템의 지연을 평가한 것은 아니다. 다만 경량성(모델 크기와 연산량이 작은 특성)만으로 Cat28이 우수하다고 말할 수는 없다. 매개변수 4,001개의 소형 CNN도 예측이 구간당 1.9 μs였고, AUROC는 0.888로 Cat28보다 0.016 높았으며, AP 차이 -0.014(-0.033~0.004)의 신뢰구간은 0을 포함하였다. 이 CNN의 학습에는 153.5~259.5초가 걸렸다. Cat28의 차이점은 5.2절과 5.3절의 제약 안에서 인자 단위로 살펴볼 수 있다는 점이다.

표33. Cat28과 소형 CNN의 계산 시간과 성능

모델	크기	학습 시간	구간당 시간	AUROC	AP
Cat28	트리 622~773개	13.3~16.7초	인자 계산 7.4 ms, 예측 0.5 μs	0.872	0.611
소형 CNN (폭 32)	매개변수 4,001개	153.5~259.5초	예측 1.9 μs	0.888	0.625

분석 환경은 안심존의 GPU 환경이다(CUDA, PyTorch 2.1.0, Python 3.10; 09 노트북 실행 출력). 운영체제와 세부 사양은 확인하지 못하였고 메모리 사용량은 측정하지 않았다. 시간은 시드 3개의 범위 또는 평균이다. 모델별 실행 설정이 같은지는 비교하지 않았으므로 시간은 참고값으로 읽어야 한다.

이 모델은 야간이나 인력이 부족한 환경에서 판독을 재확인하는 2차 판독 보조 도구를 지향한다(제안서 6.1절). 숙련된 판독 인력이나 GPU 장비가 부족한 환경에 경량 모델로 보급하는 방향도 고려할 수 있으나, 이번 연구는 이를 검증하지 않았다. 위의 시간은 GPU 환경에서 얻은 값이므로, GPU가 없는 저사양 기기에서의 실행 시간은 따로 측정해야 한다. 자료는 국내 상급병원에서 수집되었고(NIA, 2023, p. 19), 다른 환경에서는 유병률, 장비, 신호 품질이 다를 수 있다. **따라서 다른 환경에 적용하려면 그 환경의 자료로 성능과 경보 부담을 다시 확인하고 임계값을 조정해야 하며, 임상 효용은 전향적으로 평가해야 한다.**

5.5 모델이 반영하지 못하는 임상 맥락

Cat28의 입력은 5분 구간의 FHR과 TOCO에서 계산한 인자 28개뿐이다. 그러나 FIGO는 재태주수와 산모에게 투여한 약물 등이 FHR 특징에 영향을 줄 수 있으므로 CTG 분석을 다른 임상 정보와 통합해야 한다고 설명하고(FIGO, 2015, p. 22), ACOG도 FHR 양상을 임상 상황의 맥락에서 해석해야 한다고 밝힌다(ACOG, 2025, p. 589). 같은 파형이라도 맥락에 따라 의미가 달라질 수 있지만, 모델에는 이를 구별할 정보가 없다(표34, 부록 C).

표34. 파형 해석에 영향을 주는 임상 맥락과 이번 분석의 입력

맥락	파형에 줄 수 있는 변화	근거	이번 분석의 입력
태아 수면	변이도가 정상 범위의 낮은 쪽에 있고, 최대 50분까지 가속이 드묾	FIGO pp. 16, 18; ACOG p. 590	없음
투여 약물	변이도 감소, 빈맥 (부록 C)	FIGO pp. 16, 22; ACOG p. 590	없음
발열, 감염	빈맥, 변이도 감소	FIGO p. 16	없음
진통 단계	분만 2기에 산모 힘주기가 저산소증에 기여할 수 있고, 신호 오류가 늘어남	FIGO pp. 14, 22; ACOG p. 591	없음
재태주수	32주 미만에서는 가속 기준이 다름	FIGO p. 18; ACOG p. 588	Cat28에는 없음, 임상 변수 비교에만 사용
산모 심박 혼입	산모 심박이 태아 심박으로 기록될 수 있음	FIGO p. 14; ACOG p. 591	없음, 품질 점검 안 함

이번 분석의 입력은 2장에 정리한 자료 항목을 기준으로 하였다. 출처: FIGO, 2015, pp. 14, 16, 18, 22; ACOG, 2025, pp. 588, 590, 591.

예를 들어 stv 최저 분위의 이상 구간 비율은 27.0%였으나, 변이도가 낮은 이유가 저산소증인지, 태아 수면인지, 약물의 영향인지는 파형 인자만으로 구별할 수 없다(FIGO, 2015, p. 16; ACOG, 2025, p. 590). 전문의 판독에는 EMR 정보가 함께 제공되었으므로(2.5절), 모델이 재현하지 못한 판독의 일부에는 이러한 맥락이 포함되었을 가능성이 있다. 다만 경보 오류와 임상 맥락의 관계는 이번 연구에서 분석하지 않았으므로 가설이다.

임상 변수 13개를 Cat28에 더해도 AP는 0.002(-0.011~0.014), AUROC는 -0.003(-0.006~0.001) 달라져 뚜렷한 이득이 없었다. 그러나 이를 맥락이 필요 없다는 뜻으로 읽어서는 안 된다. 사용한 변수는 키, 체중, 임신력과 출산력, 혈압, 고혈압, 당뇨, 전자간증 관련 항목, 산모 나이, 재태주수이고, 약물, 발열, 진통 단계처럼 파형 해석에 직접 관련된 정보는 포함되지 않았다. 재태주수도 실제 모니터링 시점에 쓸 수 있는 값인지 확인이 필요하다. 또한 이 분석의 기준은 태아 상태가 아니라 전문의 판독이다. 신호 품질도 마찬가지이다. 외부 감시에서는 산모 심박 혼입(산모 심박을 태아 심박으로 기록하는 현상)과 신호 오류가 생길 수 있으나(FIGO, 2015, p. 14; ACOG, 2025, p. 591), 품질이 나쁜 구간을 표시하거나 경보에서 제외하는 절차는 평가하지 않았다(2.5절).

이러한 한계 때문에 Cat28의 역할은 판독 보조로 제한된다. ACOG는 분만 중 FHR의 해석과 관리에서 컴퓨터 접근에 일차적으로 의존하지 말 것을 권고하고(강한 권고, 중등도 근거; ACOG, 2025, pp. 585, 596), FIGO는 CTG 감시 자체도 임상 관찰과 판단을 대신할 수 없다고 밝힌다(FIGO, 2015, p. 13). **따라서 Cat28은 전문의의 판단을 대체하는 도구가 아니라, 판독 재확인을 돕는 임상 의사결정 보조(clinical decision support) 도구로 해석해야 한다.** 이번 연구는 임상의가 경보를 어떻게 사용하는지, 경보가 판단과 분만 결과를 바꾸는지를 평가하지 않았으므로, 임상 효용은 실제 사용 환경에서 전향적으로 확인해야 한다.

5.6 선행 연구와의 비교

박창은(2025)은 이번 분석과 같은 NIA 구축 사업의 자료로 전문의 판독을 예측하는 1D SE-ResNet50을 개발하였다(박창은, 2025, pp. 3, 5, 25). 내부 테스트 성능은 AUROC 0.880, PRC 0.625였고(박창은, 2025, p. 12), Cat28의 AUROC 0.872, AP 0.611은 이와 비슷한 범위이다(표35). **이는**

파형 인자와 트리 기반 모델로도 딥러닝 모델과 비슷한 판독 재현 성능을 얻을 수 있음을 시사한다. 다만 같은 사업의 자료라 산모가 상당 부분 겹칠 수 있으므로 독립적인 재현으로 볼 수 없고, 제외 기준과 평가 집합이 달라 두 모델의 우열을 비교한 결과도 아니다. 학습에 사용하지 않은 병원에서의 외부 검증 성능은 AUROC 0.862~0.895, PRC 0.553~0.615로(박창은, 2025, p. 12), 이번 분석의 기관 코드 제외 평가(leave-one-site-out; 한 기관 코드를 학습에서 제외하고 그 코드로 평가, AUROC 0.795~0.890, AP 0.316~0.751)에 해당한다. AP의 범위가 넓은 데에는 기관 코드별 유병률의 차이도 영향을 줄 수 있다(4.6절).

표35. 선행 연구와 Cat28의 판독 재현 성능

연구	모델	평가 방식	AUROC	AP (PRC)
박창은(2025)	1D SE-ResNet50	내부 테스트	0.880	0.625
이번 연구	Cat28	시험 집합 (산모 단위 분할)	0.872 (0.858~0.886)	0.611 (0.570~0.653)
박창은(2025)	1D SE-ResNet50	외부 병원 3곳	0.862, 0.895, 0.862	0.553, 0.615, 0.601
이번 연구	Cat28	기관 코드 제외 평가 12개	0.795~0.890	0.316~0.751

박창은(2025)은 PR 곡선 아래 면적을 PRC로 보고하였고, AP와 계산 방식이 다를 수 있다. 괄호는 산모 군집 부트스트랩 95% CI이다. 두 연구는 같은 NIA 사업의 자료를 사용하였으나 제외 기준과 평가 집합이 달라, 값의 우열을 직접 비교할 수 없다. 출처: 박창은, 2025, p. 12.

구글 리서치(Google Research) 연구진의 Chiou et al.은 체코 브르노 대학병원 산모 552명의 공개 CTG 데이터(CTU-UHB)로 태아 상태를 예측하는 CNN을 개발하였다(Chiou et al., 2025, p. 1). 이 연구는 이번 분석과 설계가 비슷하다. 파형 인자 기반 모델과 CNN을 비교하였고, 특이도 90%에서의 민감도로 경보 성능을 평가하였으며, 산모와 태아의 임상정보를 추가한 효과를 확인하였다(Chiou et al., 2025, pp. 2-3). pH 예측에서 인자 기반 모델의 AUROC는 0.61 ± 0.06으로 CNN의 0.62 ± 0.06과 통계적으로 다르지 않았고, 임상정보를 더한 모델의 AUROC는 0.69 ± 0.08로 0.07 높았으나 유의하지 않았다(Chiou et al., 2025, pp. 2-3). 이번 분석에서도 소형 CNN과 Cat28의 AP 차이는 신뢰구간이 0을 포함하였으나 AUROC는 CNN이 0.016 높았고(4.3절), 임상정보를 추가한 이득은 뚜렷하지 않았다(4.4절).

다만 두 연구는 규모와 예측 대상이 다르다. Chiou et al.은 제대동맥혈 pH 7.20 미만과 Apgar 7점 미만을 직접 예측하였고, pH를 학습 라벨로 사용한 모델이 Apgar를 학습 라벨로 사용한 모델보다 우수하였다고 보고하였다(Chiou et al., 2025, p. 1). 이번 분석은 산모 수가 20,551명으로 약 37배(계산) 많지만, 학습 라벨은 분만 결과가 아니라 전문의 판독이다. 따라서 이번 연구는 Chiou et al.의 설계를 대규모 국내 자료의 판독 재현 과제로 확장한 것으로 볼 수 있으며, 분만 결과를 학습 라벨로 사용하는 모델은 향후 과제로 남는다(6.2절). 5.2절 그림17의 공개 파형도 같은 CTU-UHB 데이터에서 가져왔다.

5.7 종합

본 연구는 정의된 파형 인자를 이용해 전문의 판독을 어느 정도 재현할 수 있는지와, 그 성능이 어떤 계산 정보에 의존하는지를 평가하였다. Cat28은 단일 인자보다 높은 성능을 보였고 변이도 관련 계산값과 심박수 수준에 주로 의존하였다. 다만 인자의 명칭은 임상 소견의 정확한 측정을 보장하지 않으며, 경량 CNN과의 비교도 지표별로 결론이 달랐다. 고정 경보의 위음성과 오경보, 기관 간 경보

부담의 차이는 실제 적용 전에 확인할 문제이다. 실제 판독과 분만 결과의 대응 및 예측 증분 역시 결과별로 달랐다. 따라서 이번 결과는 판독 재현 절차의 성능과 해석 범위를 보여 주며, 자동 판독의 임상적 유익성이나 태아 상태 예측력을 직접 입증한 것으로 해석하지 않는다.

표36. 연구 가설별 결과와 해석 범위

가설	관찰 결과	결론의 범위
H1 충분성	Cat28 시험 AP 0.611 (95% CI 0.570~0.653), AUROC 0.872 (0.858~0.886).	명시적 인자 조합으로 판독을 재현하는 성능 수준을 확인했다. 임상적 충분성이나 유용성을 입증한 것은 아니다.
H2 종합성	검증에서 선택한 단일 spline 대비 AUROC 차이 +0.128 (0.110~0.146). 개발 집합 반복 평가에서도 조합의 이득을 확인했다.	이 자료와 선택 절차에서 여러 인자 조합의 이득을 지지한다.
H3 기여 구조	변이도군 제거의 AP 감소가 가장 컸고 심박수 수준군도 기여했다. 가속과 감속이군 제거의 AP 차이 CI는 0을 포함했다.	부분 지지. 계산값의 기여이며 임상 소견별 중요도나 전문의의 사고 과정을 뜻하지 않는다.
H4 경량 모델 대등성	maxabs 소형 CNN 대비 AP 차이는 -0.014 (-0.033~0.004), AUROC 차이는 -0.016 (-0.023~-0.008).	AP 차이는 불확실하고 AUROC는 CNN에 유리했다. 동등성이나 비열등성을 확정할 수 없다.
H5 판독-분만 결과 대응	실제 판독 비율의 직접 AUROC는 0.578~0.644. 임상정보 대비 판독 요약의 증분은 결과와 지표별로 달랐다.	부분적인 대응을 확인했다. 자동 판독 모델의 예후 예측력이나 임상 효용을 검증한 결과는 아니다.

이 표는 4장의 결과를 요약한다. 가설별 새로운 검정이나 별도의 성능 문턱을 추가하지 않았다.

이번 연구의 의의는 세 가지이다. **첫째, Cat28은 가볍다.** 학습은 13.3~16.7초, 구간당 인자 계산은 7.4 ms, 예측은 0.5 μs였고(표33), 시험 AP는 0.611로 소형 CNN의 0.625와의 차이가 신뢰구간 안에서 0을 포함하였다(4.3절). AUROC는 CNN이 0.016 높았으나, 인력과 장비가 부족한 환경에서 판독을 재확인하는 보조 모델의 후보가 될 수 있다. 다만 저사양 기기에서의 실행 시간은 따로 확인해야 한다(5.4절). **둘째, 같은 설계의 선행 연구보다 자료의 규모와 범위가 크다.** 공개 데이터 CTU-UHB의 산모 552명을 사용한 Chiou et al.(2025)과 달리, 이번 분석은 국내 13개 기관 코드의 산모 20,551명, 기록 22,137건을 사용하였고(산모 수 약 37배, 계산), 이 규모 덕분에 기관 코드를 하나씩 제외하는 일반화 평가까지 수행할 수 있었다(4.6절). **셋째, 판독 재현에 쓰인 정보를 인자 단위로 확인할 수 있다.** 인자군 제거와 SHAP로 Cat28이 변이도와 심박수 수준에 주로 의존한다는 점을 확인하였으며(5.3절), 이는 파형을 직접 입력하는 CNN과 구별되는 점이다(5.4절).

Cat28은 파형 인자만으로 전문의 판독을 AUROC 0.872로 재현하였으나, 이는 판독 재현 성능이며 태아 상태를 예측하는 성능이 아니다(5.1절). 판독 자체도 pH 7.20 미만에 대한 민감도가 43.4%로 분만 결과와의 대응이 제한적이었다. 인자 이름은 임상 소견과 같지 않았고(5.2절), 모델은 변이도와 심박수 수준에 주로 의존하였다(5.3절). 경보에는 위음성 36.5%와 오경보 42.9%가 있었고, 경보 부담은 기관과 유병률에 따라 달랐다(5.4절). **따라서 Cat28은 임상 맥락을 함께 보는 전문의의 판독을 재확인하는 보조 도구로 해석해야 하며(5.5절), 다른 환경에 적용하려면 그 환경의 자료로 다시 검증해야 한다.**

6. 한계와 향후 과제

6.1 한계

첫째, 파형 인자는 임상 소견을 그대로 옮긴 값이 아니라 본 연구의 전처리와 검출 규칙에 따른 값이다. 5분 기저선 추정과 창 경계, 일괄 30초 평활, 사건 진폭·기간 조건, 감속 유형 분류가 각 인자의 의미를 제한한다. 일부 입력은 상수이거나 다른 입력의 정확한 파생값이고, 여러 인자가 같은 기저선·마스크·사건 검출 결과를 공유한다. 따라서 예측상 기여를 독립적인 생리적 중요도나 전문의 판단의 인과적 설명으로 옮길 수 없다. 변수별 제한은 부록 A에 정리하였다.

둘째, 제공 주석과의 비교는 기록 단위 집계값의 대응 점검이며 개별 사건의 시작·끝과 유형을 독립적으로 확인한 검증이 아니다. BaseLine의 산출 절차와 독립성도 별도로 확인하지 않았다. 상관이 높다는 사실만으로 구간 안의 기저선 추정이나 다른 인자의 측정이 타당하다고 보장할 수 없다. 주 분석에서 관찰한 미검출 현상의 원인별 기여를 정량적으로 분리하지도 않았다.

셋째, 분석 자료는 구축 목표에 따라 구성된 데이터이며 실제 사용 환경의 이상 판독 비율과 같다고 볼 수 없다. 임상 변수의 분포는 구축 전체 기준의 보고값이고 분석 집단의 재태주수 분포 등은 충분히 제시되지 않아 대표성 판단에 제한이 있다. 기관 코드와 실제 병원의 대응도 확인되지 않았다. 산모를 분리한 시험 평가와 기관 코드 제외 평가는 해당 자료 체계 안의 평가이며, 새로 수집한 독립 자료나 전향적 진료 환경의 검증을 대신하지 않는다.

넷째, 경보는 유지된 5분 구간마다 평가하였다. 정상 기록의 시간당 경보 구간 수는 연속 경보를 하나의 사건으로 합친 임상 경보 빈도와 다르다. 탐지 지연, 사용자 반응, 불필요한 개입이나 임상 결과의 개선은 평가하지 않았다. 준비된 입력의 모델 추론 시간도 원자료 수집·전처리·특징 계산을 모두 포함하는 처리시간과 구별해야 한다.

다섯째, 분만 결과 분석은 결과가 관측된 기록에 한정되며, 특히 pH의 관측 여부에 따라 기록 구성이 달랐다. 모니터링과 분만 사이의 시간, 분만 중 개입, 실제 예측 시점에 임상정보가 이용 가능했는지 등을 통제하지 못하였다. 추가한 정보는 실제 전문가 판독 요약이므로, 그 증분을 자동 모델의 분만 결과 예측력으로 해석할 수 없다. 성능 차이의 신뢰구간은 고정된 예측에 대한 산모 구성의 변동을 나타내며 학습·선택·분할의 모든 변동을 포함하지 않는다.

6.2 향후 과제

우선 변수의 측정 대상을 독립적으로 확인할 자료가 필요하다. 기저선과 사건 유형·시각을 명시한 참조 주석을 마련하고, 기록별 수치 대응과 사건별 검출 정확도를 나누어 검증해야 한다. 제공 라벨의 구체적인 생성·판정 절차도 확인하여 비교 기준의 의미를 정리할 필요가 있다.

추출 규칙에서는 기저선의 시간 범위, 창 경계의 사건 연결, 진폭 조건과 사건 시작·회복 경계의 분리, 특징별 평활 강도, TOCO 영점 처리와 수축 대응을 검토할 수 있다. 실제 사용을 목표로 할 때는

예측 시점에 이용 가능한 과거 정보의 범위를 명시해야 한다. 이러한 변경이 판독 재현을 개선하는지는 원래 모델과 같은 분할·학습 예산의 짝지은 비교 및 새로운 평가 자료에서 확인해야 하며, 본 보고서는 그 개선 효과를 주장하지 않는다.

적용 단계에서는 새 기관·기간의 자료에서 확률 보정과 경보 기준을 다시 평가하고, 구간 경보를 실제 경보 사건으로 묶는 규칙과 탐지 지연을 함께 검토해야 한다. 산모·태아의 주요 임상 특성별 성능, 입력 품질, 경보에 대한 사용자의 대응과 임상 결과를 평가하여 판독 재현 성능이 실제 보조 가치로 이어지는지 확인할 필요가 있다.

Data availability

분석 코드는 다음 저장소에 공개하였다.

https://github.com/yabsed/fetalguard-results

저장소의 notebook 폴더에는 데이터 준비, 파형 인자 계산, 모델 학습과 평가에 사용한 노트북 00~10이 있고, report-abstract 폴더에는 장별 방법과 수식 정의를 정리하였다. 원자료는 건양대학교의료원 의료데이터안심존에서만 분석할 수 있어 저장소에 포함하지 않았으며, 자료의 접근과 제공은 데이터 관리기관의 절차를 따른다. 따라서 노트북을 다시 실행하려면 승인된 자료 접근이 필요하다. 보고서에는 개인별 신호, 식별자, 예측값을 포함하지 않았다. 분석 설계는 3장, 인자별 계산 규칙과 주석 비교는 부록 A와 부록 B에 정리하였다.

5.2절의 그림17은 체코 브르노 대학병원에서 수집된 공개 데이터인 CTU-UHB Intrapartum CTG Database(Chudáček et al., 2014)로 작성하였으며, 출처와 라이선스(ODC Attribution License v1.0)를 그림 아래에 표시하였다. 그 밖의 표와 그림은 본 분석의 결과이다. 수치는 원칙적으로 소수점 셋째 자리까지 표시하되, 작은 값의 부호를 보존할 필요가 있으면 자릿수를 늘렸다. 계산과 임계값 적용에는 반올림 전 값을 사용하였다. 별도 표시가 없는 신뢰구간은 95%이다.

참고문헌

1. 박창은. (2025). 태아심박동 자동 해석을 위한 딥러닝 모델: 전국 다기관 연구 [석사학위논문, 아주대학교 대학원].
2. 아마데이터. (2026). CTG 파형 특성의 정의 및 추출을 통한 이상 판독(Abnormality) 예측 모델 개선: 파형 특성 인자 분석과 Abnormality의 임상적 이해 [2026 K-Health 미개방 의료데이터 활용 경진대회 아이디어 제안서]. (본문 인용 표기: 제안서)
3. 한국지능정보사회진흥원(NIA). (2023). 태아심박동 모니터링 데이터 인공지능 학습용 데이터 구축·활용 가이드라인 (V1.0). 한국지능정보사회진흥원. (사업 총괄: 아주대학교 산학협력단)
4. American College of Obstetricians and Gynecologists. (2009). ACOG Practice Bulletin No. 106: Intrapartum fetal heart rate monitoring: Nomenclature, interpretation, and general management principles. *Obstetrics & Gynecology, 114*(1), 192–202. https://doi.org/10.1097/AOG.0b013e3181aef106 (본문 인용 표기: ACOG, 2009)
5. American College of Obstetricians and Gynecologists. (2025). ACOG Clinical Practice Guideline No. 10: Intrapartum fetal heart rate monitoring: Interpretation and management. *Obstetrics & Gynecology, 146*(4), 583–599. https://doi.org/10.1097/AOG.0000000000006049 (본문 인용 표기: ACOG, 2025)
6. Arnold, J. J., & Gawrys, B. L. (2020). Intrapartum fetal monitoring. *American Family Physician, 102*(3), 158–167.
7. Ayres-de-Campos, D., Spong, C. Y., & Chandraharan, E.; FIGO Intrapartum Fetal Monitoring Expert Consensus Panel. (2015). FIGO consensus guidelines on intrapartum fetal monitoring: Cardiotocography. *International Journal of Gynecology & Obstetrics, 131*(1), 13–24. https://doi.org/10.1016/j.ijgo.2015.06.020 (본문 인용 표기: FIGO, 2015)
8. Bosco, M., Uccella, S., De Bellis, B., D'Alessandro, R., Laterza, R., & Garzon, S. (2025). Insight into the abnormal cardiotocographic patterns following neuraxial analgesia for pain management in labor. *American Journal of Obstetrics & Gynecology MFM, 7*(10), 101747. https://doi.org/10.1016/j.ajogmf.2025.101747

9. Campbell, K. S. J., Collier, A. C., Irvine, M. A., Brain, U., Rurak, D. W., Oberlander, T. F., & Lim, K. I. (2021). Maternal serotonin reuptake inhibitor antidepressants have acute effects on fetal heart rate variability in late gestation. *Frontiers in Psychiatry, 12*, 680177. https://doi.org/10.3389/fpsyt.2021.680177

10. Chiou, N., Young-Lin, N., Kelly, C., Cattiau, J., Tiyasirichokchai, T., Diack, A., Koyejo, S., Heller, K., & Asiedu, M. (2025). Development and evaluation of deep learning models for cardiotocography interpretation. *npj Women's Health, 3*, 21. https://doi.org/10.1038/s44294-025-00068-w

11. Chudáček, V., Spilka, J., Burša, M., Janků, P., Hruban, L., Huptych, M., & Lhotská, L. (2014). Open access intrapartum CTG database. *BMC Pregnancy and Childbirth, 14*, 16. https://doi.org/10.1186/1471-2393-14-16

12. Ganeshamoorthy, A., Duke, O. F., Mistry, H. D., Bone, J. N., Vidler, M., Abalos, E., Badawy, K., Khalil, A., von Dadelszen, P., & Magee, L. A. (2025). Antihypertensive therapy for pregnancy hypertension and implications for fetal and neonatal heart rate monitoring: A systematic review of randomized trials and observational studies. *Acta Obstetricia et Gynecologica Scandinavica, 104*(10), 1822–1837. https://doi.org/10.1111/aogs.70019

13. Hikma Pharmaceuticals USA Inc. (2024). Terbutaline sulfate injection, USP [Prescribing information]. DailyMed. https://dailymed.nlm.nih.gov/dailymed/drugInfo.cfm?setid=613df3cb-4d55-4d12-ab08-a932481aaa0b

14. Leeflang, M. M., Rutjes, A. W., Reitsma, J. B., Hooft, L., & Bossuyt, P. M. (2013). Variation of a test's sensitivity and specificity with disease prevalence. *CMAJ, 185*(11), E537–E544. https://doi.org/10.1503/cmaj.121286

15. Nensi, A., De Silva, D. A., von Dadelszen, P., Sawchuck, D., Synnes, A. R., Crane, J., & Magee, L. A.; MAG-CP Collaborative Group. (2014). Effect of magnesium sulphate on fetal heart rate parameters: A systematic review. *Journal of Obstetrics and Gynaecology Canada, 36*(12), 1055–1064. https://doi.org/10.1016/S1701-2163(15)30382-0

16. Olofsson, P., Ekengård, F., & Herbst, A. (2021). Time to reconsider: Have the 2015 FIGO and 2017 Swedish intrapartum cardiotocogram classifications led us from Charybdis to Scylla? *Acta Obstetricia et Gynecologica Scandinavica, 100*(9), 1549–1556. https://doi.org/10.1111/aogs.14201

17. Sekhavat, L., & Behdad, S. (2009). The effects of meperidine analgesia during labor on fetal heart rate. *International Journal of Biomedical Science, 5*(1), 59–62.

18. Subtil, D., Tiberghien, P., Devos, P., Therby, D., Leclerc, G., Vaast, P., & Puech, F. (2003). Immediate and delayed effects of antenatal corticosteroids on fetal heart rate: A randomized trial that compares betamethasone acetate and phosphate, betamethasone phosphate, and dexamethasone. *American Journal of Obstetrics and Gynecology, 188*(2), 524–531. https://doi.org/10.1067/mob.2003.136

19. Verdurmen, K. M., Renckens, J., van Laar, J. O., & Oei, S. G. (2013). The influence of corticosteroids on fetal heart rate variability: A systematic review of the literature. *Obstetrical & Gynecological Survey, 68*(12), 811–824. https://doi.org/10.1097/OGX.0000000000000002

20. Verdurmen, K. M. J., Hulsenboom, A. D. J., van Laar, J. O. E. H., & Oei, S. G. (2017). Effect of tocolytic drugs on fetal heart rate variability: A systematic review. *The Journal of Maternal-Fetal & Neonatal Medicine, 30*(20), 2387–2394. https://doi.org/10.1080/14767058.2016.1249844

21. Yonaga, Y., & Ito, A. (2021). The safety of ritodrine hydrochloride: Adverse effects on fetuses and newborns. *Drug Discoveries & Therapeutics, 15*(1), 14–19. https://doi.org/10.5582/ddt.2021.01016

부록 A. 파형 인자 28 개의 계산 규칙

공통 계산 조건

F와 T는 전처리 후 태아 심박수(FHR)와 자궁수축 신호(TOCO), N=150은 5분 구간의 표본 수, B는 반복 추정한 기저선이다. 두 채널의 0을 보간한 뒤 15표본(30초) 중심 이동평균을 적용한다. 평균과 분산의 분모는 배열 길이이며 표준편차는 모집단식(ddof=0)을 사용한다. |J|는 검출 사건 J에 속한 표본 수이다.

모든 인자는 같은 전처리 파형에서 계산하며, 구간 경계를 넘는 사건은 연결하지 않는다. 인자명은 아래 계산 규칙을 가리키고 임상 소견과의 동일성을 전제하지 않는다. 공통 해석 제한은 5.2절에, 실제 분포와 판독 주석의 비교는 부록 B에 정리하였다.

표37. 신호 수준과 산포: 4개 인자의 계산 규칙

변수(코드)	단위	계산 규칙
fhr_mean	bpm	FHR 전체의 산술평균: $\Sigma F_t/N$.
fhr_min	bpm	FHR 전체의 최솟값: $\min F_t$.
fhr_max	bpm	FHR 전체의 최댓값: $\max F_t$.
fhr_sd	bpm	FHR 평균을 기준으로 한 표준편차: $\sqrt{\{\Sigma(F_t-\text{평균})^2/N\}}$.

표38. 기저선과 분포: 4개 인자의 계산 규칙

변수(코드)	단위	계산 규칙
figo_baseline	bpm	양수 FHR 평균에서 시작하여 현재값과 차이가 15 bpm 미만인 양수 표본의 평균으로 반복 갱신. 변화<0.5 bpm 또는 50회에서 종료. 최종 마스크는 마지막 갱신에 사용한 표본 집합이다.
hist_median	bpm	전처리 FHR의 중앙값. 150개 값의 가운데 두 값을 평균.
hist_mode	bpm	min F~max F 범위를 같은 너비의 24개 상자로 나누고 최다 표본 상자의 중점을 반환. 동률이면 가장 낮은 상자 선택. 상수 c이면 범위를 c±0.5로 확장.
hist_width	bpm	FHR 범위: $\max F_t-\min F_t$.

hist_width는 fhr_max와 fhr_min에서 파생되며, hist_mode는 최빈 상자의 중점이다.

표39. 변이: 2개 인자의 계산 규칙

변수(코드)	단위	계산 규칙
stv	bpm	인접한 2초 간격 FHR의 절대차 평균: $\Sigma\lvert F_{t+1}-F_t\rvert/149$.
figo_baseline_var	bpm	기저선의 마지막 마스크에서 3표본 이상 연속 부분을 찾고 각 부분의 인접 극값 높이 차이를 모아 평균. 평탄부와 끝점은 극값에서 제외하고 서로 다른 마스크 구간은 연결하지 않는다. 극값 쌍이 없으면 0.

stv는 2초 표본의 차이를 요약하며 박동 간격 기반 STV와 구분한다. 두 변이도 인자를 제거한 조건에도 fhr_sd는 남는다.

표40. 낮거나 높은 심박수: 2개 인자의 계산 규칙

변수(코드)	단위	계산 규칙
brady_frac	비율(0~1)	FHR이 110 bpm 미만인 표본 수/N. 정확히 110인 값은 포함하지 않음.
tachy_frac	비율(0~1)	FHR이 160 bpm 초과인 표본 수/N. 정확히 160인 값은 포함하지 않음.

두 비율은 고정 문턱을 벗어난 표본의 비율이며, 연속 지속시간 조건을 적용하지 않는다.

표41. 가속과 감속: 9개 인자의 계산 규칙

변수(코드)	단위	계산 규칙
n_decel	건/5분 구간	양수 FHR이 B−15 bpm 이하로 8표본 이상 이어지는 최대 연속 구간 수.
decel_max_depth	bpm	검출 감속 J마다 B−min(F_t:t∈J)를 구한 뒤 최댓값. 검출 감속이 없으면 0.
decel_time_frac	비율(0~1)	검출 감속에 속하는 표본 수 합/N: Σ|J|/150.
n_accel	건/5분 구간	양수 FHR이 B+15 bpm 이상인 8표본 이상 후보 중 첫 최고점까지<30초, 전체 길이<600초인 사건 수.
n_early_decel	건/5분 구간	후기 감속 조건을 충족하지 않고 지속시간이 180초 미만인 검출 감속 수.
n_late_decel	건/5분 구간	감속 시작과 시작 시점이 가장 가까운 수축을 택하고, 수축 시작+20초<감속 시작<수축 끝이면 후기 분류. 이 조건을 지속시간에 따른 분류보다 먼저 적용한다.
n_variable_decel	건/5분 구간	각 검출 감속의 시작 후 첫 최저점까지 시간이 30초 미만인 사건 수. 최저점 동률이면 첫 위치 사용. 다른 감속 유형과 중복 계수한다.
n_severe_decel	건/5분 구간	후기 조건이 아니면서 지속시간이 300초를 초과하는 검출 감속 수. 300초 창에서는 항상 0이다.
n_prolonged_decel	건/5분 구간	후기 조건이 아니면서 지속시간이 180~300초(양 끝 포함)인 검출 감속 수.

사건 지속시간은 표본 수×2초이다. n_decel은 조기, 후기, 지속성, 중증 감속 수의 합이며 변이감속 수는 이 합에 더하지 않는다.

표42. 수축과 신호 연동: 7개 인자의 계산 규칙

변수(코드)	단위	계산 규칙
toco_mean	원자료 척도	전처리한 TOCO의 산술평균.
toco_max	원자료 척도	전처리한 TOCO의 최댓값.
toco_sd	원자료 척도	TOCO 표준편차: √{Σ(T_t−평균)²/N}.
n_contractions	건/5분 구간	피크 간 거리≥60초, 돌출도≥TOCO 표준편차/2를 적용. 피크에서 돌출도의 90% 만큼 내려간 높이의 너비가 45~120초인 경우 채택. 끝점은 피크에서 제외한다. 너비를 확인한 뒤 반올림한 경계를 감속 분류에 사용한다.
ft_corr0	상관계수(무단위)	같은 시간 위치의 FHR과 TOCO의 Pearson 상관.
ft_corr_min	상관계수(무단위)	−60~60초를 2초 간격으로 이동하여 겹치는 표본의 Pearson 상관을 구하고 부호 있는 최솟값 선택.
ft_corr_min_lag_s	초	최소 상관을 얻는 시차. 양수이면 뒤쪽 FHR과 앞쪽 TOCO를 대응. 동률은 0, 음의 시차 오름차순, 양의 시차 오름차순 순서로 선택.

상관은 두 신호가 겹치는 부분에서 계산한다. 한 채널이 상수이거나 비교 길이가 2 미만이면 0으로 처리한다. 최소 상관은 절댓값이 아닌 부호 있는 값의 최솟값이다.

부록 B. 파형 인자의 계산 특성과 주석 비교

94,148개 구간 모두에서 평활과 비평활 인자 28개를 계산하였으며, 평활 조건에서 상수가 아닌 열은 26개였다. 아래 주석 비교는 7개 파생값의 기록별 대응을 점검한 결과이다. 전체 28개의 임상 측정 타당성을 검증한 것은 아니며, 계산 규칙과 해석 제한은 부록 A와 5.2절에 제시하였다.

기록 안의 구간별 기저선과 기저선 변이도는 평균으로, 가속과 감속 횟수는 합계로 모아 판독 주석과 비교하였다. 비교 가능한 기록은 7개 항목 모두 22,137건이었고 결측으로 빠진 기록은 없었다. 기저선은 Spearman 상관계수 0.987, 평균 절대차 0.938 bpm으로 높은 대응을 보였다. 반면 기저선 변이도의 상관계수는 0.259였으며, 감속 유형별 존재 판별 AUROC도 0.500~0.773으로 차이가 있었다.

표43. 파형 인자의 기록별 집계와 판독 주석의 대응

판독 주석 / 계산 인자	Spearman ρ	MAE (bpm)	주석상 존재 기록	존재 판별 AUROC
기저선 / figo_baseline	0.987	0.938	—	—
기저선 변이도 / figo_baseline_var	0.259	—	—	—
가속 / n_accel	−0.146	—	14,287	0.567
조기감속 / n_early_decel	0.194	—	1,447	0.656
후기감속 / n_late_decel	0.140	—	515	0.637
변이감속 / n_variable_decel	0.464	—	2,990	0.773
지속감속 / n_prolonged_decel	산출 불가	—	380	0.500

모든 행의 비교 단위는 기록이며 N=22,137이다. Spearman 상관은 주석의 원래 코드와 계산값을 비교하였다. 존재 판별 AUROC의 양성은 가속에서 주석값 1, 감속에서 0보다 큰 값이다. 주석상 존재 기록은 이 이진 기준의 양성 수다. —는 해당 지표를 계산하지 않은 경우이며, 지속감속의 상관은 계산값이 상수여서 정의되지 않는다. 이 표에는 신뢰구간을 산출하지 않았다.

가속 주석은 1=있음, 2=없음이므로 음의 순위 상관과 '있음'을 양성으로 삼은 AUROC를 구분해야 한다. 이 비교는 전체 기록을 사용했으며, 4장의 시험 구간별 Abnormality 예측과 대상과 단위가 다르다.

표44. 이번 평활 특징표에서 상수였던 인자

인자	고유값 수	0인 구간 / 전체	계산 규칙과 해석
n_severe_decel	1	94,148 / 94,148 (100%)	후기감속이 아니면서 300초를 넘는 감속. 5분 구간 안에서는 관측할 수 없음.
n_prolonged_decel	1	94,148 / 94,148 (100%)	후기감속이 아니면서 180~300초인 감속. 이번 평활 결과에서는 검출되지 않음.

severe의 0은 5분 창의 구조적 제약이고, prolonged의 0은 이번 분석의 관찰 결과이다. 지속감속 주석 380건은 기록 단위이므로 구간별 미검출률로 환산하지 않았다.

부록 C. 임신과 분만 중 사용 약물의 태아 심박 영향

표C1. 임신과 분만 중 사용 약물의 태아 심박 영향

약물 (분류)	주요 적응증	태아 심박 영향	크기 또는 빈도	근거
Meperidine, morphine, fentanyl, nalbuphine (opioid)	분만 진통	변이도와 가속 감소, 동등 용량에서 유사	투여 후 30분 이내 변이도 소실 또는 5 bpm 이하 20.0%(대조군 5.4%), 감속 49.3%(대조군 22.7%)	ACOG, 2009, pp. 197–198; Sekhavat & Behdad, 2009, pp. 60–61
Butorphanol (opioid agonist-antagonist)	분만 진통	일시적 sinusoidal 양상, meperidine 대비 평균 심박수 약간 증가	Sinusoidal 양상 75%	ACOG, 2009, pp. 197–198
Bupivacaine, lidocaine (local anesthetic, 신경축 진통)	분만 진통	교감신경 차단과 저혈압을 통한 심박 변화	신경축 진통 후 30분 이내 지속감속 6.57%(59/898)	ACOG, 2009, p. 197; Bosco et al., 2025
Oxytocin, prostaglandin (uterotonic)	분만 유도와 촉진	자궁 과수축을 통한 심박 변화	미보고	ACOG, 2025, p. 590; FIGO, 2015, p. 22
Betamethasone, dexamethasone (corticosteroid)	태아 폐 성숙	변이도와 가속의 일시적 변화, 29주 이후 효과 증가	변이도 0~1일 +9%, 2~3일 –14%, 가속 2일 –35%, 4일에 회복	ACOG, 2009, p. 198; Subtil et al., 2003; Verdurmen et al., 2013
Magnesium sulfate (electrolyte, anticonvulsant)	전자간증과 자간증의 경련 예방	단기 변이도 감소, 가속 증가 억제	기저선 최대 약 15 bpm 감소(정상 범위 유지), 변이도 감소 보고 8.3~87.5%, 개입이 필요한 수준은 아님	ACOG, 2009, pp. 197–198; Nensi et al., 2014, pp. 1055, 1058–1059, 1061–1062
Terbutaline (short-acting β2 agonist)	기관지 경련, 자궁 과수축 시 단기 이완	기저선 상승, 빈맥 증가	미보고	ACOG, 2009, p. 198; FIGO, 2015, p. 22; Hikma Pharmaceuticals USA Inc., 2024, p. 1
Ritodrine (short-acting β2 agonist)	조기진통 억제	심박수 증가, 변이도 감소	빈맥 경구제 ROR 9.47(2.98~30.04)	Verdurmen et al., 2017; Yonaga & Ito, 2021, pp. 14–15
Fenoterol (short-acting β2 agonist)	조기진통 억제	심박수 약간 증가, 변이도 변화 없음	미보고	Verdurmen et al., 2017
Salbutamol (short-acting β2 agonist)	기관지 경련, 일부 국가에서 조기진통 억제	빈맥	미보고	FIGO, 2015, pp. 16, 22
Nifedipine, atosiban, indomethacin	조기진통 억제	임상적으로 중요한 변이도 영향 없음	리뷰 전체 연구 6편, 169명	Verdurmen et al., 2017
Labetalol 등 (antihypertensive)	임신 고혈압	근거 불충분	위약 대비 RR 1.08(0.62~1.89), 관찰연구의 labetalol RR 2.17(1.15~4.08)	Ganeshamoorthy et al., 2025, p. 1822
Atropine, scopolamine (anticholinergic)	서맥과 무스카린 효과 차단, 구역 예방	빈맥, 변이도 감소	미보고	FIGO, 2015, p. 16; Arnold & Gawrys, 2020
Benzodiazepine	불안, 경련	변이도 감소	미보고	Arnold & Gawrys, 2020
Serotonin reuptake inhibitor	우울증	투여 직후 단기 변이도 감소	미보고	Campbell et al., 2021
Zidovudine (antiretroviral)	HIV	기저선, 변이도, 가속, 감속의 차이 없음	차이 없음	ACOG, 2009, p. 198
Cocaine	해당 없음 (비의료적 사용)	장기 변이도 감소(ACOG 표), 특징적 변화 없음(ACOG 본문)	미보고	ACOG, 2009, p. 198

위 표는 임부 사용 약물 전체가 아니라, 가이드라인이나 리뷰, 허가사항에서 태아 심박 영향을 확인한 약물만 계열별로 정리한 것이다. 사용 빈도, 사고 건수, 확립된 중증도 등급, 용량별 심박 변화를 제시한 자료는 찾지 못하였다. 미보고는 확인한 자료에 크기나 빈도의 수치가 없다는 뜻이다. 수치는 연구마다 대상과 기준이 달라 약물 간에 비교할 수 없다. Sekhavat과 Behdad는 초록과 본문의 수치가 달라 본문 표 3의 값을 사용하였다. Magnesium sulfate의 변이도 감소 비율은 연구별 범위이고, FHR이 높아졌다는 보고와 변화가 없었다는 보고도 있다. ACOG는 betamethasone에서만 변이도 감소를 제시하였으나 Subtil et al.은 제제 간 차이가 없다고 보고하였다. ROR은 부작용 보고 자료의 신호로 인과관계를 뜻하지 않는다. 적응증은 허가사항과 근거 문헌을 따랐고, oxytocin, benzodiazepine, zidovudine은 일반적인 적응증이다.